DK 26

Технологии

Когда готовое не подходит — делаем своё: control plane для Software-Defined Storage

Александр Зимин

Технический менеджер продукта подсистемы хранения данных

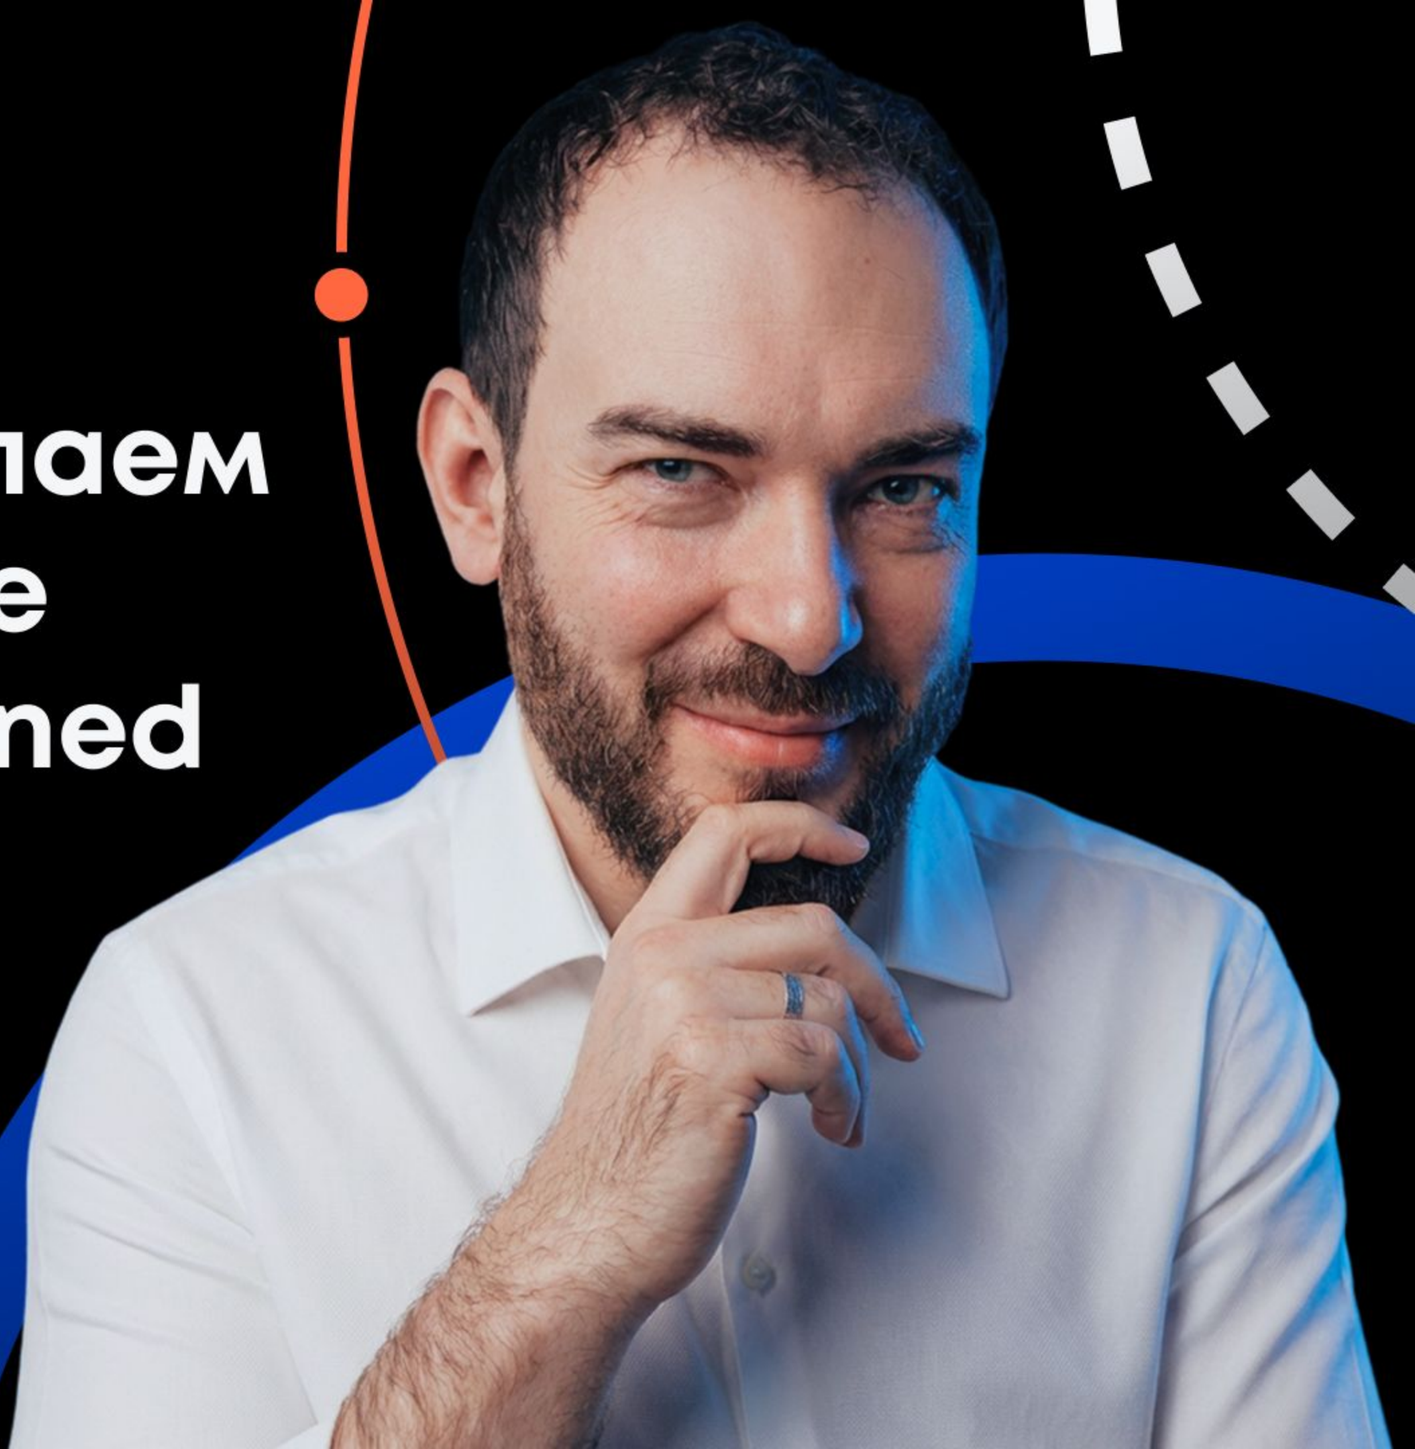

Что такое SDS и зачем оно в кубе?

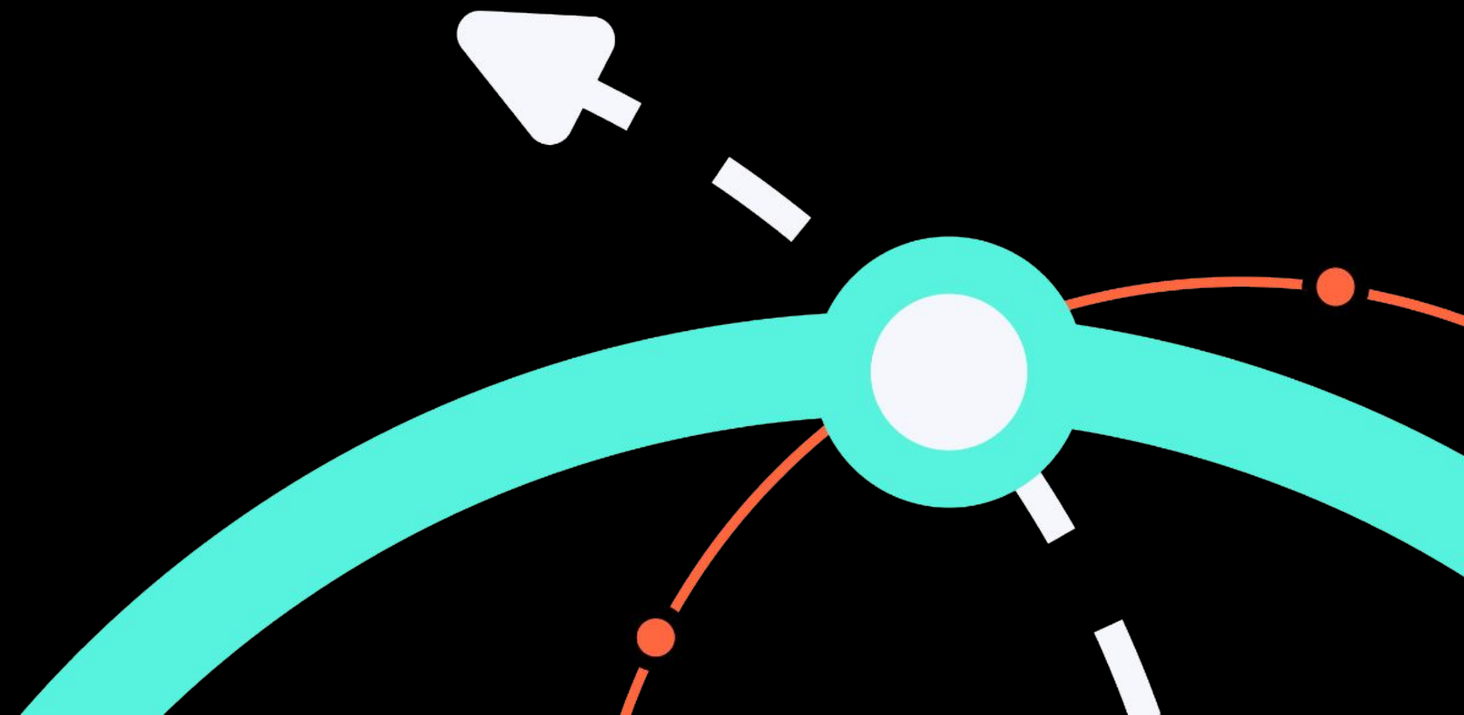

Предыдущий доклад

- Пример реализации простого SDS на локальных дисках
- С какими проблемами столкнулись при разработке
- Кейсы применения

Habr

YouTube

DRBD

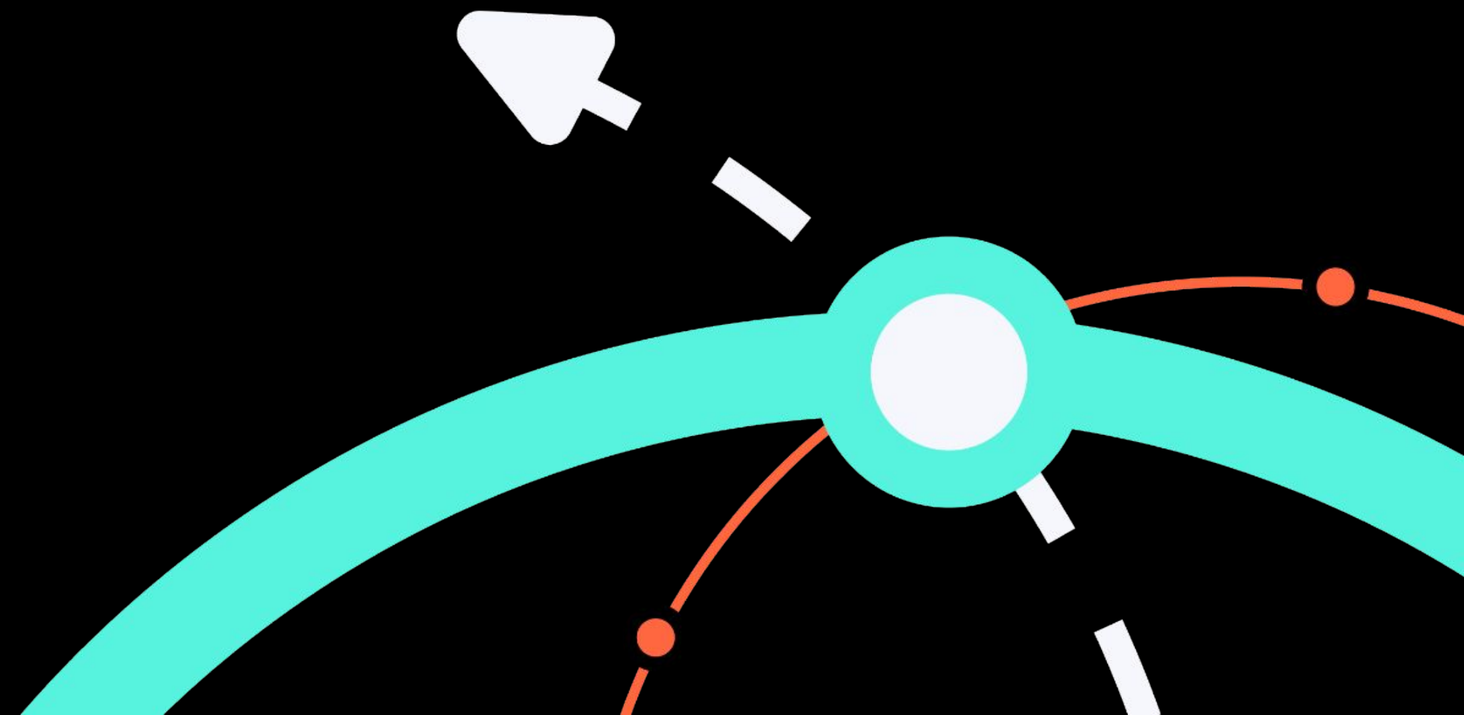

DRBD как data plane — зрелая и быстрая репликация блочных устройств

1. Модуль ядра
2. Есть синхронная репликация
3. Есть кворум

LINSTOR

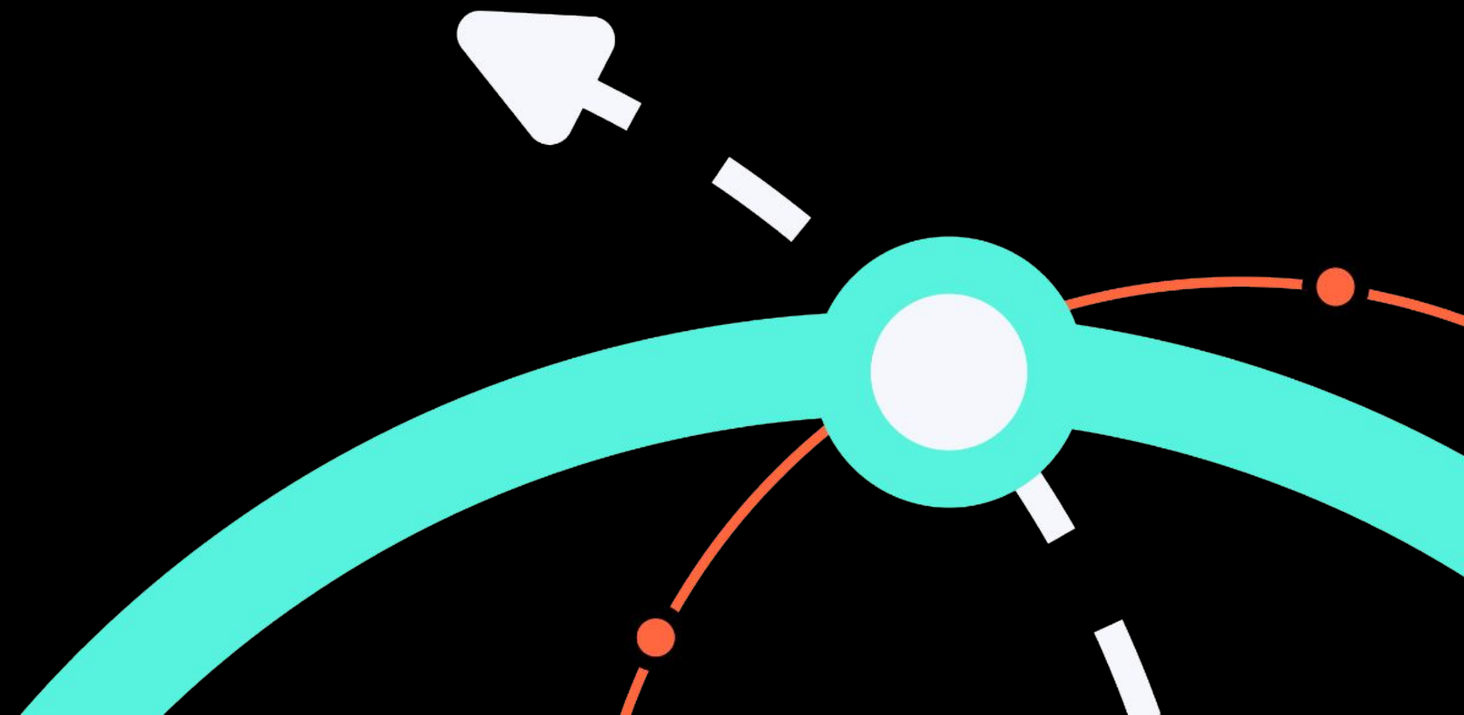

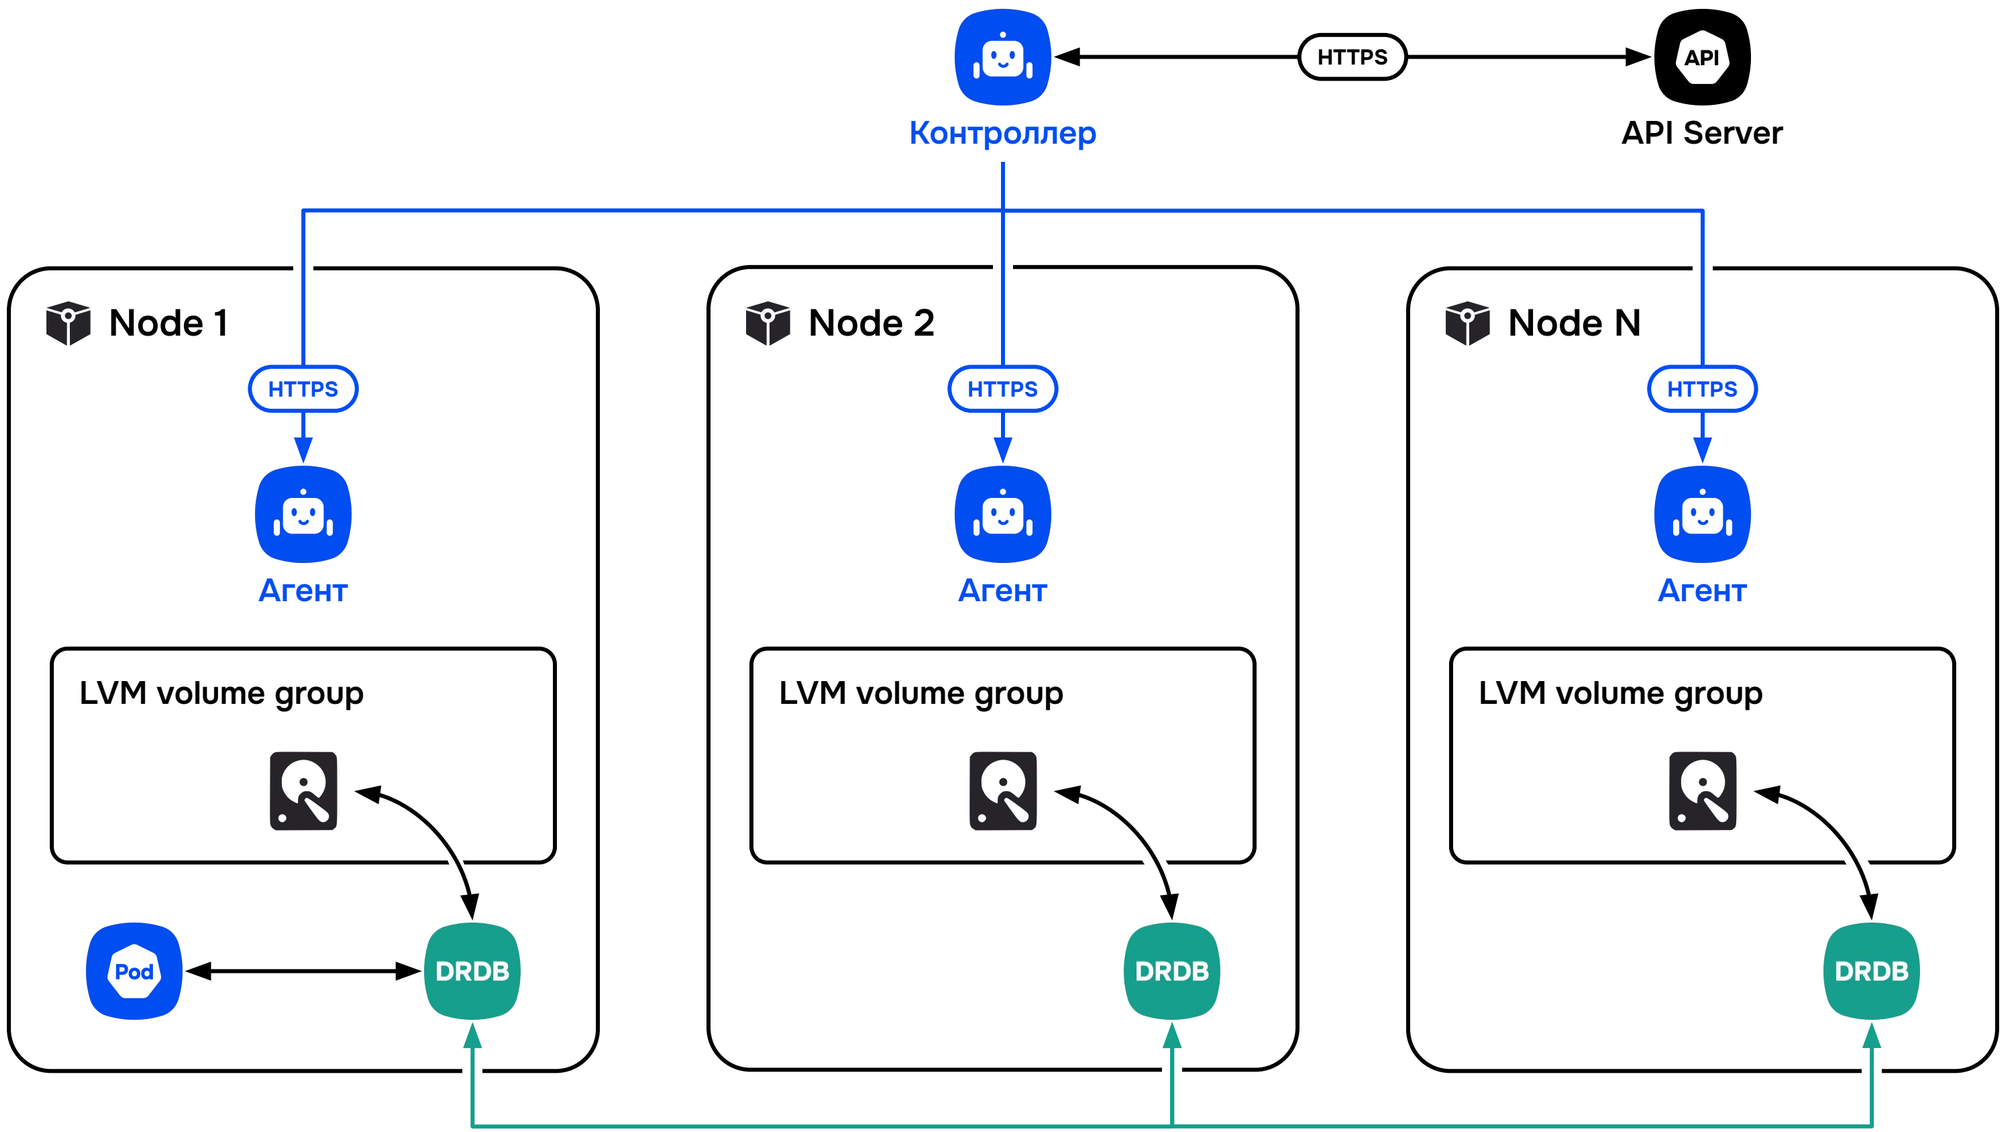
Контроллер
HTTPS
API
API Server
Node 1
HTTPS
Агент
LVM volume group
Pod
DRDB
Node 2
HTTPS
Агент
LVM volume group
DRDB
Node N
HTTPS
Агент
LVM volume group
DRDB

Какие проблемы обнаружили на старте?

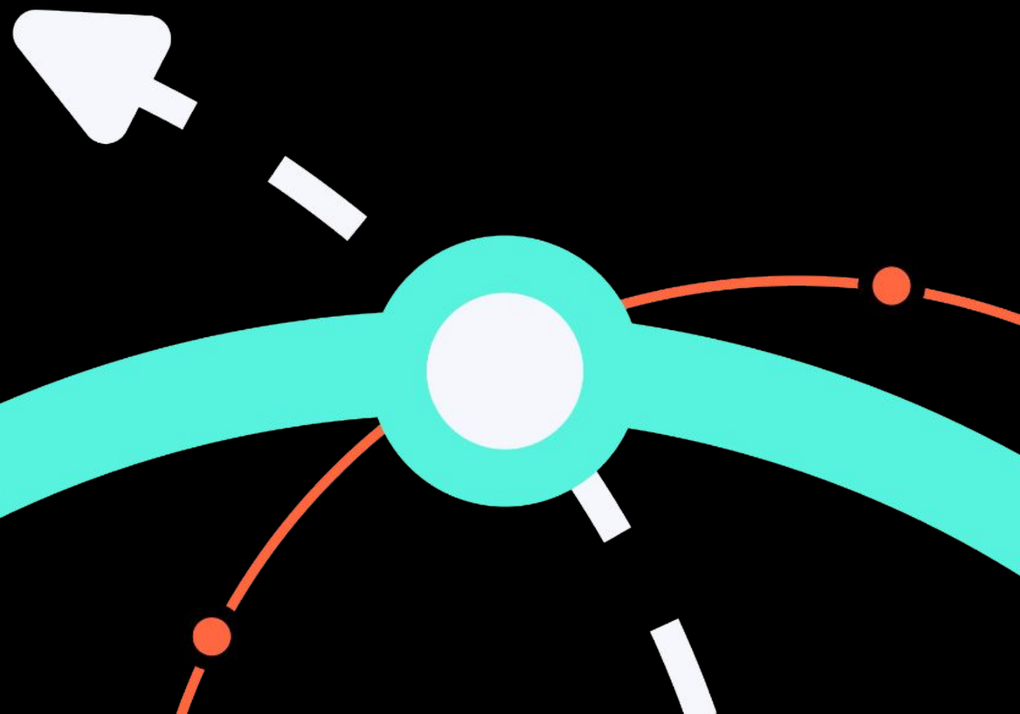

Проблема

- Push-модель

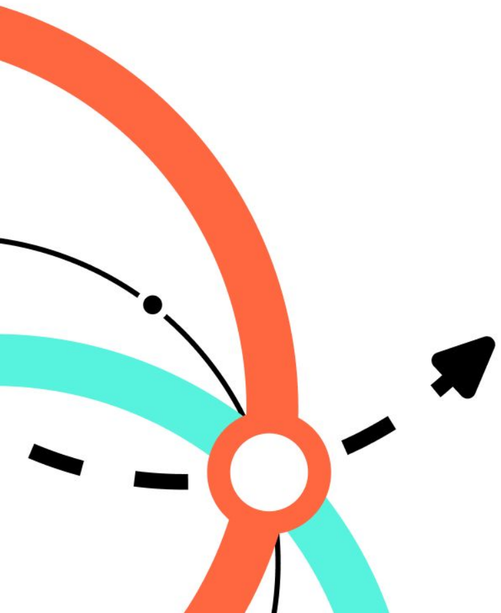

Проблема

- Push-модель

K8s way

- Pull-модель

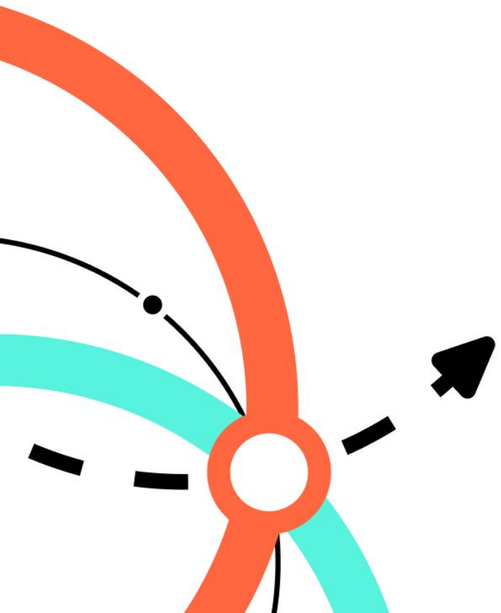

Проблема

- Стек-трейсы в файлах

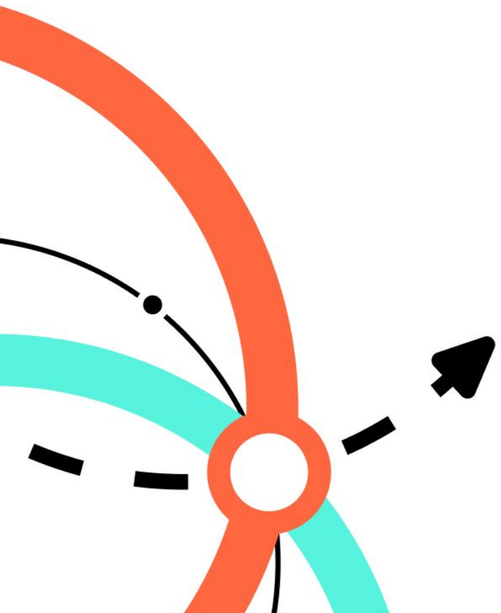

Проблема

- Стек-трейсы в файлах

K8s way

- Стек-трейсы в stderr

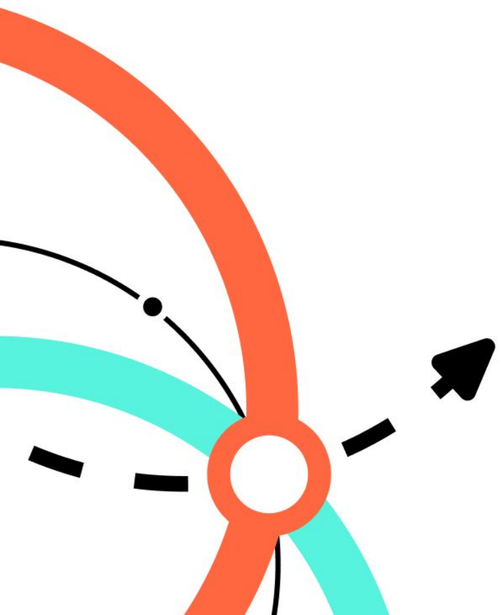

Проблемы при эксплуатации

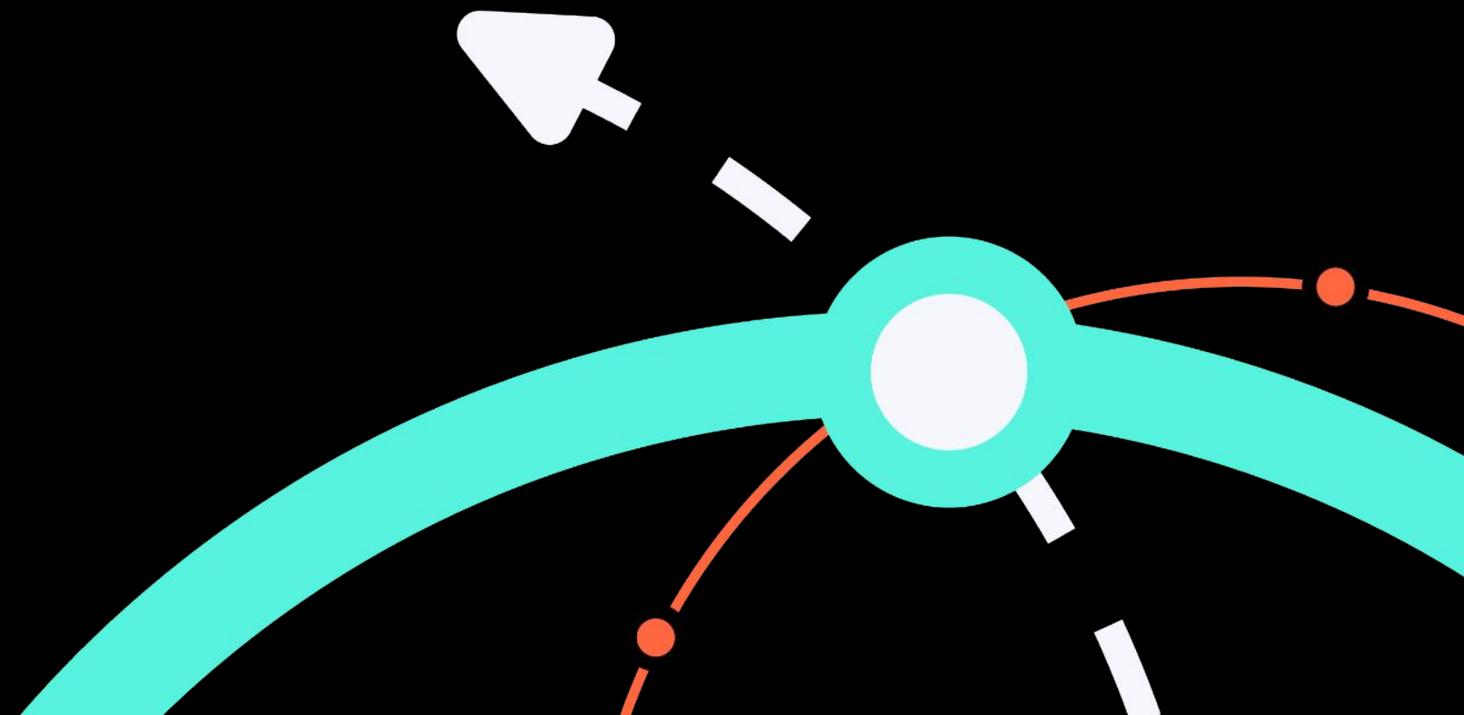

Проблема

- Потеря связи между контроллером и агентами

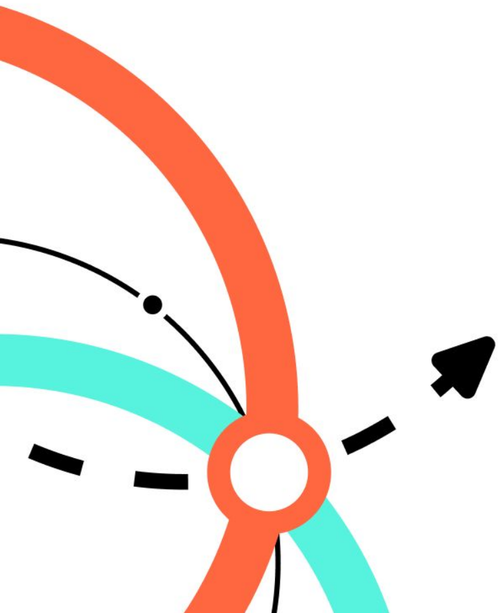

Проблема

- Потеря связи между контроллером и агентами

Решение

- Специфичные liveness-пробы

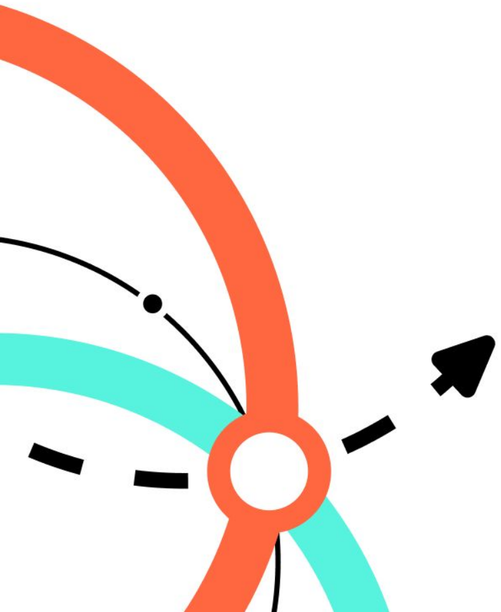

Проблема

- Повреждение БД

Проблема

- Повреждение БД

Решение

- Свой скрипт эвакуации реплик

Проблема

- Баги при ресайзе томов

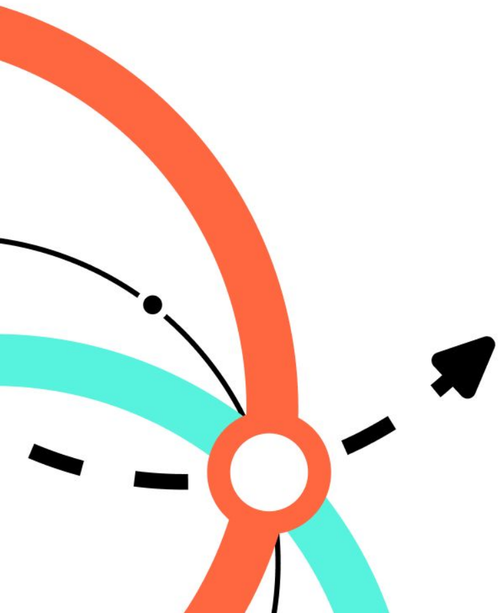

Проблема

- Баги при ресайзе томов

Решение

- Патчи Java-кода

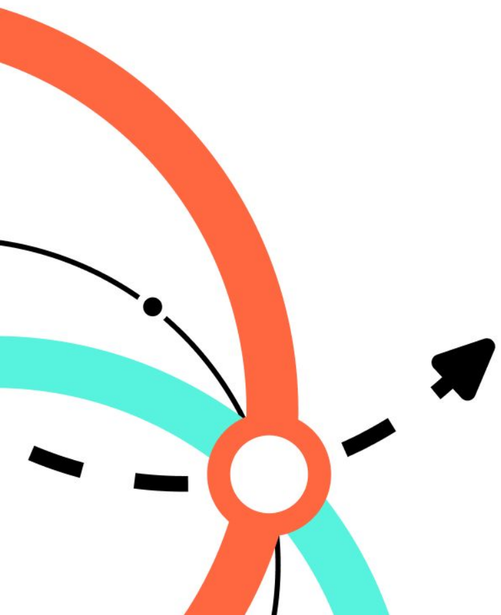

Проблема

- Обновления иногда ломают БД

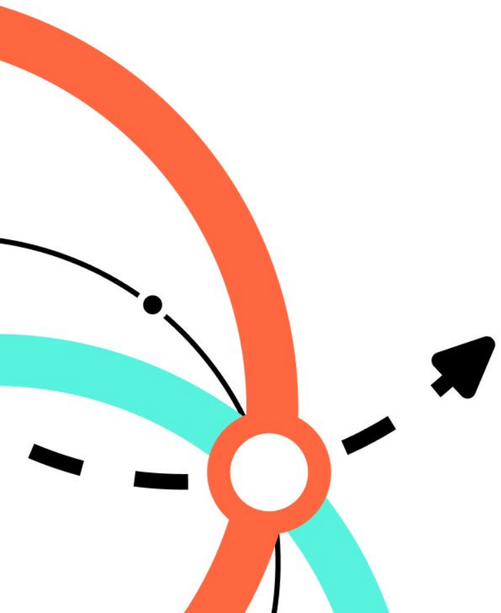

Проблема

- Обновления иногда ломают БД

Решение

- Не обновляться

Проблемы при эксплуатации (без решения)

- Контроллер не вывозит под нагрузкой

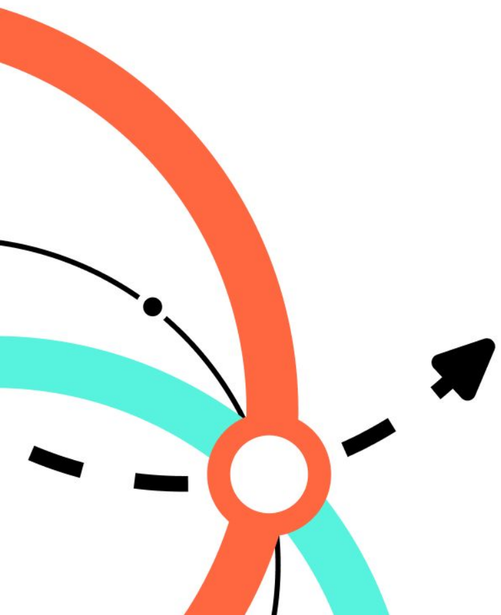

Проблемы при эксплуатации (без решения)

- Отсутствие реакции LINSTOR на изменения окружения

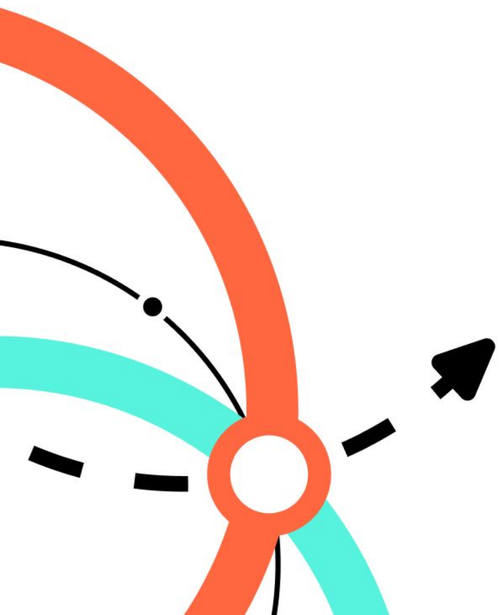

Куб не торт?

Рекомендации для Cloud Native-приложений

- Наличие liveness/readiness/startup-проб

Рекомендации для Cloud Native-приложений

- Наличие liveness/readiness/startup-проб
- Логи в stdout/stderr

Рекомендации для Cloud Native-приложений

- Наличие liveness/readiness/startup-проб
- Логи в stdout/stderr
- Управляющий слой должен вывозить большую нагрузку

Рекомендации для Cloud Native-приложений

- Наличие liveness/readiness/startup-проб
- Логи в stdout/stderr
- Управляющий слой должен вывозить большую нагрузку
- Умение работать в динамических средах

Рекомендации для Cloud Native-приложений

- Наличие liveness/readiness/startup-проб
- Логи в stdout/stderr
- Управляющий слой должен вывозить большую нагрузку
- Умение работать в динамических средах
- Хранить стейт с учётом особенностей платформы

Как жить дальше

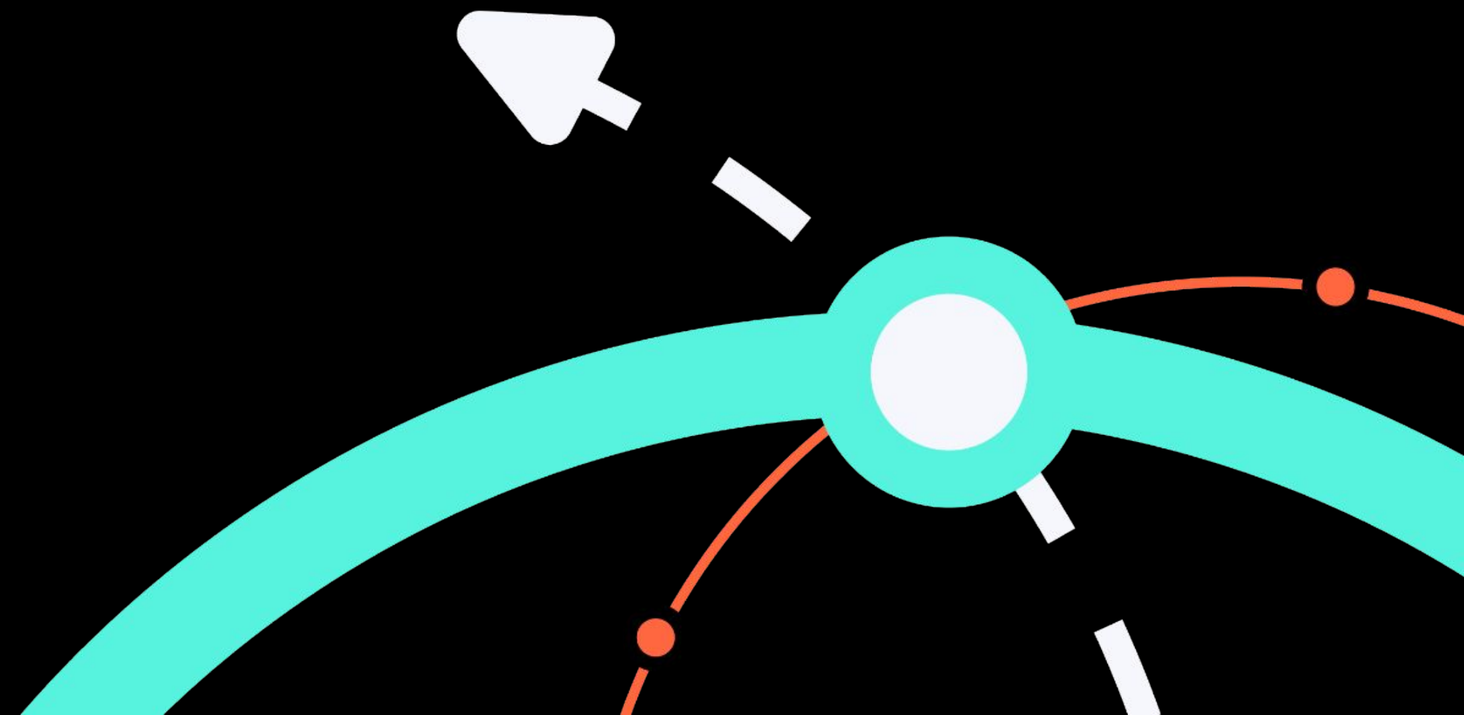

Развивать LINSTOR

→ Не поддерживаются сложные сценарии

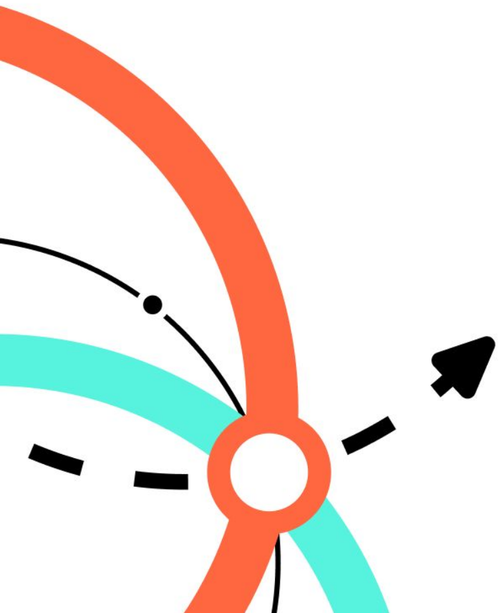

Развивать LINSTOR

- Не поддерживаются сложные сценарии
- Java-экспертиза

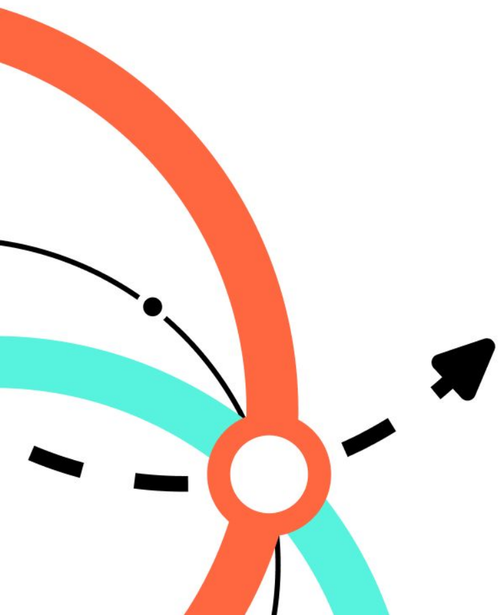

Развивать LINSTOR

- Не поддерживаются сложные сценарии
- Java-экспертиза
- Архитектурные проблемы

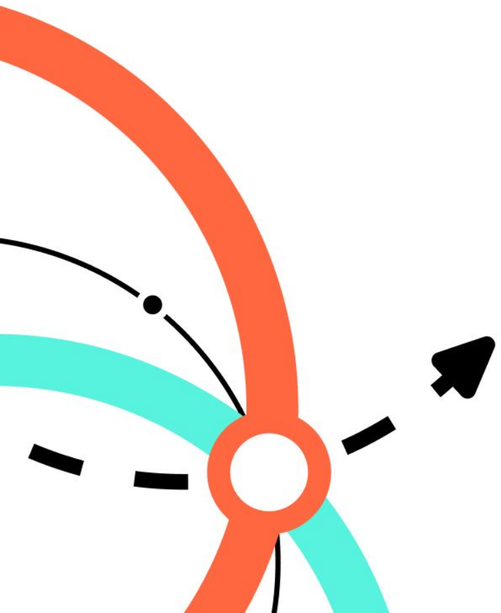

Развивать LINSTOR

- Не поддерживаются сложные сценарии
- Java-экспертиза
- Архитектурные проблемы
- Избыточная универсальность (ZFS и др.)

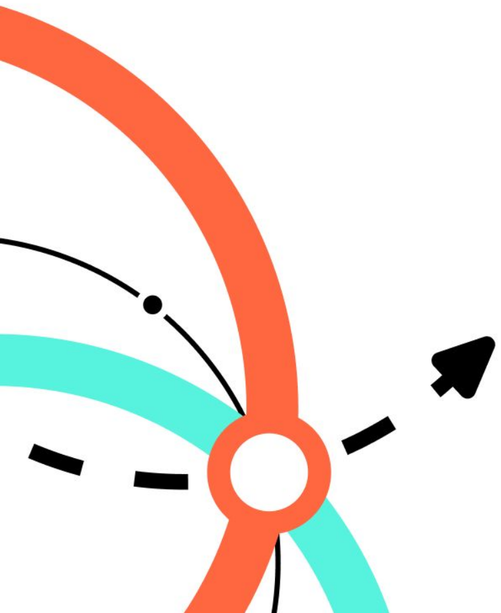

Развивать LINSTOR

- Не поддерживаются сложные сценарии
- Java
- Архитектурные проблемы
- Избыточная универсальность (ZFS и др.)
- Зависимость от upstream

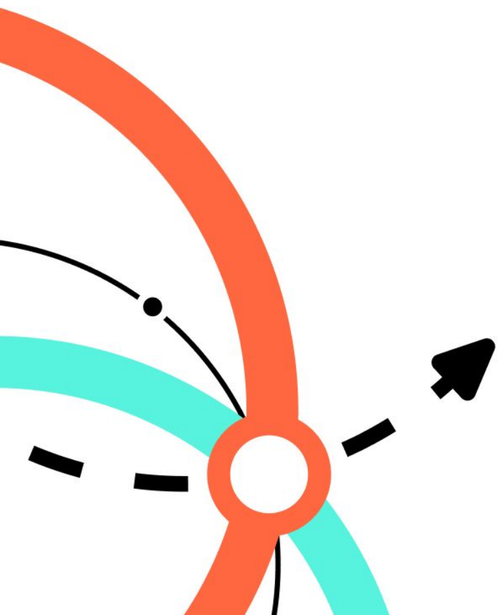

Развивать DRBD

→ Быстрый

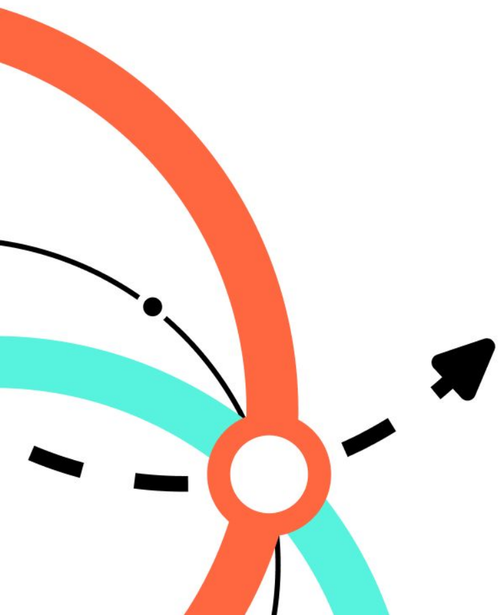

Развивать DRBD

- Быстрый
- Надёжный

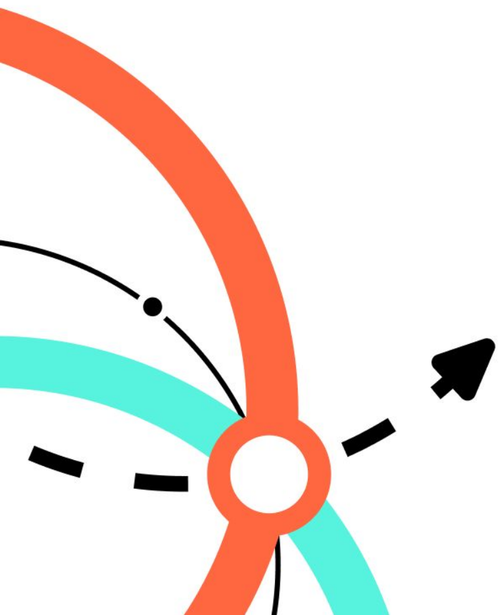

Развивать DRBD

- Быстрый
- Надёжный
- Развивается

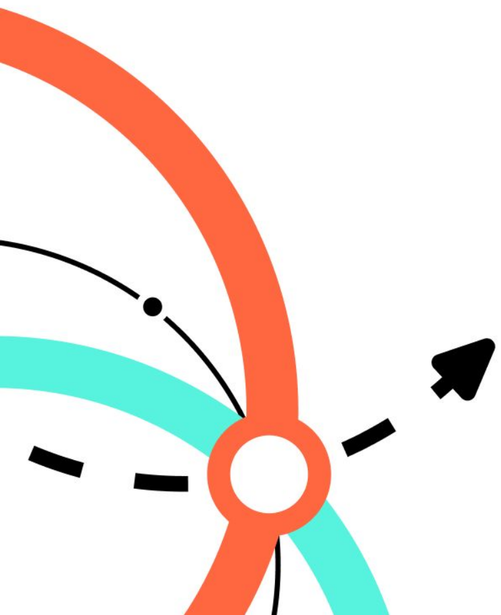

Развивать DRBD

- Быстрый
- Надёжный
- Развивается
- Почти весь функционал нами востребован

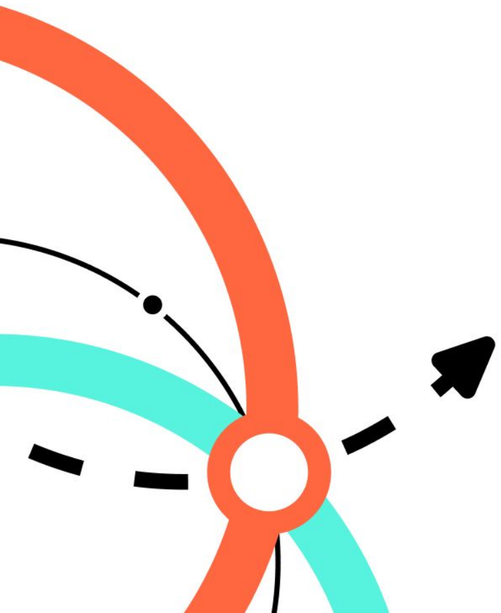

Свой control plane

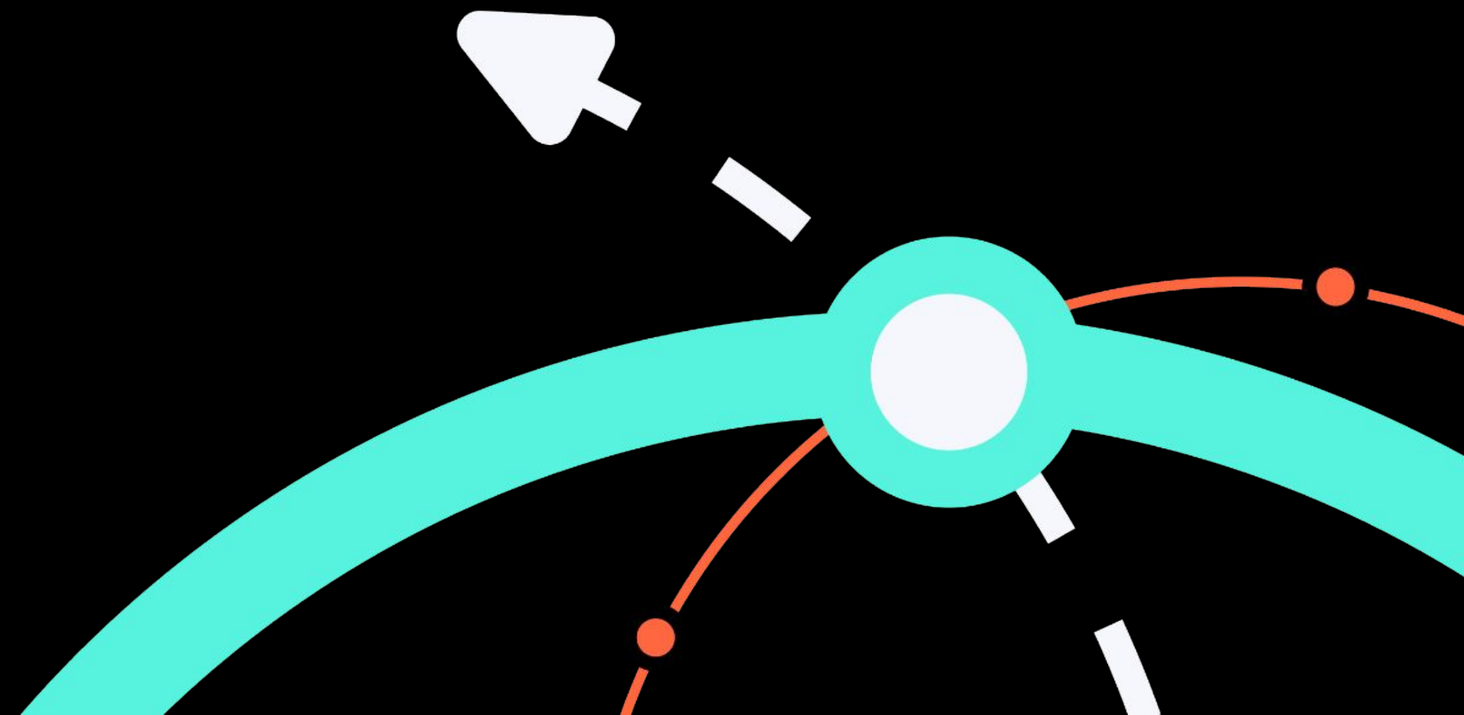

Развивать свой control plane

→ Оставляем DRBD

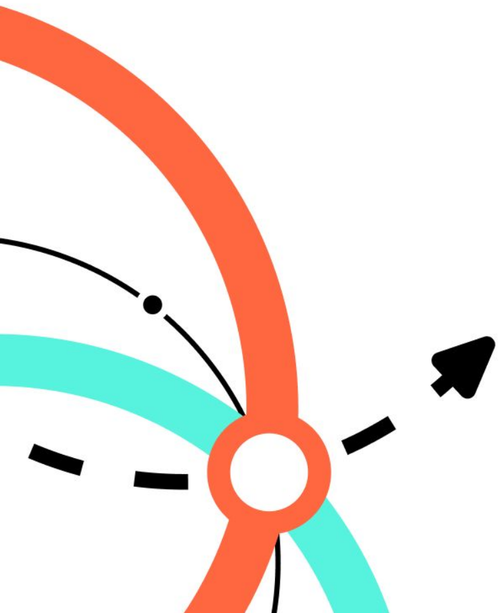

Развивать свой control plane

- Оставляем DRBD
- Go

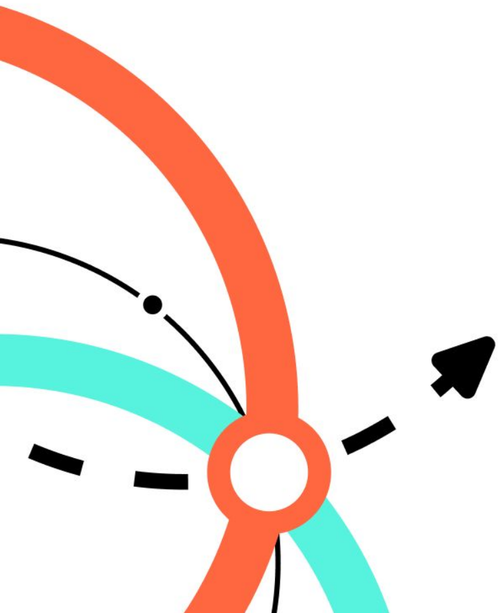

Развивать свой control plane

- Оставляем DRBD
- Go
- Kubernetes way «из коробки»

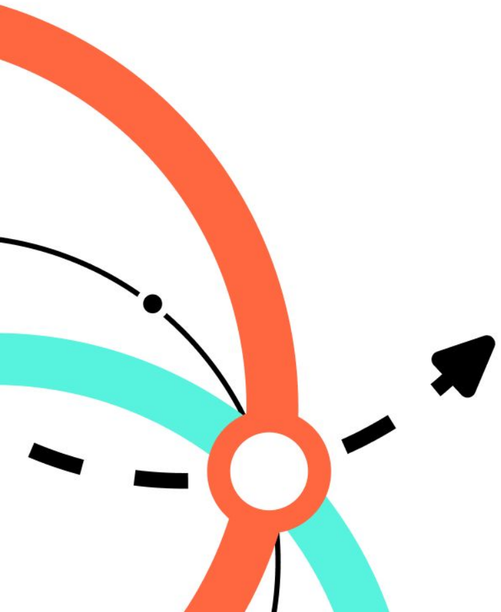

Развивать свой control plane

- Оставляем DRBD
- Go
- Kubernetes way «из коробки»
- Упрощение реализации сложных сценариев

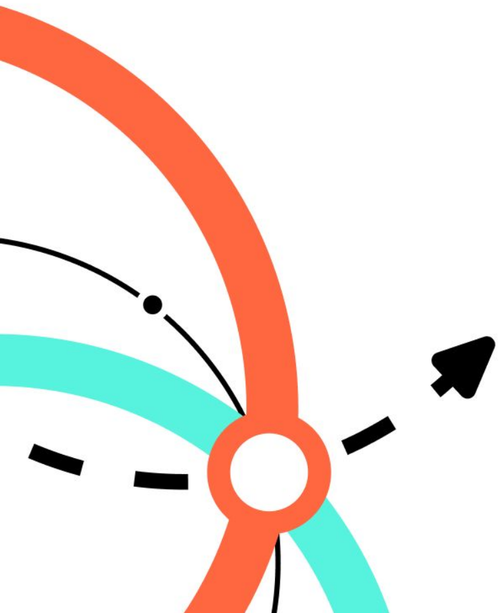

Развивать свой control plane

- Оставляем DRBD
- Go
- Kubernetes way «из коробки»
- Упрощение реализации сложных сценариев
- Нет зависимости от upstream

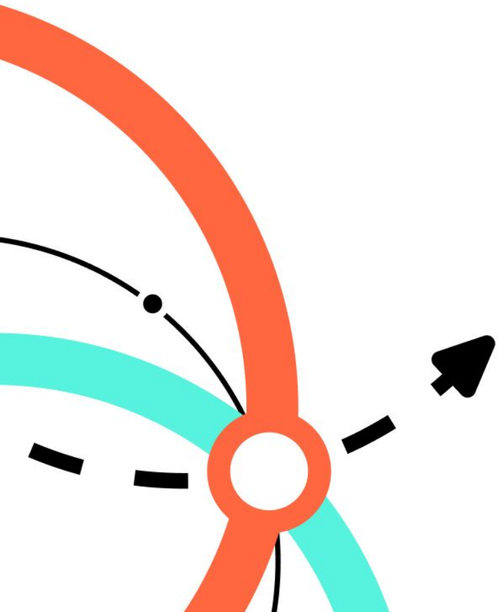

Что нужно сделать

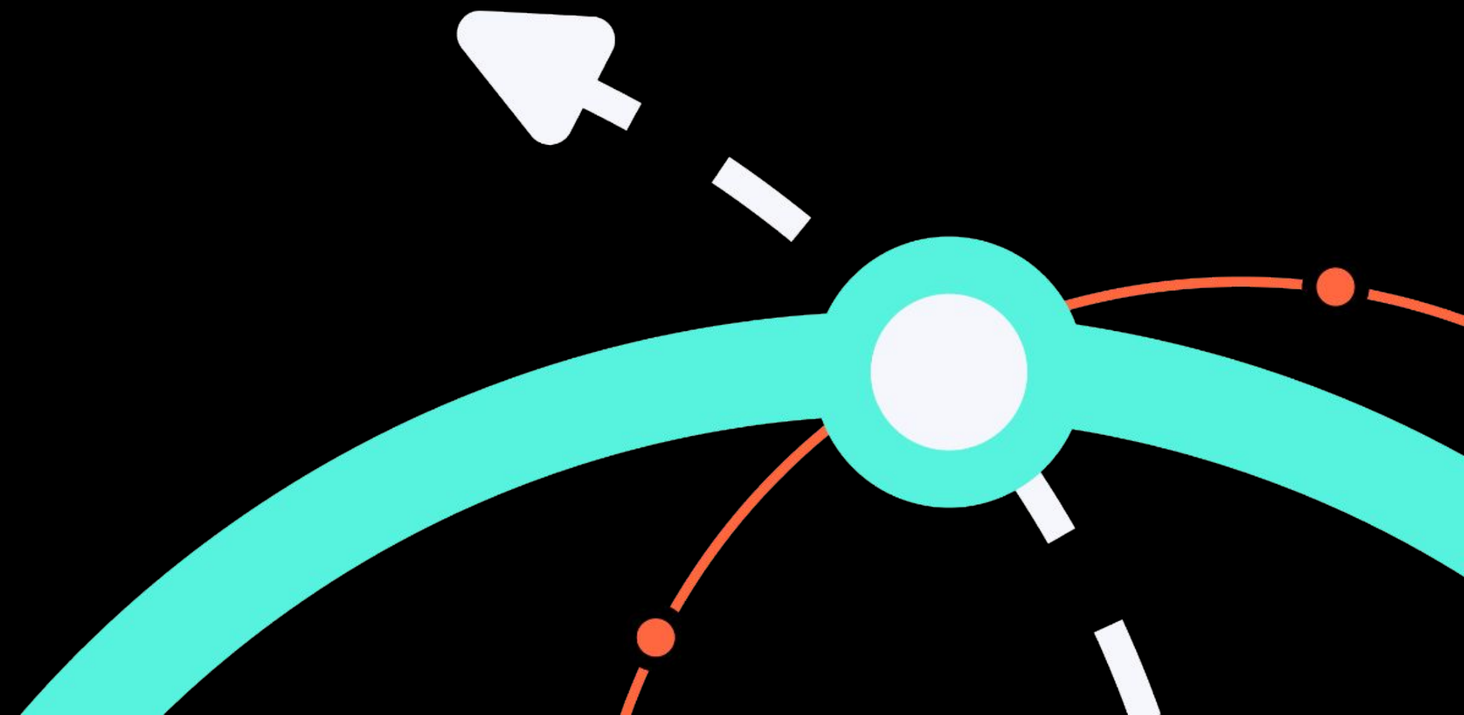

Контроллер и агент

Было

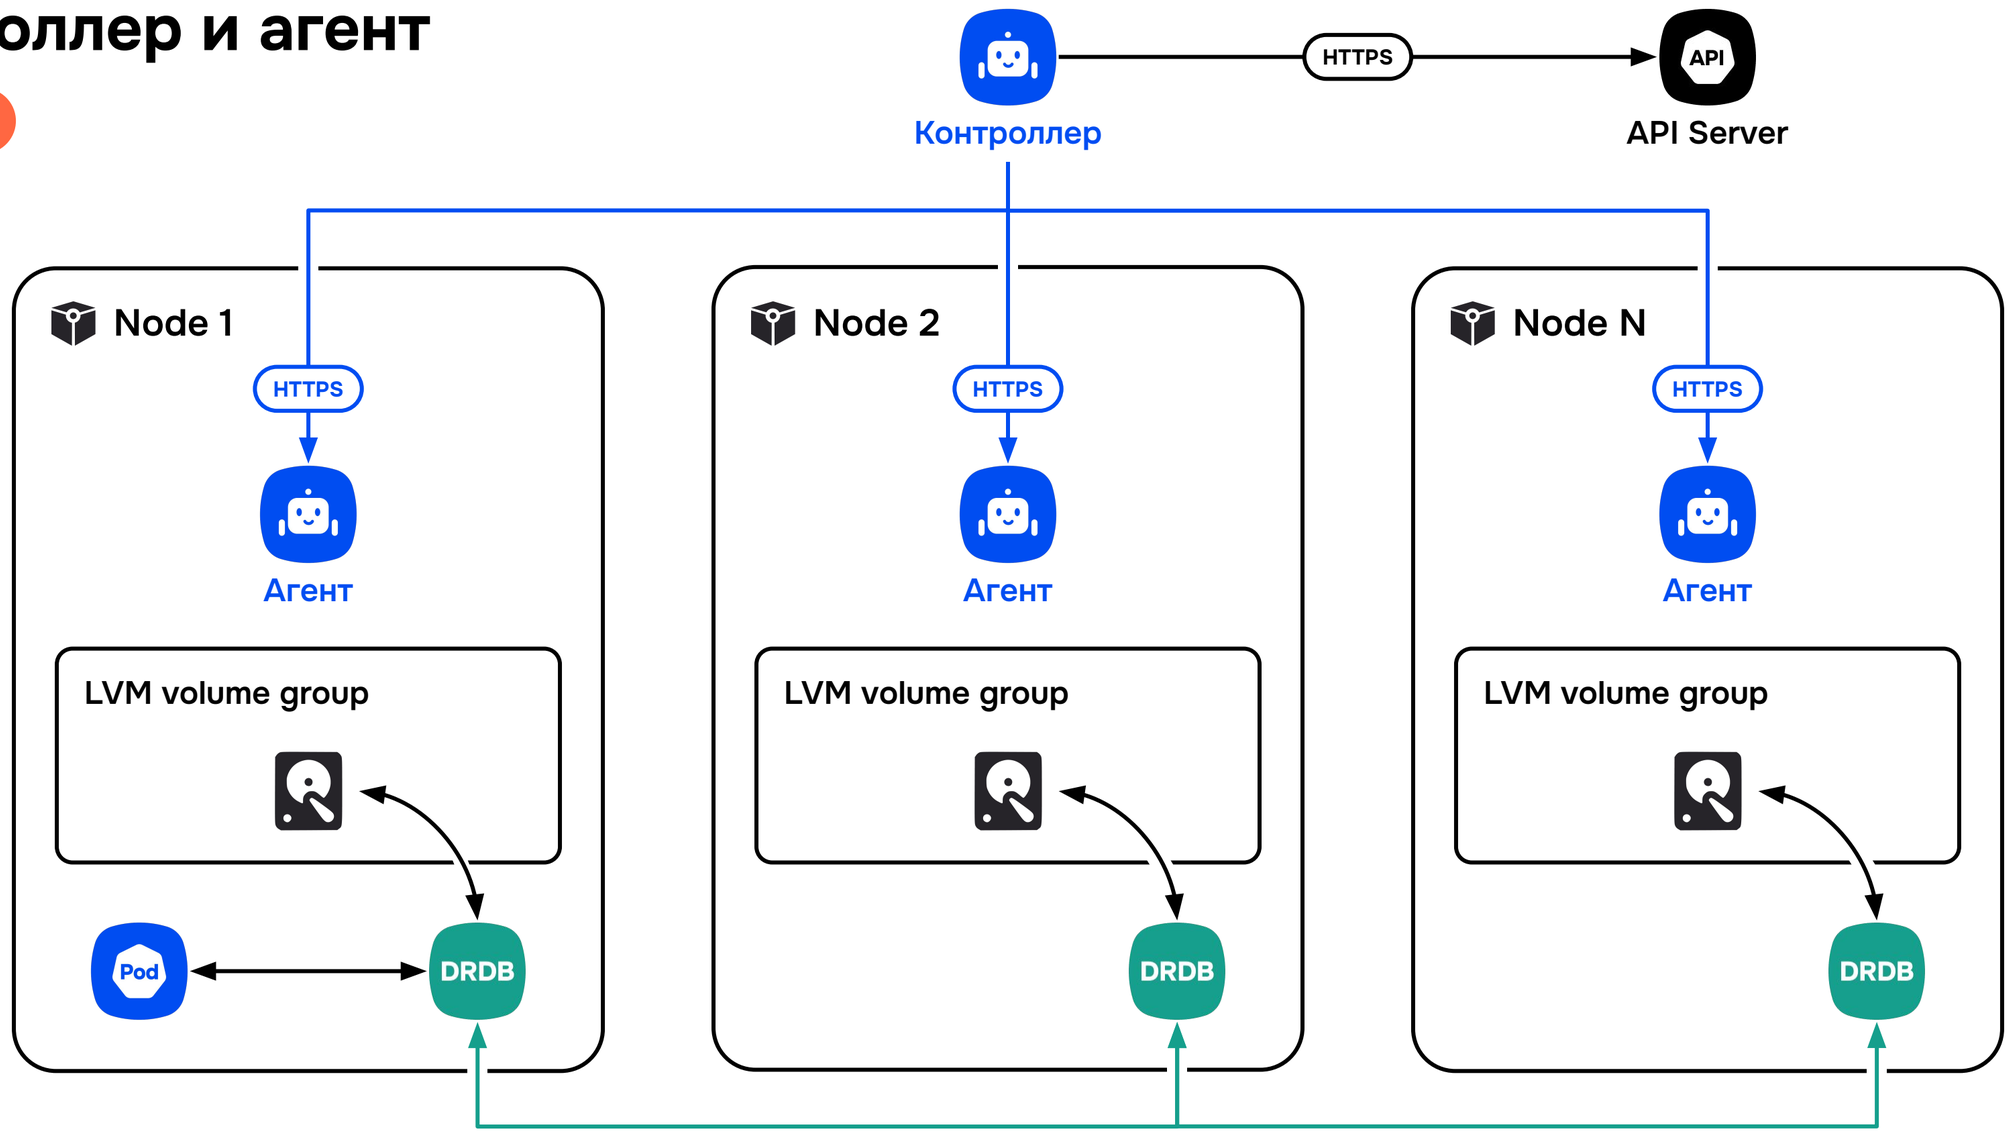

Контроллер и агент

Стало

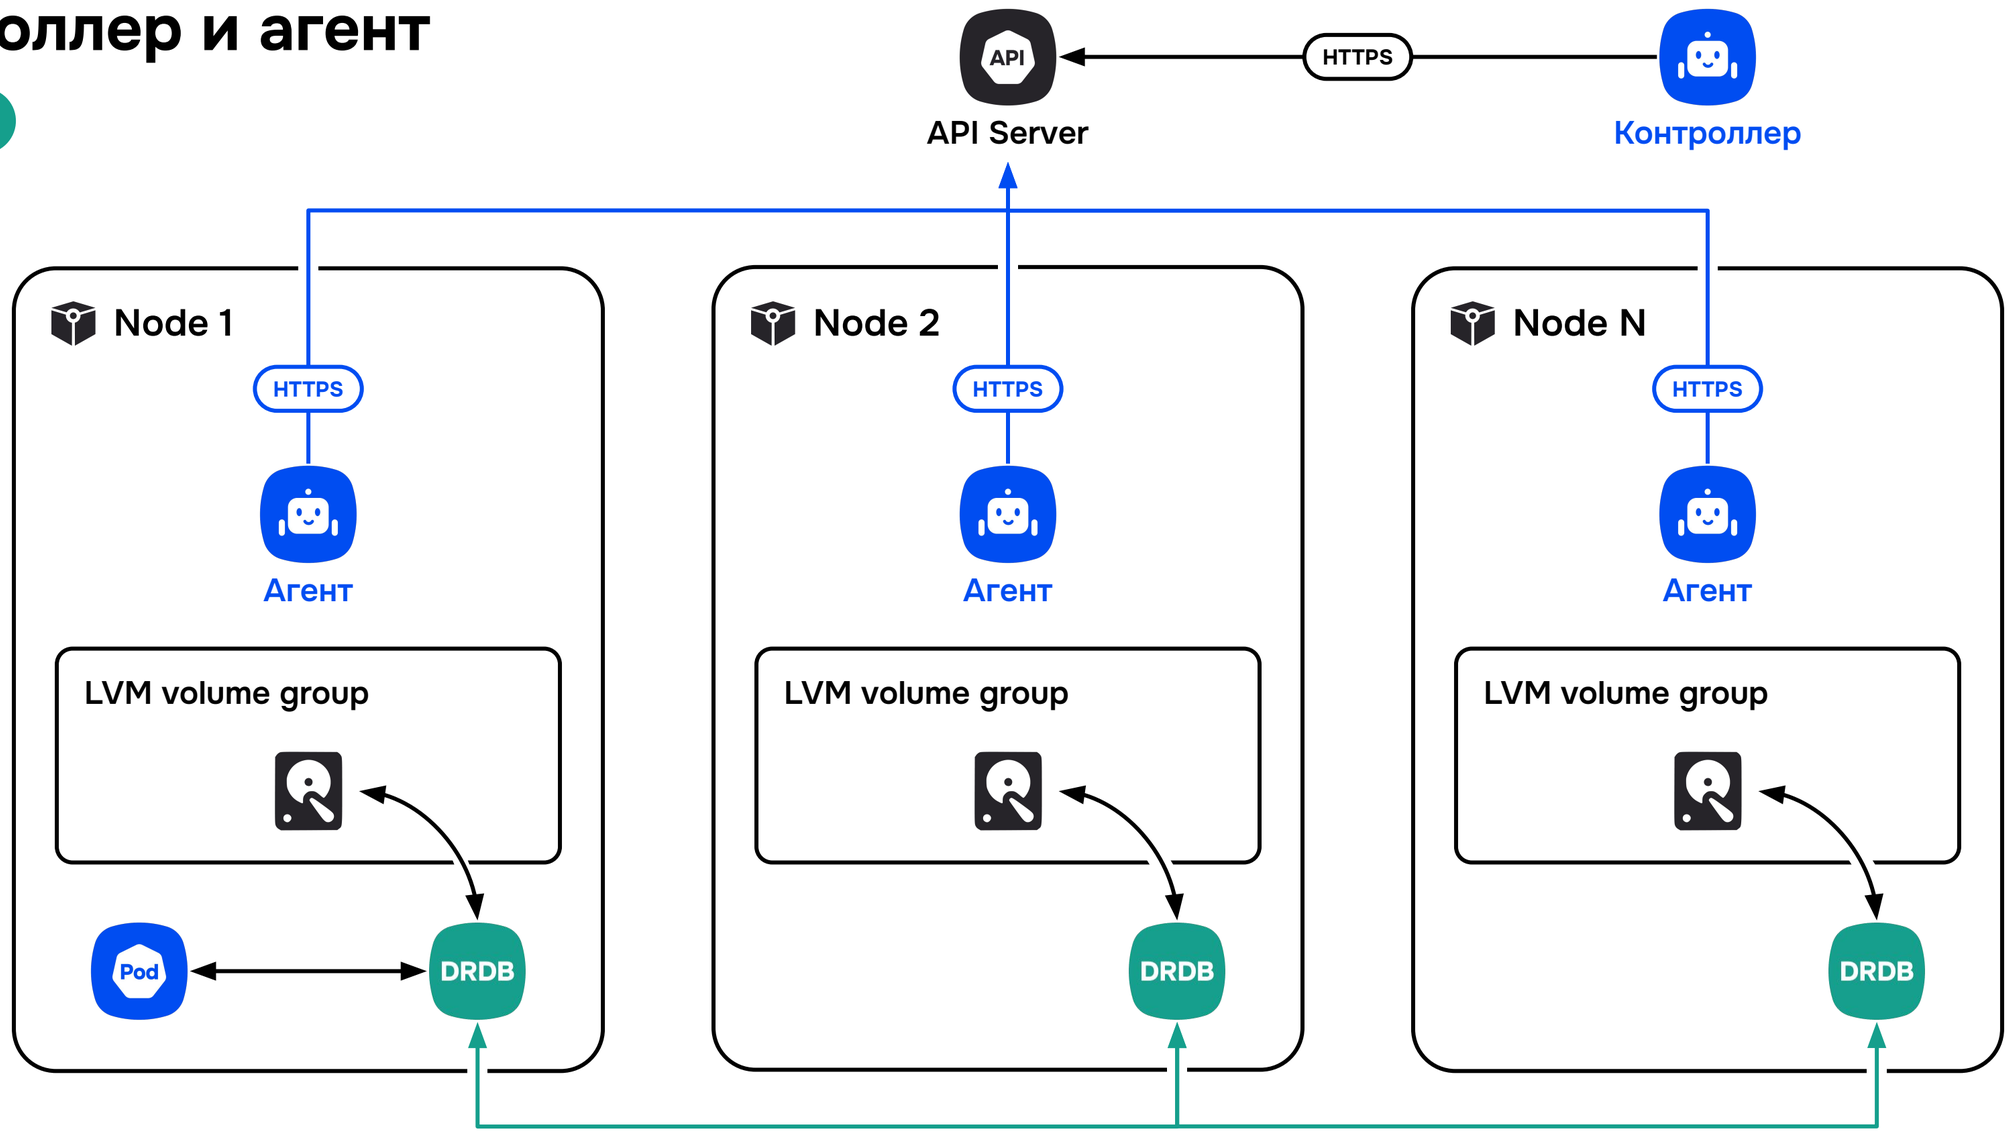

CSI

Было

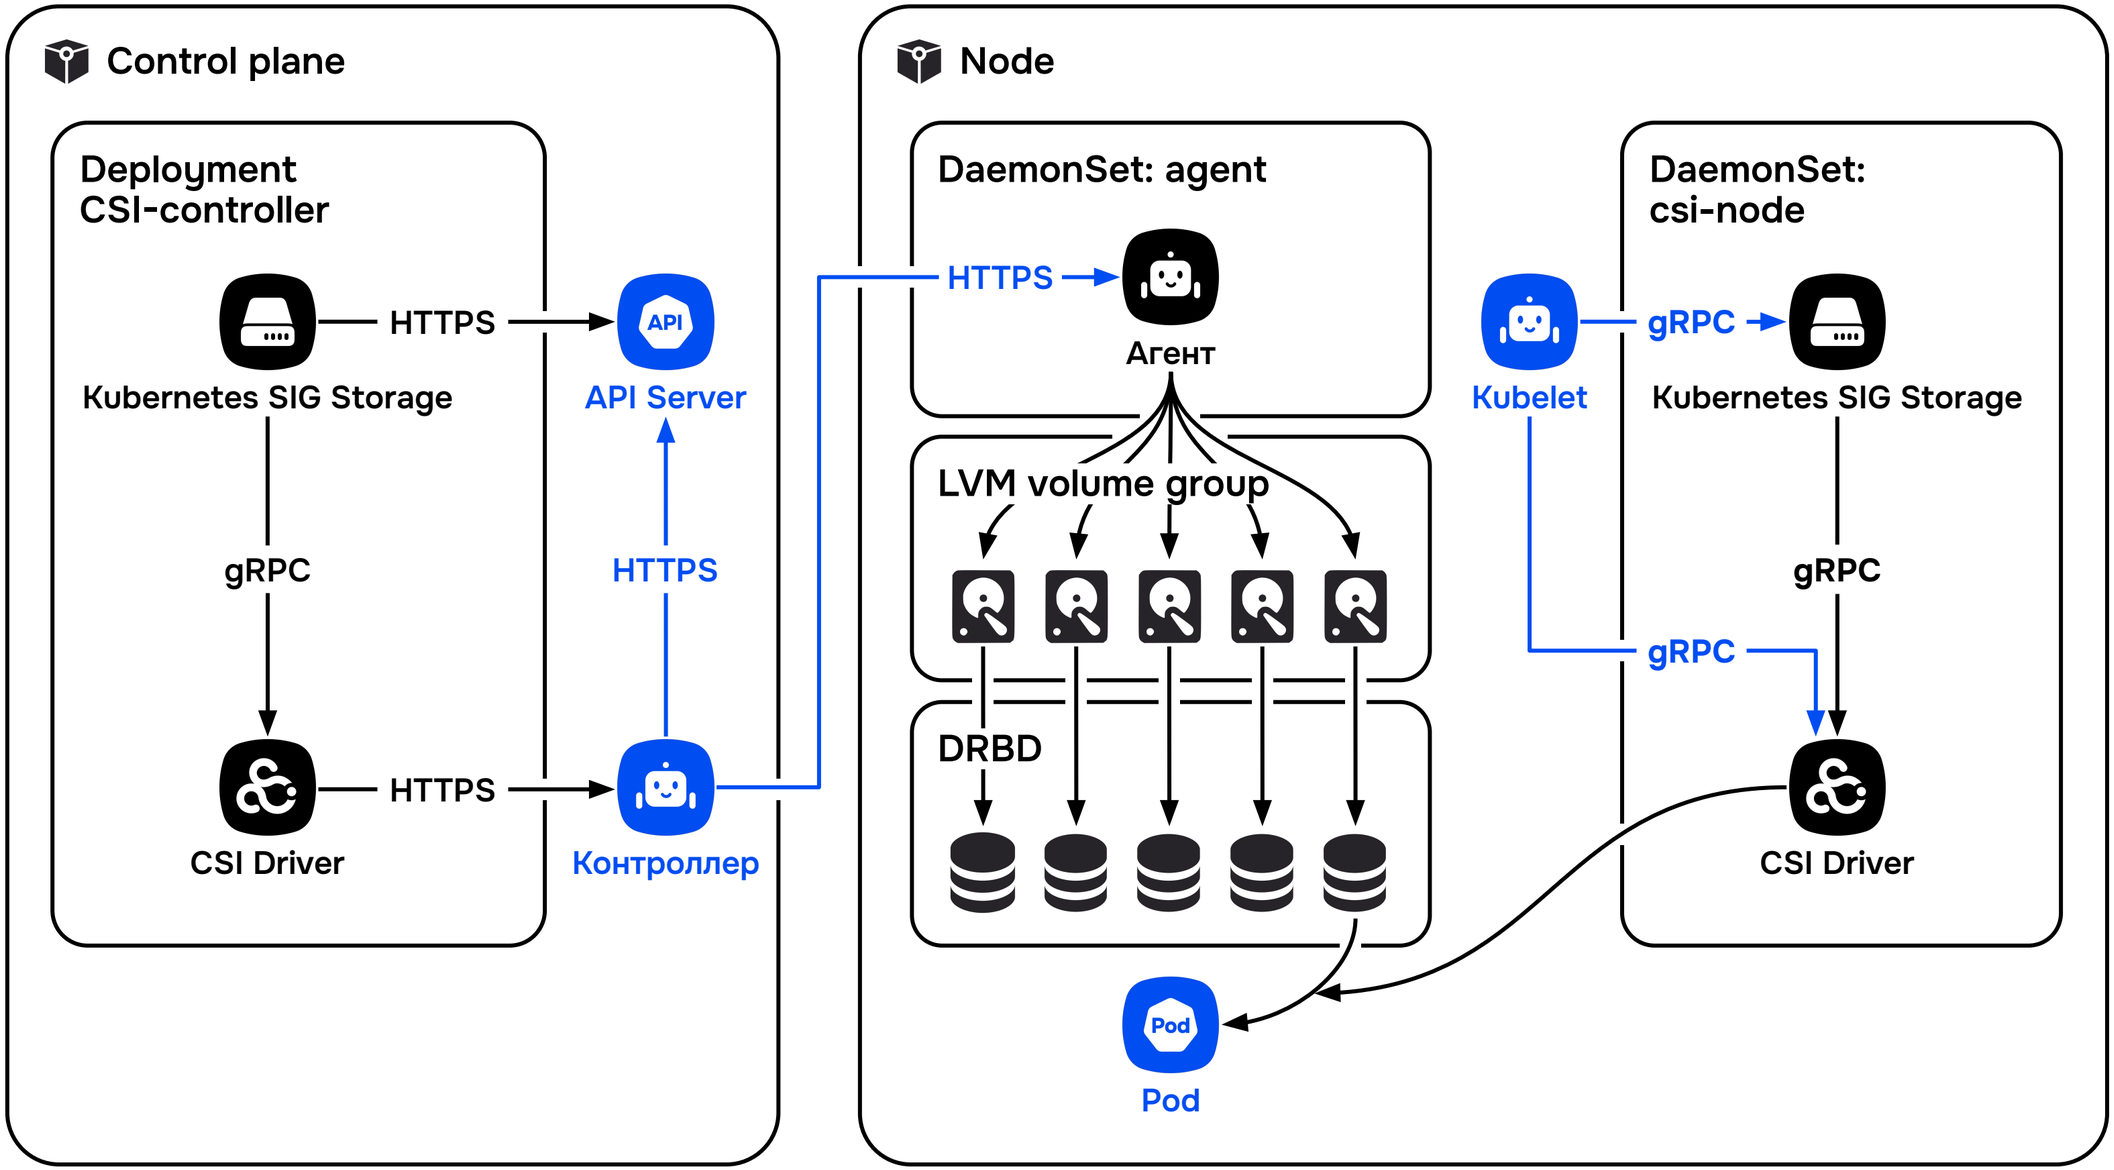
Control plane
Deployment
CSI-controller
HTTPS
Kubernetes SIG Storage
API
API Server
gRPC
HTTPS
HTTPS
CSI Driver
Контроллер
Node
DaemonSet: agent
HTTPS
Агент
LVM volume group
DRBD
Pod
Pod
Kubelet
gRPC
Kubernetes SIG Storage
DaemonSet:
csi-node
gRPC
gRPC
CSI Driver

CSI

Стало

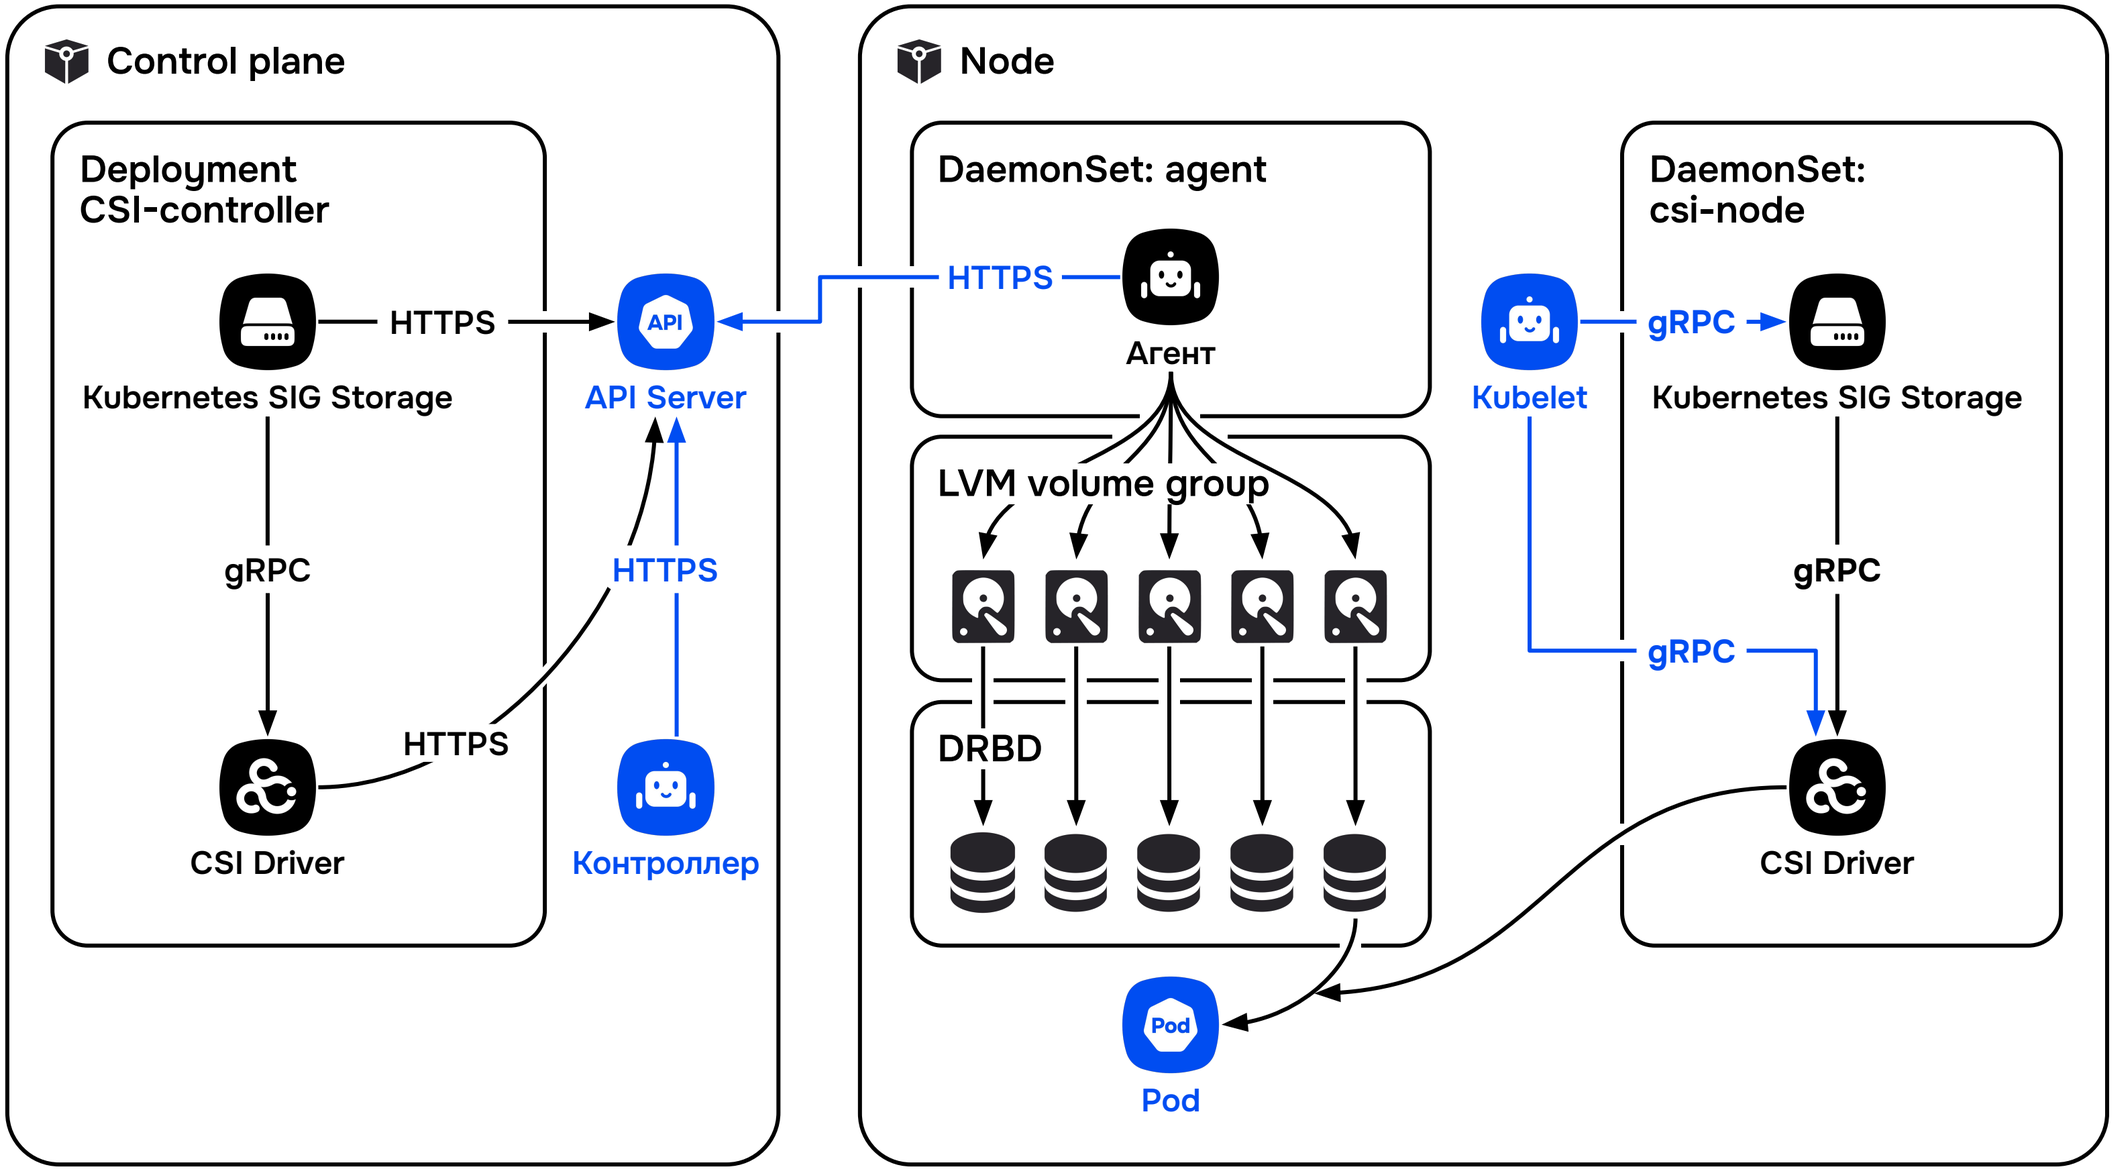
Control plane
Deployment
CSI-controller
HTTPS
Kubernetes SIG Storage
API
API Server
gRPC
HTTPS
HTTPS
CSI Driver
Контроллер
Node
DaemonSet: agent
HTTPS
Агент
LVM volume group
DRBD
Pod
Pod
Kubelet
gRPC
Kubernetes SIG Storage
DaemonSet:
csi-node
gRPC
gRPC
CSI Driver

Scheduler-extender

Было

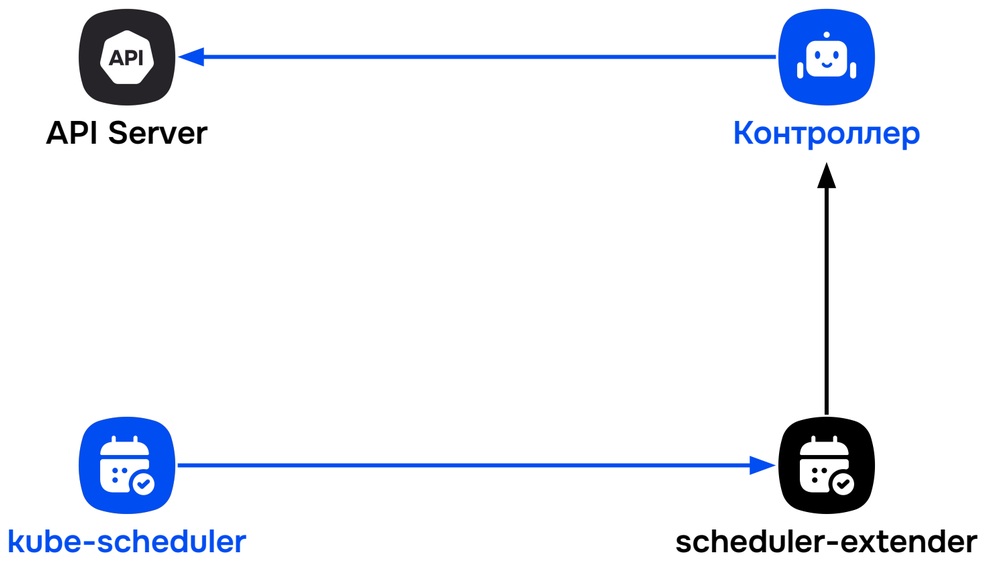

Scheduler-extender

Стало

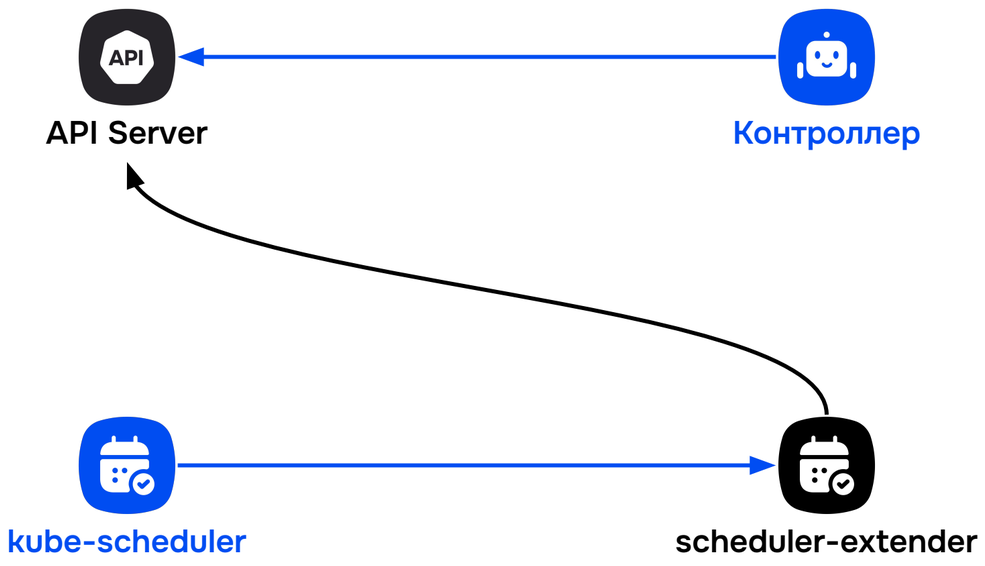

Прозрачная миграция с LINSTOR на наше решение

- Утилита-мигратор из БД LINSTOR в наши ресурсы

Прозрачная миграция с LINSTOR на наше решение

- Утилита-мигратор из БД LINSTOR в наши ресурсы
- Maintance-режим в нашем операторе

Прозрачная миграция с LINSTOR на наше решение

- Утилита-мигратор из БД LINSTOR в наши ресурсы
- Maintance-режим в нашем операторе
- Многошаговая автоматическая миграция

Архитектура

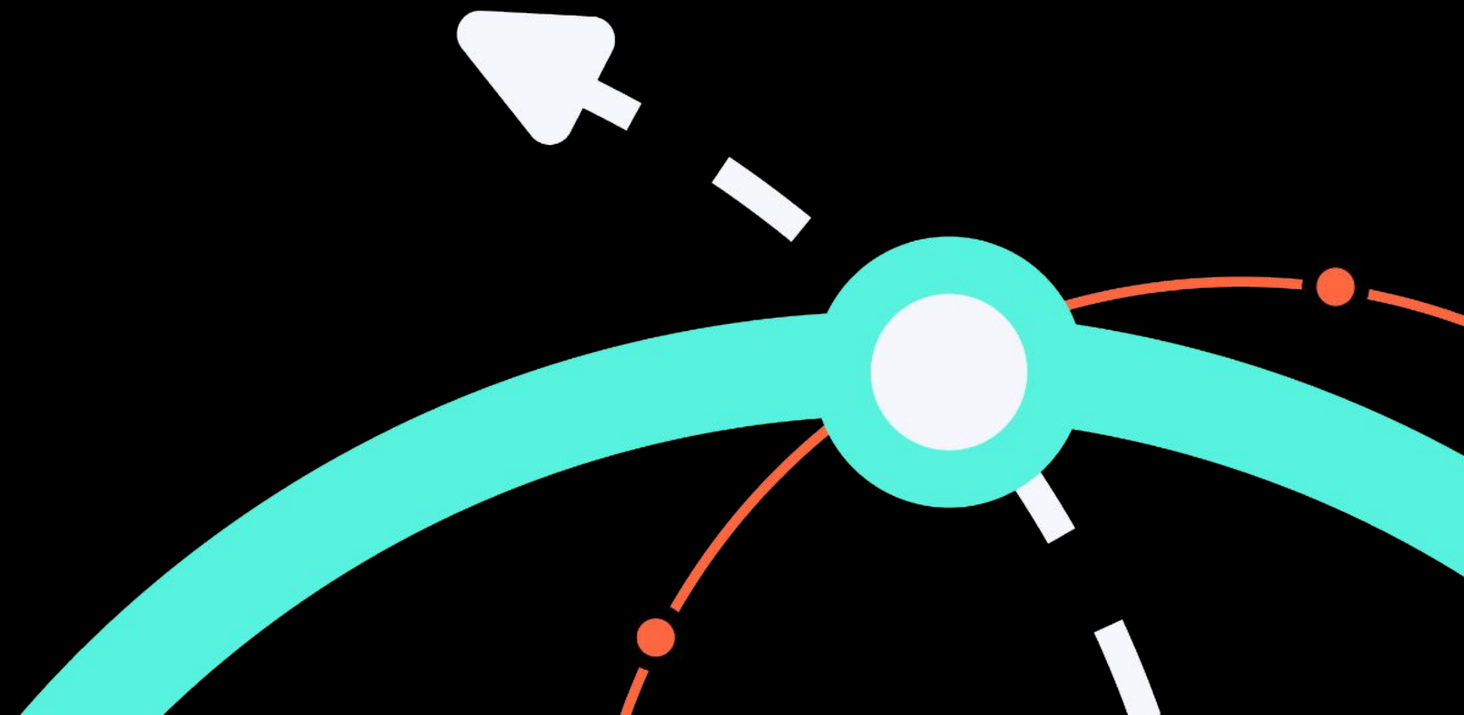

Kubernetes-оператор

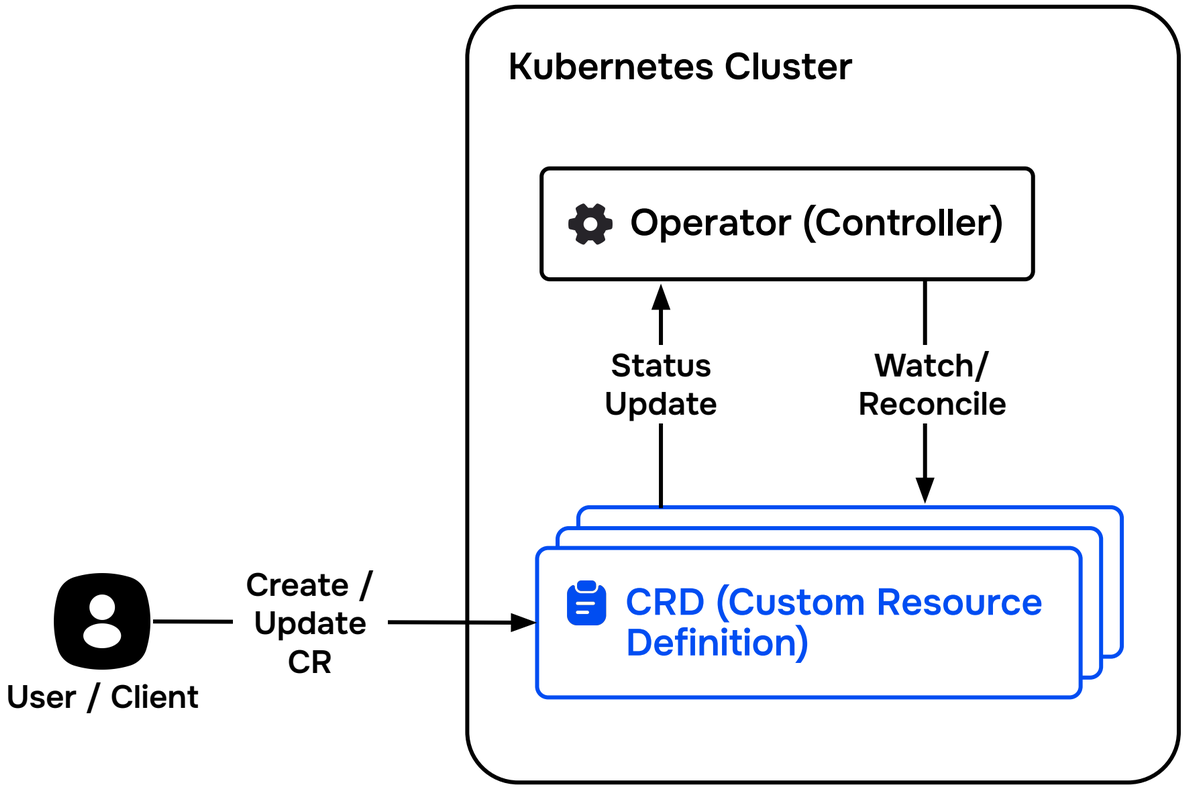

status/conditions как основной UX эксплуатации

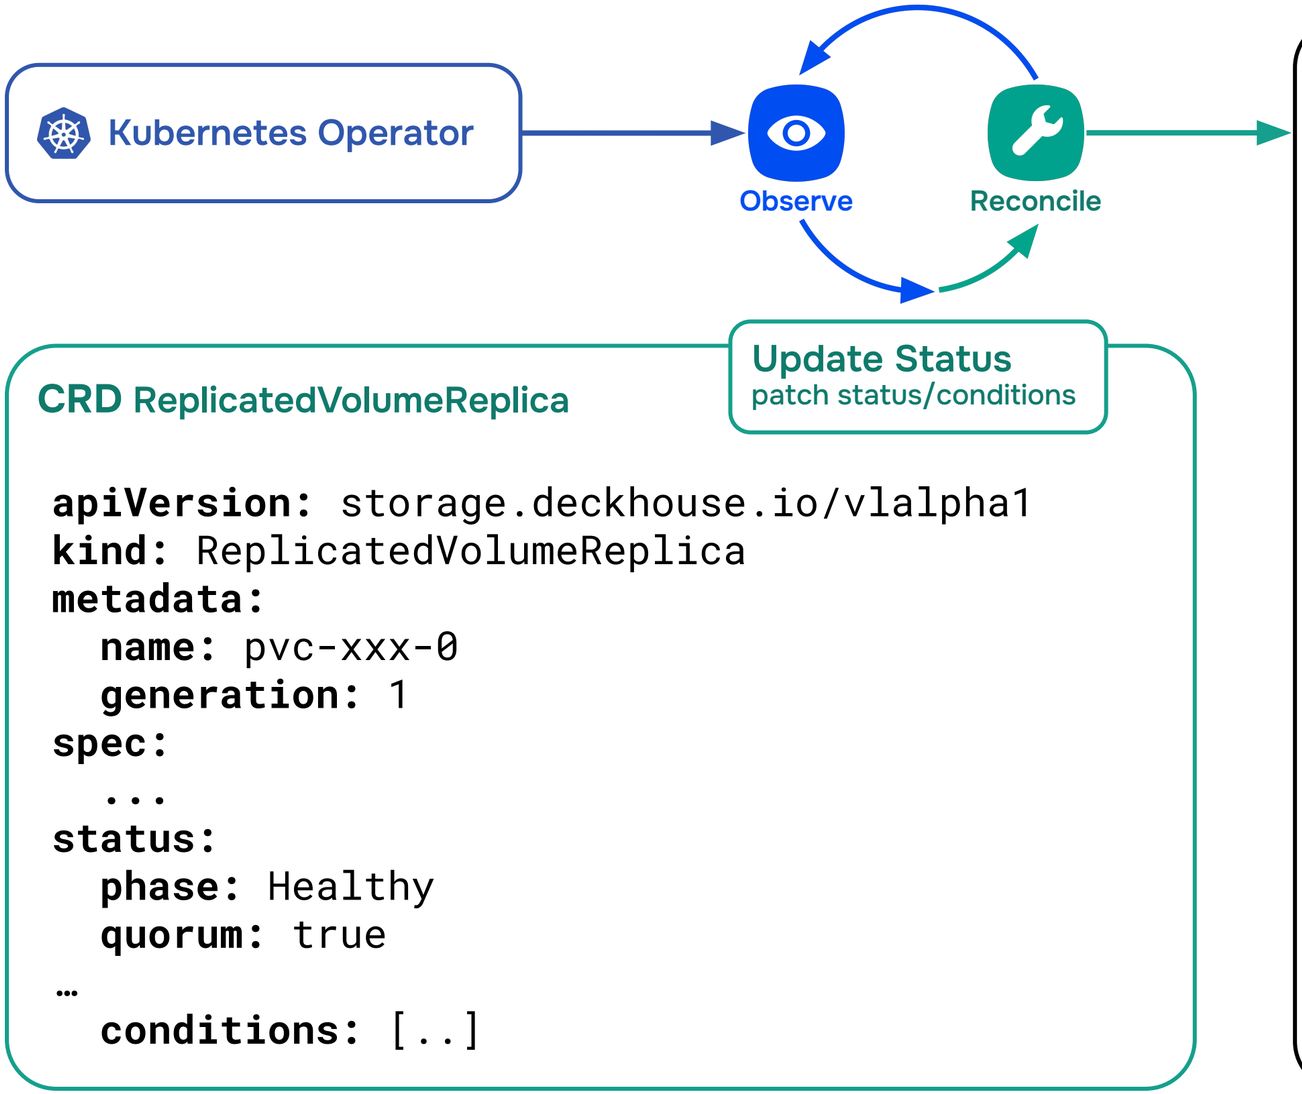

Type	Status	Reason	Last Transition	Massage
Scheduled	True	Scheduled	2026-03-22 18:52:54Z	Replica scheduled successfully
BackingVolume Ready	True	Ready	2026-03-22 18:52:54Z	Backing volume pvc-xxx-0-yyy is ready
DRDB Configured	True	Configured	2026-04-22 01:05:33Z	DRDB fully connected
Fully Connected	True	Fully Connected	2026-04-22 01:05:33Z	fully connected to all peers on all paths
Ready	True	Ready	2026-04-22 01:05:33Z	Quorum: diskful 3/2, data quorum: 3/2
SatisfyEligible Nodes	True	Satsfiedi	2026-03-22 18:52:54Z	Replica satisfies eligible nodes requirements
Configured	True	Configured	2026-03-22 02:08:00Z	Replica is configured as intended
BackingVolume UpToDate	True	UpToDate	2026-04-22 01:05:33Z	Backing volume is fully up-to-date

Оптимизации в hot path

- Строгие предикаты

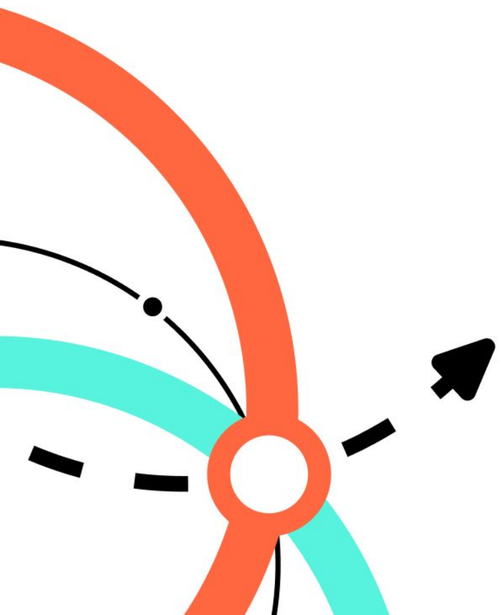

Оптимизации в hot path

- Строгие предикаты
- Использование индексов

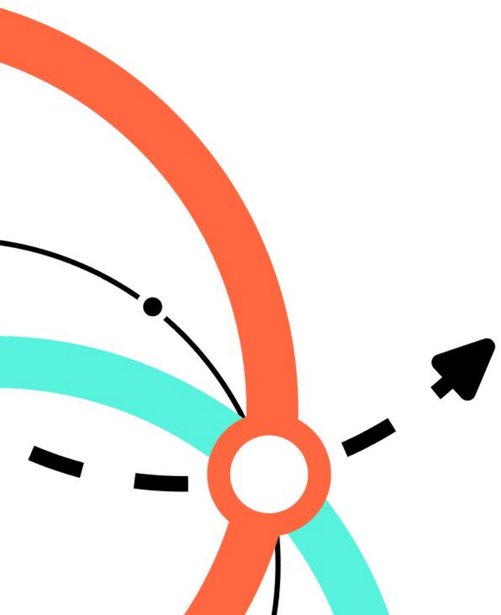

Оптимизации в hot path

- Строгие предикаты
- Использование индексов
- Ранний выход из reconcile

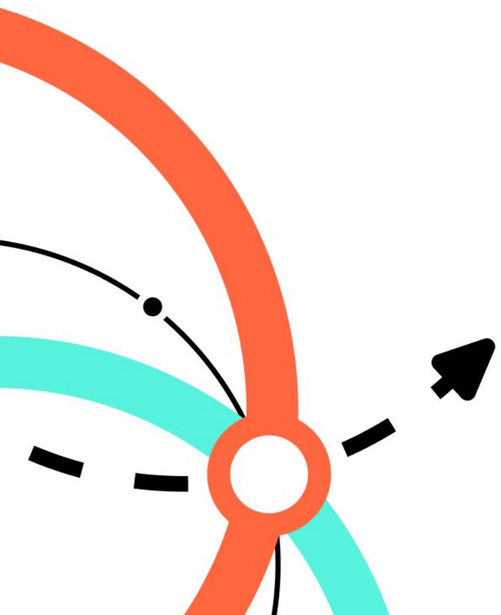

Оптимизации в hot path

- Строгие предикаты
- Использование индексов
- Ранний выход из reconcile
- Инкрементальный пересчёт состояния

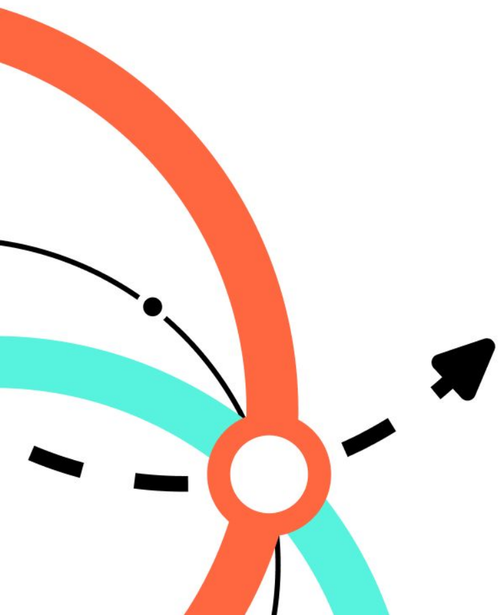

Оптимизации в hot path

- Строгие предикаты
- Использование индексов
- Ранний выход из reconcile
- Инкрементальный пересчёт состояния
- Тяжёлые действия только при реальном drift

Оптимизации в hot path

- Строгие предикаты
- Использование индексов
- Ранний выход из reconcile
- Инкрементальный пересчёт состояния
- Тяжёлые действия только при реальном drift
- Минимум лишних patch в API

Надёжные переходы между состояниями

- План перехода хранится в самом объекте
- Каждый шаг подтверждается всеми репликами
- Конфликты не перетирают состояние
- Переходы детерминированы и идемпотентны
- Конфликтующие операции нельзя запустить одновременно

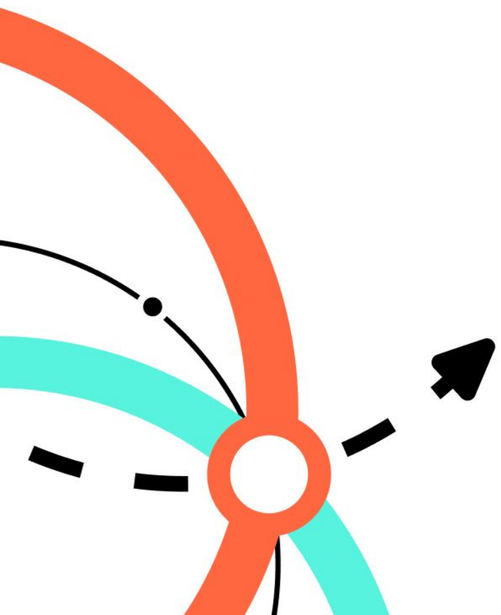

Проблемы при разработке

- Документация по DRBD не везде актуальна

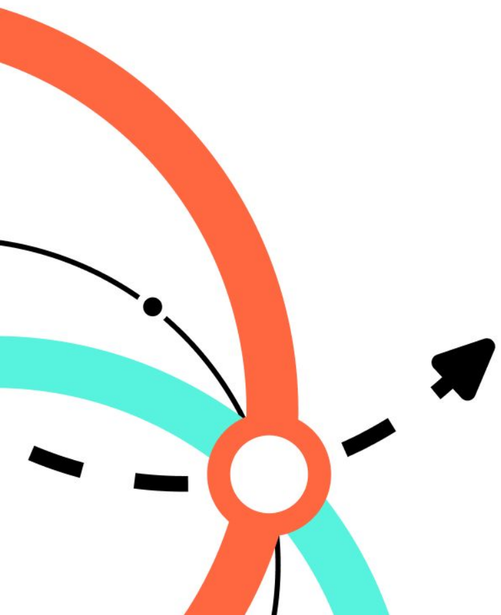

Проблемы при разработке

- Документация по DRBD не везде актуальна
- Экспертиза в C (26 патчей в DRBD)

Проблемы при разработке

- Документация по DRBD не везде актуальна
- Экспертиза в C (26 патчей в DRBD)
- Сильное погружение в предметную область для Go-разработчиков

Уже в проде

- 627 виртуалок
- 1414 томов
- 4876 реплик
- Несколько секунд на создание тома
- Меньше секунды на аттач/детач

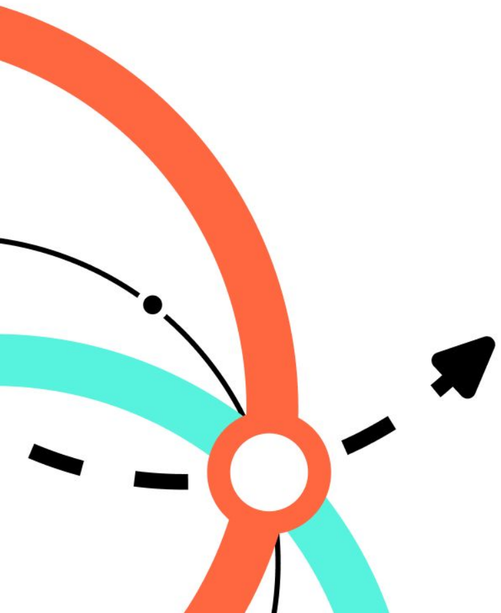

Новые фичи

1. Обновление модуля DRBD наживую (без необходимости остановки нагрузки)

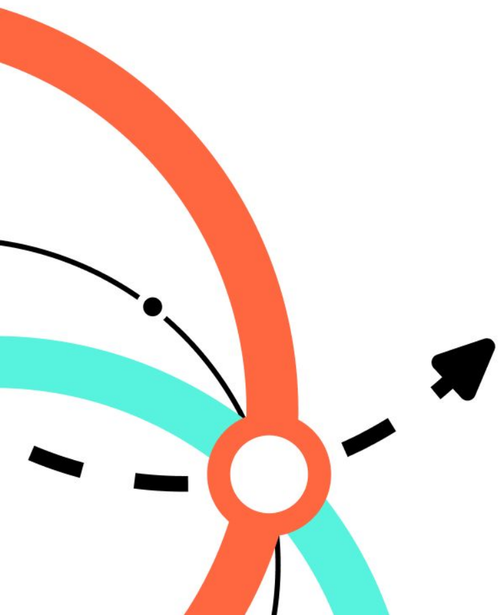

Новые фичи

1. Обновление модуля DRBD наживую (без необходимости остановки нагрузки)

2. Автоматическое поддержание реплик в заданном количестве

Новые фичи

1. Обновление модуля DRBD наживую (без необходимости остановки нагрузки)
2. Автоматическое поддержание реплик в заданном количестве
3. Автоматическая переконфигурация ресурсов при изменении StorageClass

Новые фичи

1. Обновление модуля DRBD наживую (без необходимости остановки нагрузки)
2. Автоматическое поддержание реплик в заданном количестве
3. Автоматическая переконфигурация ресурсов при изменении StorageClass
4. Готовность к сертификации ФСТЭК

Планы на дальнейшее развитие

- Дешедулинг
- Учет IOPS и пропускной способности сети
- Выделенная сеть репликации
- ГОСТ TLS

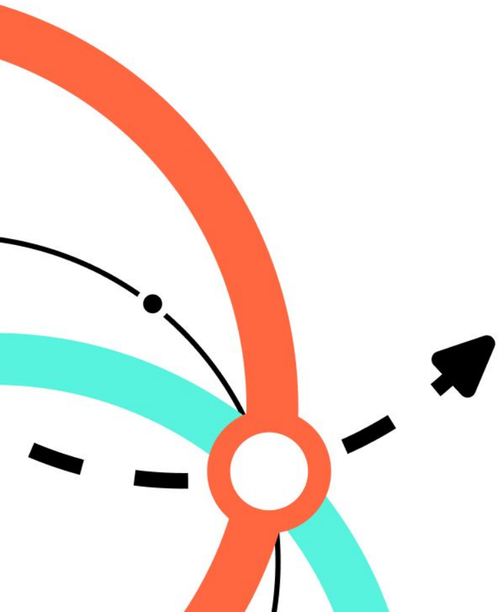

Где грань?

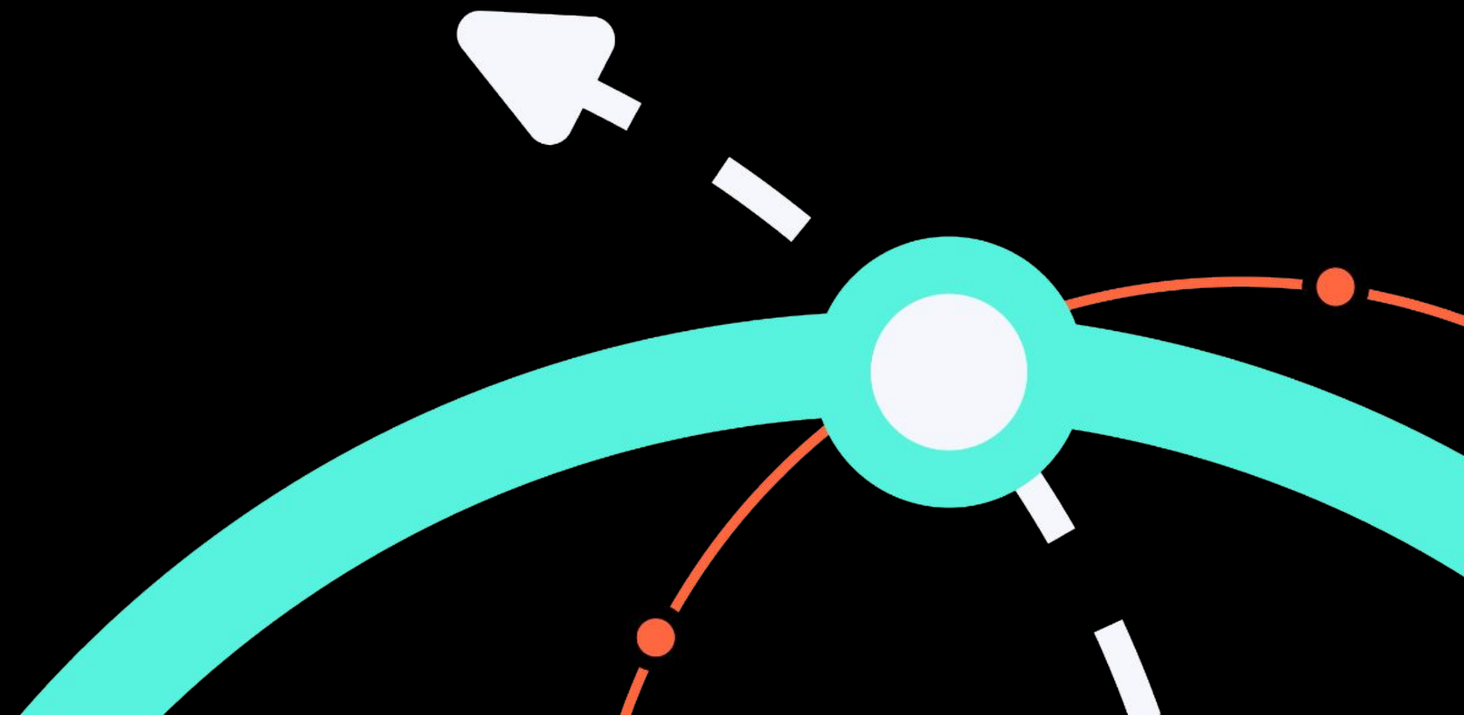

DK 26

Технологии

Оцените доклад

Александра Зимина

@deckhouse_news

github.com/deckhouse