

Deckhouse AI/ML 2026: от управления GPU к AI-платформе

● Александр Подмосковный

Менеджер продукта
по направлению ML/AI

Одна логика, три продуктовые линии

Наша цель — стать самой
надёжной дорогой к on-prem AI

Одна логика, три продуктовые линии

Наша цель — стать самой
надёжной дорогой к on-prem AI

Слой 1. Инфраструктура

Предсказуемость и утилизация дорогих ресурсов

Одна логика, три продуктовые линии

Наша цель — стать самой
надёжной дорогой к on-prem AI

Слой 1. Инфраструктура

Предсказуемость и утилизация дорогих ресурсов

Слой 2. Сервисы платформы

Скорость запуска и единый стандарт эксплуатации

Одна логика, три продуктовые линии

Наша цель — стать самой
надёжной дорогой к on-prem AI

Слой 1. Инфраструктура

Предсказуемость и утилизация дорогих ресурсов

Слой 2. Сервисы платформы

Скорость запуска и единый стандарт эксплуатации

Слой 3. Прикладные AI-решения

Быстрые сценарии, за которые
бизнес готов платить уже сейчас


Ключевой принцип

Мы не просто собираем Open Source.

Мы строим продукт.

Где готовые компоненты хороши — используем их.

Где они не дотягивают по качеству, управляемости или требованиям enterprise — делаем своё



Что есть в основании

Что есть в основании

Уже сегодня в DKP

Автоматическое включение NVIDIA GPU
на узлах, готовый эксплуатационный
контур, интеграция с мониторингом

Что есть в основании

Уже сегодня в DKP

Автоматическое включение NVIDIA GPU на узлах, готовый эксплуатационный контур, интеграция с мониторингом

Режимы шеринга

Exclusive, TimeSlicing и MIG на уровне NodeGroup — уже штатная часть платформы

Что есть в основании

Уже сегодня в DKP

Автоматическое включение NVIDIA GPU на узлах, готовый эксплуатационный контур, интеграция с мониторингом

Режимы шеринга

Exclusive, TimeSlicing и MIG на уровне NodeGroup — уже штатная часть платформы

Q1 уже закрывает базу

MIG «по карточкам» и TimeSlicing — это фундамент, с которым можно входить в 2026 год

Суровая реальность – GPU в прод-кластере

Суровая реальность – GPU в прод-кластере

Коммунальный H100-кластер

8 узлов × 8 H100 = 64 GPU

 8xGPU

 8xGPU

 8xGPU

 8xGPU

 8xGPU

 8xGPU

 8xGPU


 8xGPU

Prod inference

Суровая реальность – GPU в прод-кластере

Коммунальный H100-кластер


8 узлов × 8 H100 = 64 GPU



Суровая реальность – GPU в прод-кластере

Коммунальный H100-кластер

8 узлов × 8 H100 = 64 GPU



Именно такая картина
быстрее всего упирается
в модель «GPU как счётчик»

Как сделать так, чтобы GPU
не просто был «виден», а управлялся
как ресурс платформы?



здРАвый смысл: GPU как ресурс платформы

DRA (Dynamic Resource Allocations) –
нужен не вместо GPU-модуля, а как
следующий уровень, чтобы выделение
устройств стало предсказуемым
и управляемым по единому контракту

здРАвый смысл: GPU как ресурс платформы

DRA (Dynamic Resource Allocations) —
нужен не вместо GPU-модуля, а как
следующий уровень, чтобы выделение
устройств стало предсказуемым
и управляемым по единому контракту

Точные заявки

Не «дай N GPU», а «дай подходящее
устройство или партицию по политике»

ЗДРАВЫЙ СМЫСЛ: GPU как ресурс платформы

DRA (Dynamic Resource Allocations) —
нужен не вместо GPU-модуля, а как
следующий уровень, чтобы выделение
устройств стало предсказуемым
и управляемым по единому контракту

Точные заявки

Не «дай N GPU», а «дай подходящее
устройство или партицию по политике»

Шаринг по правилам

Механизмы DRA дают реальную модель
shared GPU, а не набор побочных механизмов

ЗДРАВЫЙ СМЫСЛ: GPU как ресурс платформы

DRA (Dynamic Resource Allocations) —
нужен не вместо GPU-модуля, а как
следующий уровень, чтобы выделение
устройств стало предсказуемым
и управляемым по единому контракту

Точные заявки

Не «дай N GPU», а «дай подходящее
устройство или партицию по политике»

Шаринг по правилам

Механизмы DRA дают реальную модель
shared GPU, а не набор побочных механизмов

Путь к топологии

DRA открывает дорогу к NVLink / RDMA /
scheduler-extender без ручных привязок
и специальных пулов под каждый случай

зDRAвый смысл: GPU как ресурс платформы

K8s 1.35

DRA уже stable. Подробности
механики — в серии технических
статей про DRA и GPU



Технический разбор DRA —
в серии статей «DRAMатургия
GPU в Kubernetes»

Roadmap 2026: три линии усиливают друг друга

Q1

Q2

Q3

Q4

Roadmap 2026: три линии усиливают друг друга

	Q1	Q2	Q3	Q4
Инфраструктура	MIG «по карточкам» + time-slicing	DRA: динамическая аллокация и шаринг	NVLink/RDMA топология + scheduler/QoS + AMD/Intel	Multi-node NVLink + автодрайверы + vGPU

Roadmap 2026: три линии усиливают друг друга

	Q1	Q2	Q3	Q4
Инфраструктура	MIG «по карточкам» + time-slicing	DRA: динамическая аллокация и шаринг	NVLink/RDMA топология + scheduler/QoS + AMD/Intel	Multi-node NVLink + автодрайверы + vGPU
Сервисы платформы	Проектирование сервиса и стандартизация API	vLLM/Ollama (первый релиз), Реестр моделей	API-шлюз, Распределенный инференс	Airflow, JupyterHub, MLFlow Quality и security сценарии

Roadmap 2026: три линии усиливают друг друга

	Q1	Q2	Q3	Q4
Инфраструктура	MIG «по карточкам» + time-slicing	DRA: динамическая аллокация и шаринг	NVLink/RDMA топология + scheduler/QoS + AMD/Intel	Multi-node NVLink + автодрайверы + vGPU
Сервисы платформы	Проектирование сервиса и стандартизация API	vLLM/Ollama (первый релиз), Реестр моделей	API-шлюз, Распределенный инференс	Airflow, JupyterHub, MLFlow Quality и security сценарии
Прикладные AI-решения	Концепция и UX (политики, аудит)	Оркестрация агентных сценариев (первый релиз)	RAG, чат-боты	CV/STT/TTS и коннекторы

Что вы получите

Что вы получите

Предсказуемое выделение GPU

Запрашиваем профиль или класс –
получаем нужную карту/партицию
по политике, без ручного подбора узлов

Что вы получите

Предсказуемое выделение GPU

Запрашиваем профиль или класс –
получаем нужную карту/партицию
по политике, без ручного подбора узлов

Больше задач на тех же GPU

Шаринг, квоты и showback/chargeback
уменьшают простой и дают больше
полезной нагрузки на том же парке

Что вы получите

Предсказуемое выделение GPU

Запрашиваем профиль или класс —
получаем нужную карту/партицию
по политике, без ручного подбора узлов

Безопасный инференс в своём контуре

Единый API, лимиты, auth,
audit, SLO по latency/throughput
и понятный путь из PoC в production

Больше задач на тех же GPU

Шаринг, квоты и showback/chargeback
уменьшают простой и дают больше
полезной нагрузки на том же парке

Что вы получите

Предсказуемое выделение GPU

Запрашиваем профиль или класс —
получаем нужную карту/партицию
по политике, без ручного подбора узлов

Безопасный инференс в своём контуре

Единый API, лимиты, auth,
audit, SLO по latency/throughput
и понятный путь из PoC в production

Больше задач на тех же GPU

Шаринг, квоты и showback/chargeback
уменьшают простой и дают больше
полезной нагрузки на том же парке

Агентные сценарии без хаоса

n8n, RAG, чат-боты и multimodal-сервисы
под теми же правилами: политики,
аудит, обновления

Единый стандарт эксплуатации



Доступ



Метрики/SLO



Аудит




Обновления




Экономика

Как продолжить 2026 вместе с нами



Как продолжить 2026 вместе с нами

Не внедрять всё сразу,
а идти через понятные пилоты




Как продолжить 2026 вместе с нами

Не внедрять всё сразу,
а идти через понятные пилоты


1. Пилот по GPU и DRA

Если у вас уже есть коммунальный GPU-кластер –
начнём с самого болезненного: профили, шаринг,
миграция и правила эксплуатации без остановки
production-контура



Как продолжить 2026 вместе с нами

Не внедрять всё сразу,
а идти через понятные пилоты



1. Пилот по GPU и DRA


Если у вас уже есть коммунальный GPU-кластер — начнём с самого болезненного: профили, шаринг, миграция и правила эксплуатации без остановки production-контура

2. Проектирование сервиса инференса

Если вам нужен on-prem inference-контур — обсудим API, лимиты, метрики, безопасность, стоимость и реестр моделей

Как продолжить 2026 вместе с нами

Не внедрять всё сразу,
а идти через понятные пилоты



1. Пилот по GPU и DRA

Если у вас уже есть коммунальный GPU-кластер — начнём с самого болезненного: профили, шаринг, миграция и правила эксплуатации без остановки production-контура

2. Проектирование сервиса инференса

Если вам нужен on-prem inference-контур — обсудим API, лимиты, метрики, безопасность, стоимость и реестр моделей

3. Прикладные AI-сценарии

Если у вас «болят» внутренние ассистенты, RAG, low-code или multimodal — ищем сценарии, где платформа быстрее всего даёт бизнес-эффект

Коротко о главном

- В основе — предсказуемое управление GPU
- На этой базе — inference и MLOps как сервис
- Поверх — прикладные AI-сценарии для бизнеса



Статья на Habr DRA

Спасибо за внимание!

📍 @PodmoskovniyAlex

📍 @deckhouse_news

🐙 github.com/deckhouse