DUC meetup/4

Опыт внедрения и эксплуатации DKP CE:

можно ли в одного DevOps крутить кластеры Kubernetes?

DUC meetup/4

Вячеслав Дружинин

Ведущий системный администратор
КЛ ГРУПП

SALE 70%
до 70%

План доклада

- Предыстория и задача проекта
- С чего всё начиналось, первый деплой
- Нужен **Kubernetes**, выбор дистрибутива
- Что получили от K8s и от DKP CE
- Выводы

Предыстория

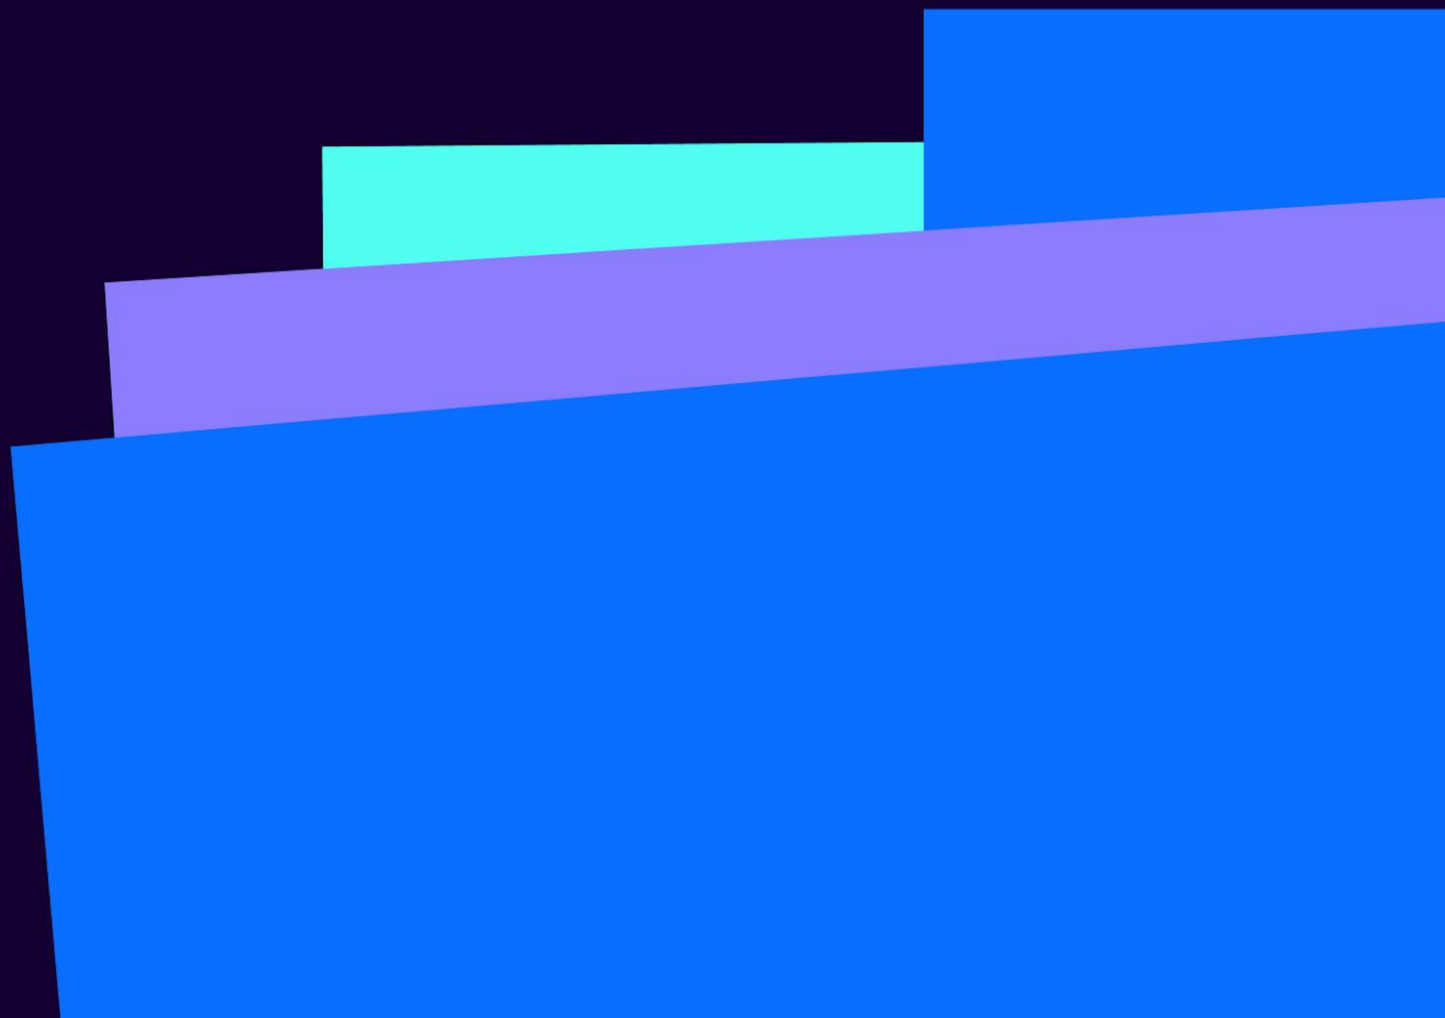

DUC meetup/4

Проблема бизнеса

К 2022 году сайт на Bitrix CMS перестал удовлетворять требованиям бизнеса, существующая интеграция с ERP, WMS и платформой 1С работала медленно, приводила к ошибкам при обмене данными.

- ERP — система на базе Oracle DB
- Склад — своя WMS на базе Oracle DB
- Платформа 1С на базе Oracle DB
- Интернет-магазин tjcollection.ru на базе MySQL

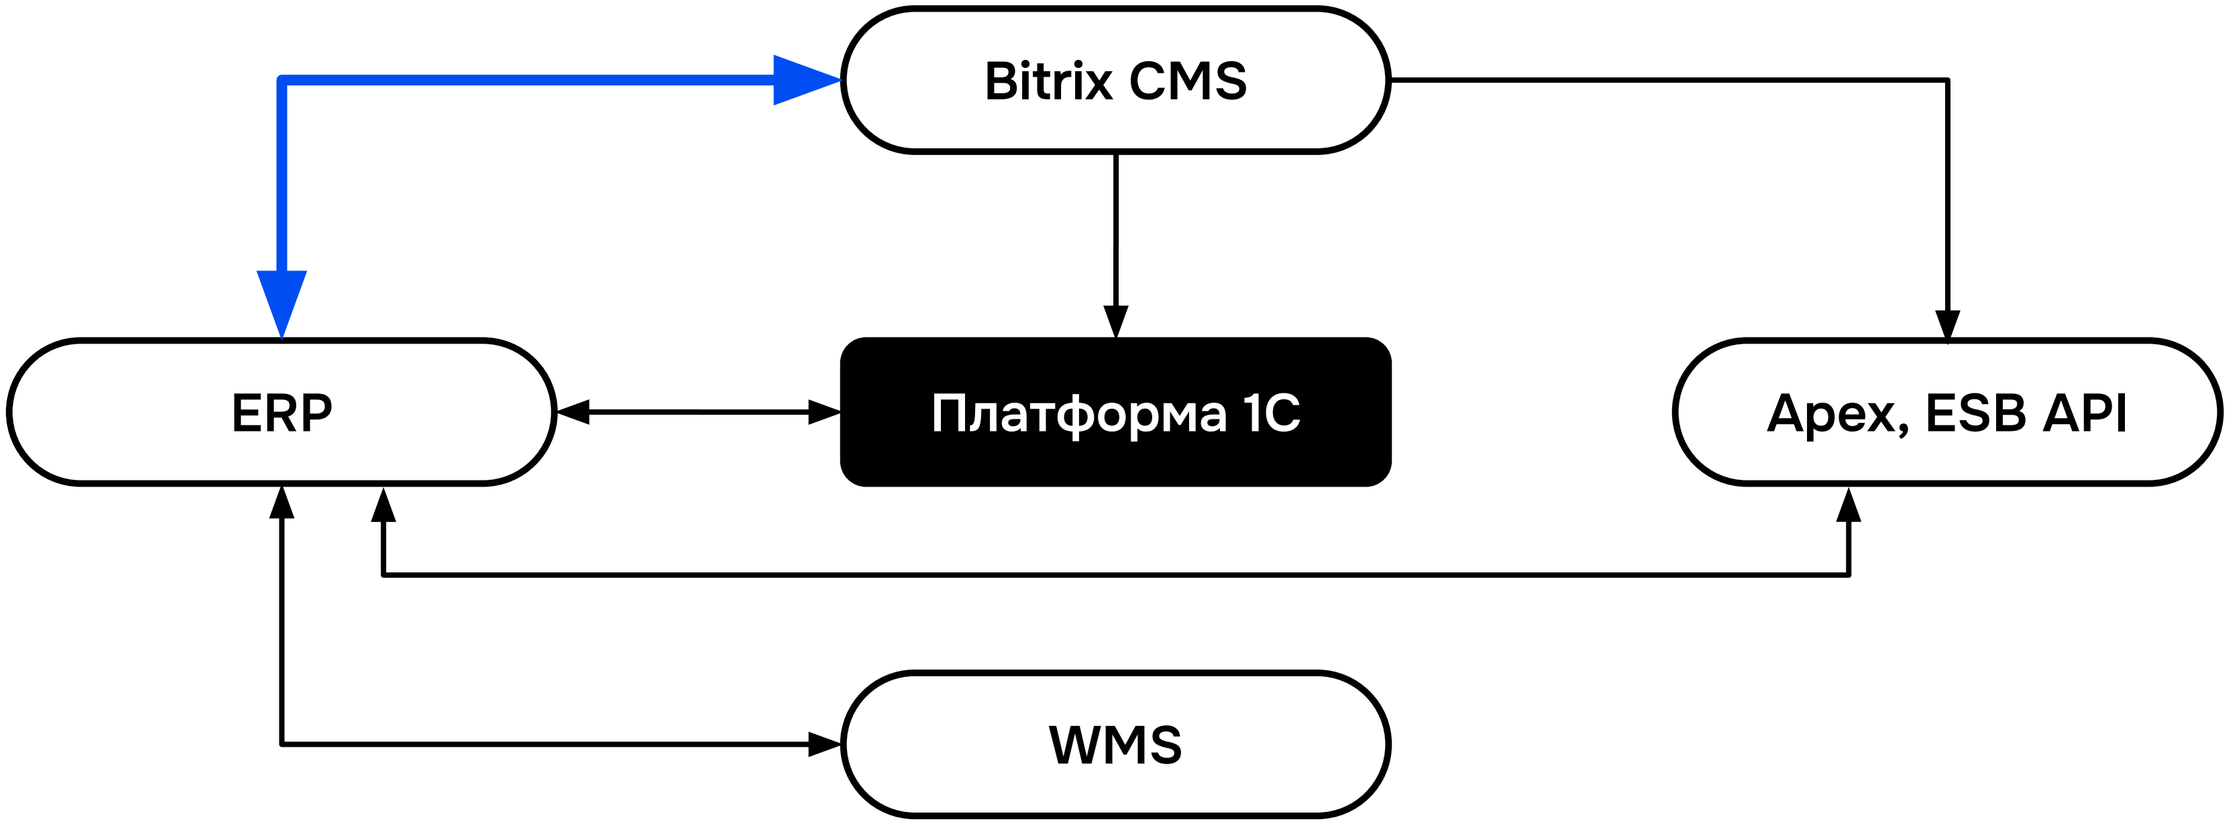
Bitrix CMS
ERP
Платформа 1С
Apex, ESB API
WMS

Задача проекта

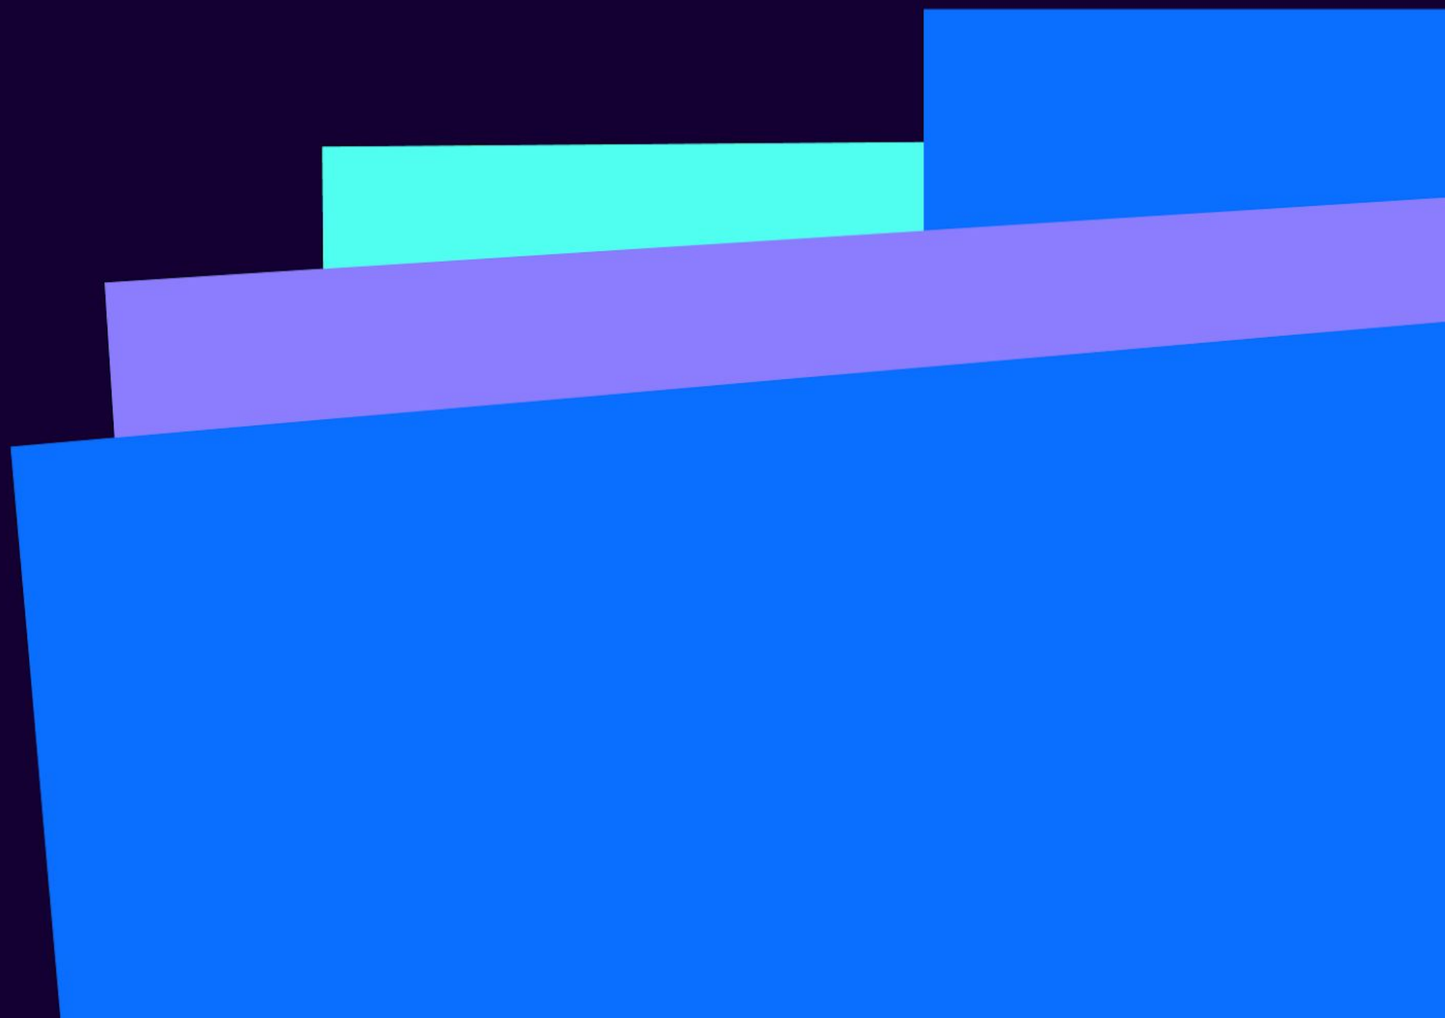

DUC meetup/4

Новый сайт

Переписать сайт, сделать новую интеграцию с ERP, WMS, Oracle DB, обеспечить надёжный, предсказуемый, стабильный Ops с гладким прохождением пиков заказов

- **Ограничения** — бюджет, Open Source, сроки
- **Ключевые сложности** — отсутствие опыта у команды
- **Личная мотивация** — внедрение практик DevOps в команде

С чего всё начиналось

DUC meetup/4

Начало

Разрабатываем архитектуру, выбираем стек,
используемые технологии, обсуждаем DevOps-практики

- **Технологический стек** — FastAPI, Nuxt SSR, Oracle DB
- Код — в GitLab, приложения — в контейнеры

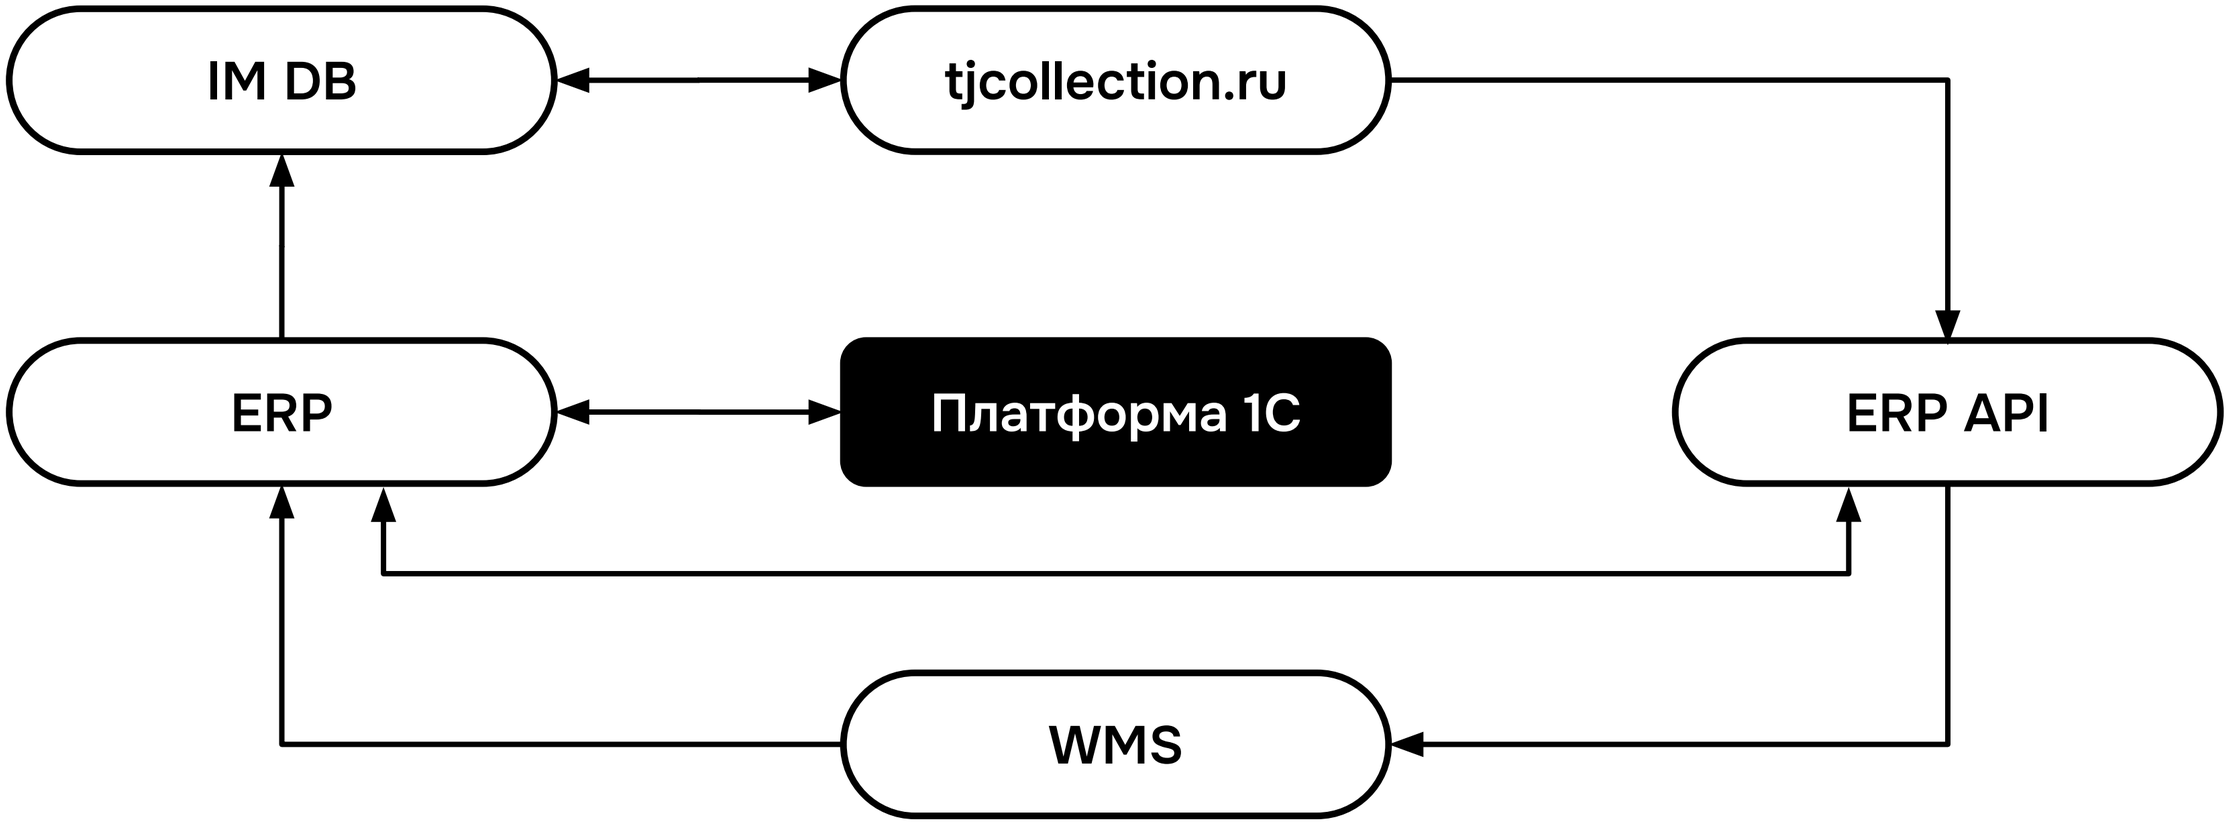
IM DB
tjcollection.ru
ERP
Платформа 1С
ERP API
WMS

Первый деплой

DUC meetup/4

Куда деплоиться?

Для PoC решили ничего не изобретать,
пробуем самые простые и быстрые решения

- GitLab CI/CD
- Сборка Docker build, Kaniko
- Деплой через Docker compose

Docker compose хорошо для local dev,
плохо для dev-окружения, нужны reverse proxy,
сертификаты, мониторинг, алерты, логи

Какие варианты?

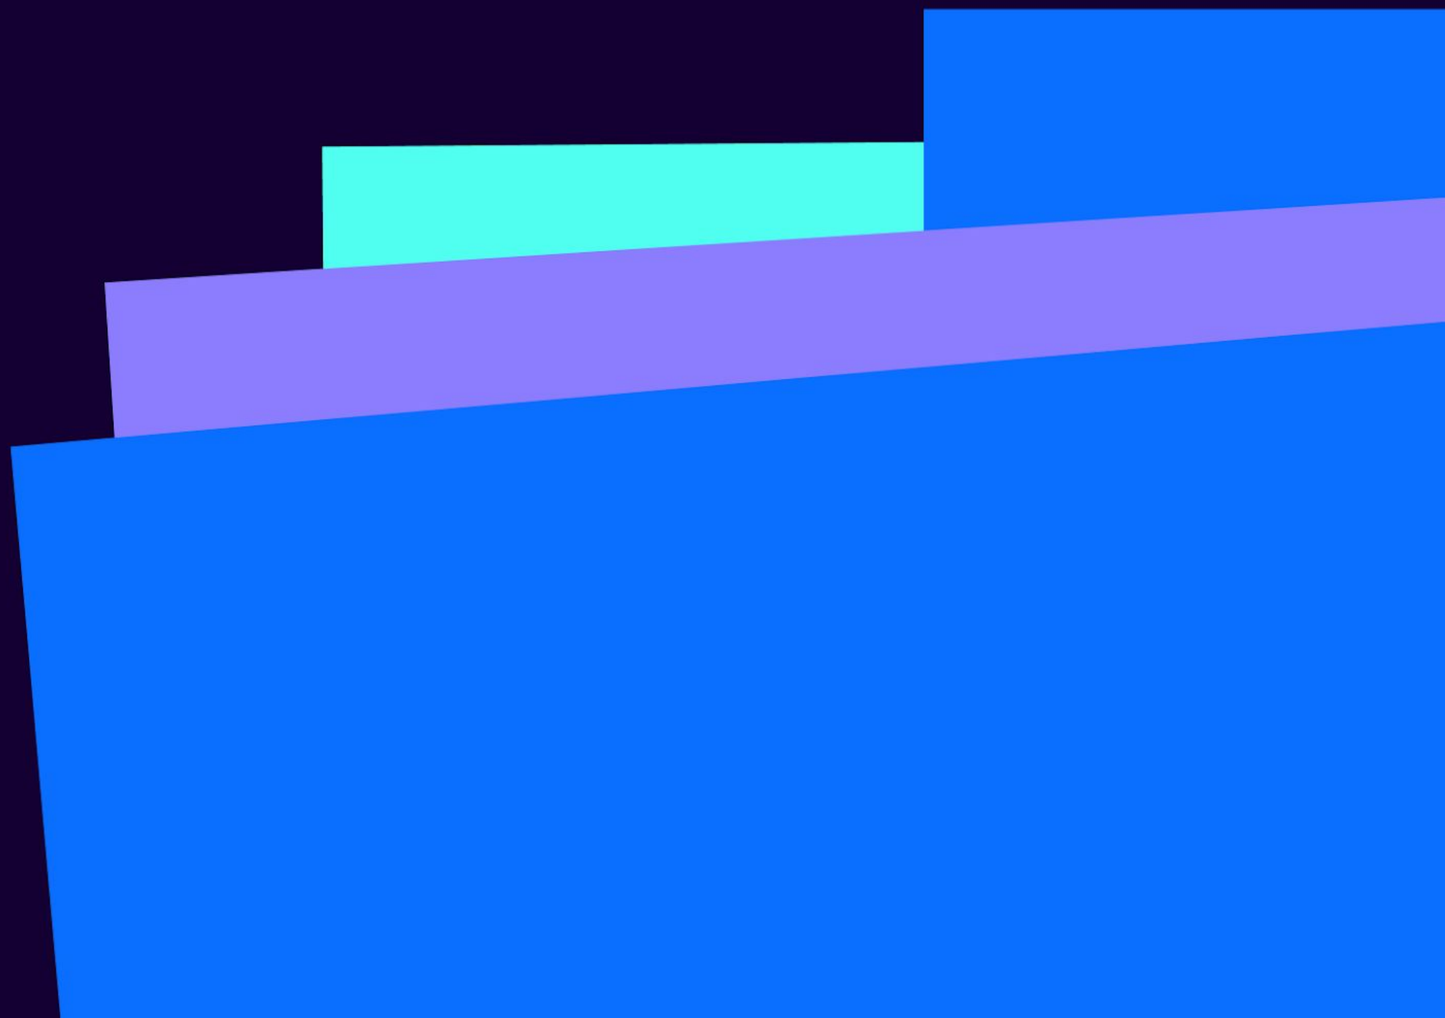

DUC meetup/4

Оркестраторы

Если Docker compose не подходит, значит, нужен оркестратор.
Какие есть варианты, из чего выбирать?

DOCKER SWARM

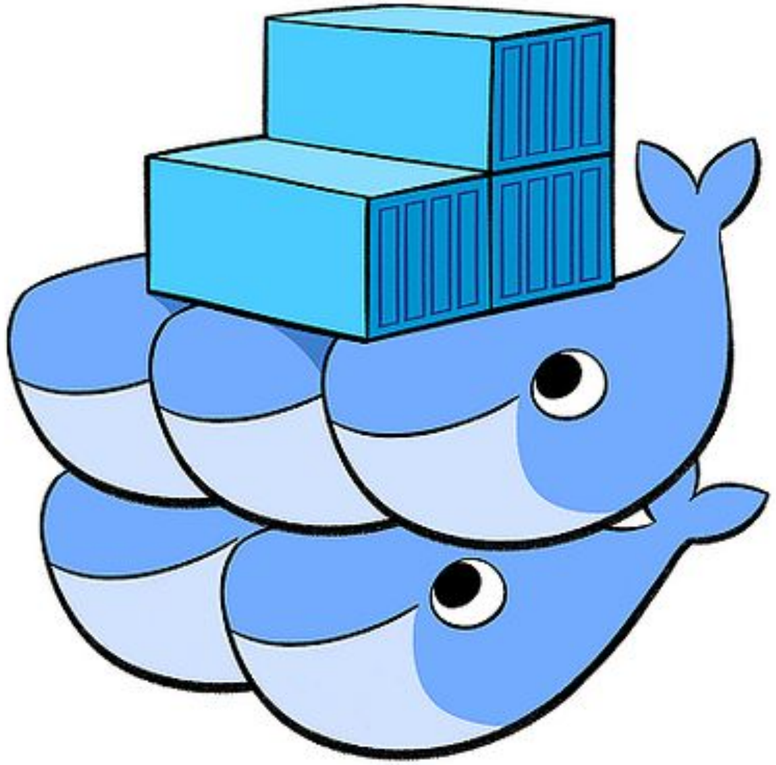

HashiCorp

Nomad

kubernetes

Нужен Kubernetes, выбор дистрибутива

DUC meetup/4

Требования к кластеру Kubernetes

План: 2–3 кластера, dev (+test), prod.

Наш идеальный K8s:

01 Легкий bootstrap/upgrade/downgrade

02 Cordon/drain любого узла

03 Open Source, наличие community

04 Обязательно on-prem

05 Максимальная автономность

06 Понятный control plane

Наша инфраструктура

- 3 сервера HP DL360 Gen10, 1Tb RAM, Intel Xeon Gold 6242R
- NetApp FAS2720, NetApp AFF C190
- VMware vSphere
- 10G Arista + 16G FC Brocade

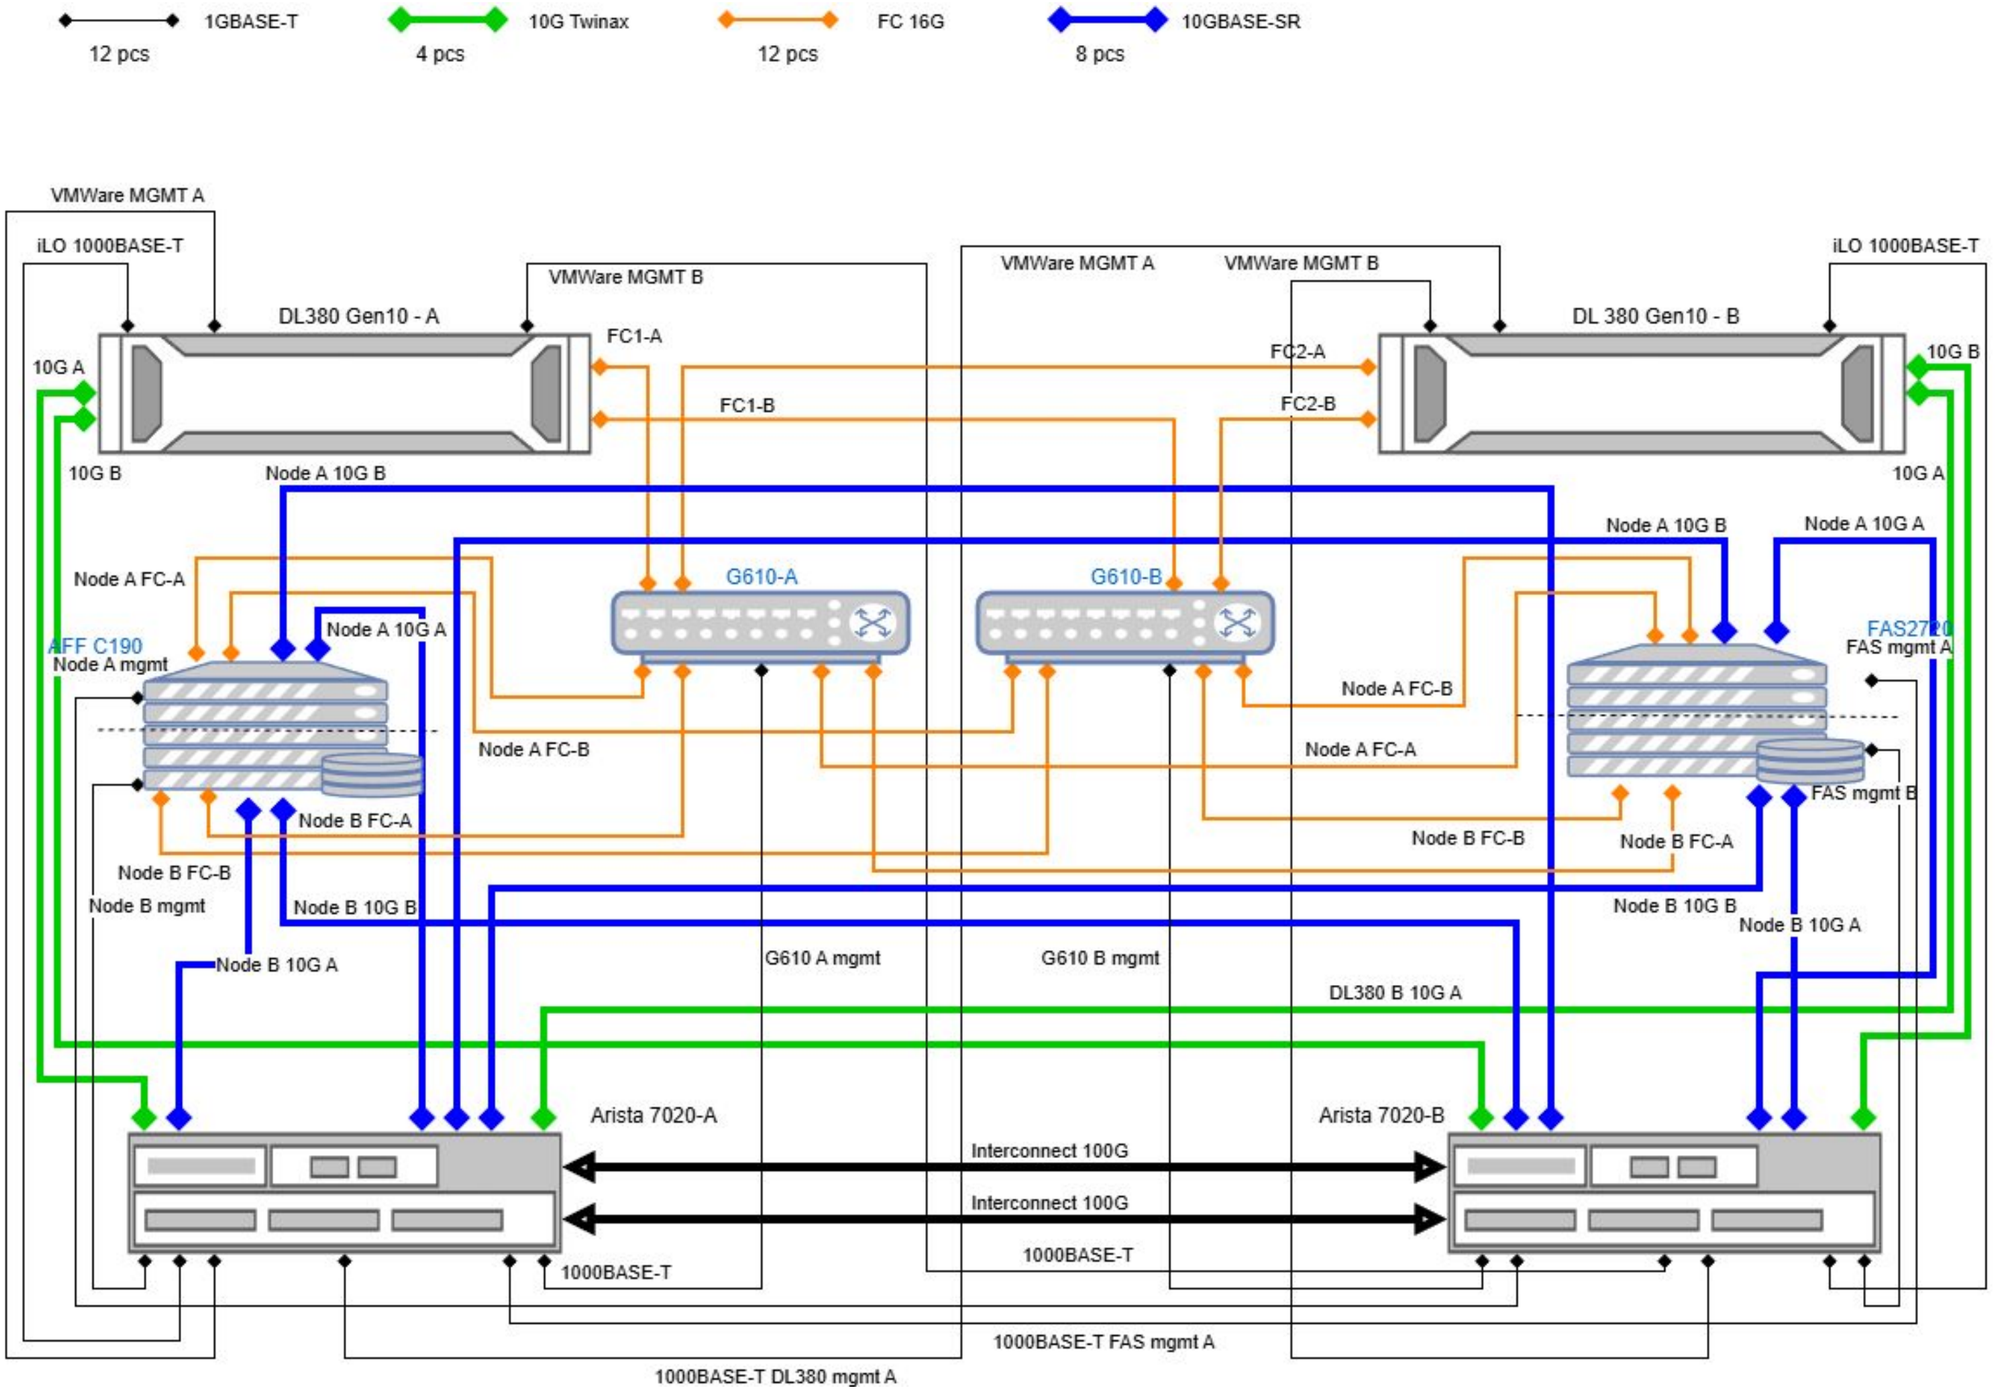
1GBASE-T
12 pcs
10G Twinax
4 pcs
FC 16G
12 pcs
10GBASE-SR
8 pcs
VMWare MGMT A
iLO 1000BASE-T
VMWare MGMT B
DL380 Gen10 - A
FC1-A
FC1-B
10G A
10G B
Node A 10G B
VMWare MGMT A
VMWare MGMT B
iLO 1000BASE-T
DL 380 Gen10 - B
FC2-A
FC2-B
10G B
10G A
Node A 10G B
Node A 10G A
Node A FC-A
G610-A
G610-B
Node A 10G A
AFF C190
Node A mgmt
FAS2720
FAS mgmt A
Node A FC-B
Node A FC-B
Node A FC-A
FAS mgmt B
Node B FC-A
Node B FC-B
Node B FC-A
Node B FC-B
Node B mgmt
Node B 10G B
Node B 10G B
Node B 10G A
Node B 10G A
G610 A mgmt
G610 B mgmt
DL380 B 10G A
Arista 7020-A
Arista 7020-B
Interconnect 100G
Interconnect 100G
1000BASE-T
1000BASE-T
1000BASE-T FAS mgmt A
1000BASE-T DL380 mgmt A

Ставим Kubernetes

Нет понимания, что ставить, чаты рекомендовали
идти в облака, смотрим, что попалось на первый взгляд

Ставим Kubernetes

Нет понимания, что ставить, чаты рекомендовали
идти в облака, смотрим, что попалось на первый взгляд

kelseyhightower/
kubernetes-the-hard-way

Bootstrap Kubernetes the hard way. No scripts.

51 Contributors

18 Used by

47k Stars

15k Forks

Ставим Kubernetes

Нет понимания, что ставить, чаты рекомендовали
идти в облака, смотрим, что попалось на первый взгляд

Ищем альтернативы

На момент лета 2022 года выбор невелик,
прислушиваемся к советам других DevOps

Ищем альтернативы

На момент лета 2022 года выбор невелик,
прислушиваемся к советам других DevOps

Ищем альтернативы

VMware Tanzu

На момент лета 2022 года выбор невелик,
прислушиваемся к советам других DevOps

Ищем альтернативы

На момент лета 2022 года выбор невелик,
прислушиваемся к советам других DevOps

Установка DKP CE

- Packer – готовим OVF template
- Terraform – разворачиваем в VMWare
- Ansible – увеличиваем диски, ставим пакеты, выключаем swap, и т. д.

Узлы DKP CE

- frontend – 2 nodes, HDD
- master – 3 nodes, SSD
- monitoring – 2 nodes, HDD
- system – 2 nodes, HDD
- worker – 3 nodes, HDD

Процесс установки

Рекомендую минимальный базовый курс по K8s, узлы – **clean OS** из рекомендованного списка, открытый контур, «быстрый старт» через консоль утилитой dhctl

- Rollout DKP – быстро и легко
- Документация – RTFM рулит
- Конфиг – недели, если нет опыта
- Чат – https://t.me/deckhouse_ru

Модули

Помимо штатных модулей prometheus, loki, snapshot-controller и т. д., **задеплоены дополнительно:**

- metallb — своя /23 сеть, нужен inlet: LoadBalancer
- netapp trident — PV NetApp
- loki — не хватало decolorize

Infrastructure services

Для полноценной работы команды и приложений потребовались дополнительные сервисы:

- S3 service — MinIO (Garage) для Loki и статики сайта
- Telepresence — удалённая отладка сервисов
- Redis Operator
- Nexus — proxy + python, npm-модули

Production

Prod-кластер DKP CE был развёрнут на порядок быстрее. От обновления образов до полностью сконфигурированного рабочего кластера — пара дней вместе с фоновой работой.

Два кластера — dev на канале EarlyAccess и prod на канале Stable. Для EarlyAccess стабильность не хуже Stabe, но раньше прилетают обновы

На текущий момент на dev- и prod-кластерах DKP CE работает как продакшен, так и разработка во множестве окружений:

- Сайт tjcollection.ru — 13 сервисов, 5 окружений
- Telegram-бот компании @tjcollection_bot (dev + prod)
- Zammad — внутренняя Helpdesk-система
- mini apps — wms-mailer, mark-api, clamav-mirror и т. д.

Что получили от K8s и DKP CE?

DUC meetup/4

Мифы о Kubernetes

Распространено мнение, почему не нужно разворачивать свой Kubernetes.
Также много советов эксплуатировать только managed Kubernetes:

- Очень дорого
- Требует много ресурсов
- Для высоких RPS
- Нужно только гиперскейлерам
- Слишком сложно

Зачем K8s, если вы не ждёте 10K RPS?

Можно же писать монолит и деплоить в VM?

Можно, а зачем?

Когда есть K8s, который стал стандартом, это похоже на изобретение велосипеда

- Ansible playbook’и, bash spaghetti
- Monitoring, alerting, self-healing
- Новый инстанс — новая VM
- Кто сможет это всё поддерживать?

Плюшки Kubernetes

Хотя Kubernetes сложен сам по себе, но то, что он даёт взамен, очень заманчиво. Что мы получили с внедрением Kubernetes?

- Стандартизация деплоя
- IaC-подход
- HPA/VPA
- Rolling Updates
- HA

Плюшки DKP CE

Вместе с K8s в DKP CE получили большой набор полезного тулинга, которым стали активно пользоваться

Мониторинг, алертинг, логи

DUC meetup/4

Deckhouse Prom++

Grafana

VECTOR
BY DATADOG

LE-сертификаты для внутренних сервисов через cert-manager

DUC meetup/4

```yaml
kind: ClusterIssuer
metadata:
  name: letsencrypt-rfc2136
spec:
  acme:
    preferredChain: ""
    privateKeySecretRef:
      name: certmgr-le-priv-key
    server: https://acme-v02.api.lets
encrypt.org/directory
…
```

```yaml
…
    solvers:
    - dns01:
        cnameStrategy: Follow
        rfc2136:
          nameserver: 10.0.0.30
          tsigAlgorithm: HMACSHA512
          tsigKeyName: letsencrypt
          tsigSecretSecretRef:
            key: le-bind-secret-key
            name: le-bind-tsig-secret
```

```
// named.conf
zone "lp.tjcollection.ru" {
  type master;
  file "/etc/namedb/dynamic/lp.tjcollection.ru";
  check-names warn;
  update-policy {
    grant letsencrypt subdomain lp.tjcollection.ru. TXT;
  };
};
```

```
;zone file dynamic/lp.tjcollection.ru
$ORIGIN .
$TTL 3600       ; 1 hour
lp.tjcollection.ru IN SOA ns.tjc.ru. admin.tjc.ru. (
                                2022092126 ; serial
                                900        ; refresh (15 minutes)
                                60         ; retry   (1 minute)
                                86400      ; expire  (1 day)
                                30         ; minimum (30 seconds)
                                )
                          NS      ns.tjc.ru.
```

```
;zone file tjcollection.ru
;[skip]
$ORIGIN tjcollection.ru.
lp                              IN NS ns.tjc.ru.
_acme-challenge.internal        CNAME    _acme-challenge.lp.tjcollection.ru.
```

Dex, kubelogin, GitLab

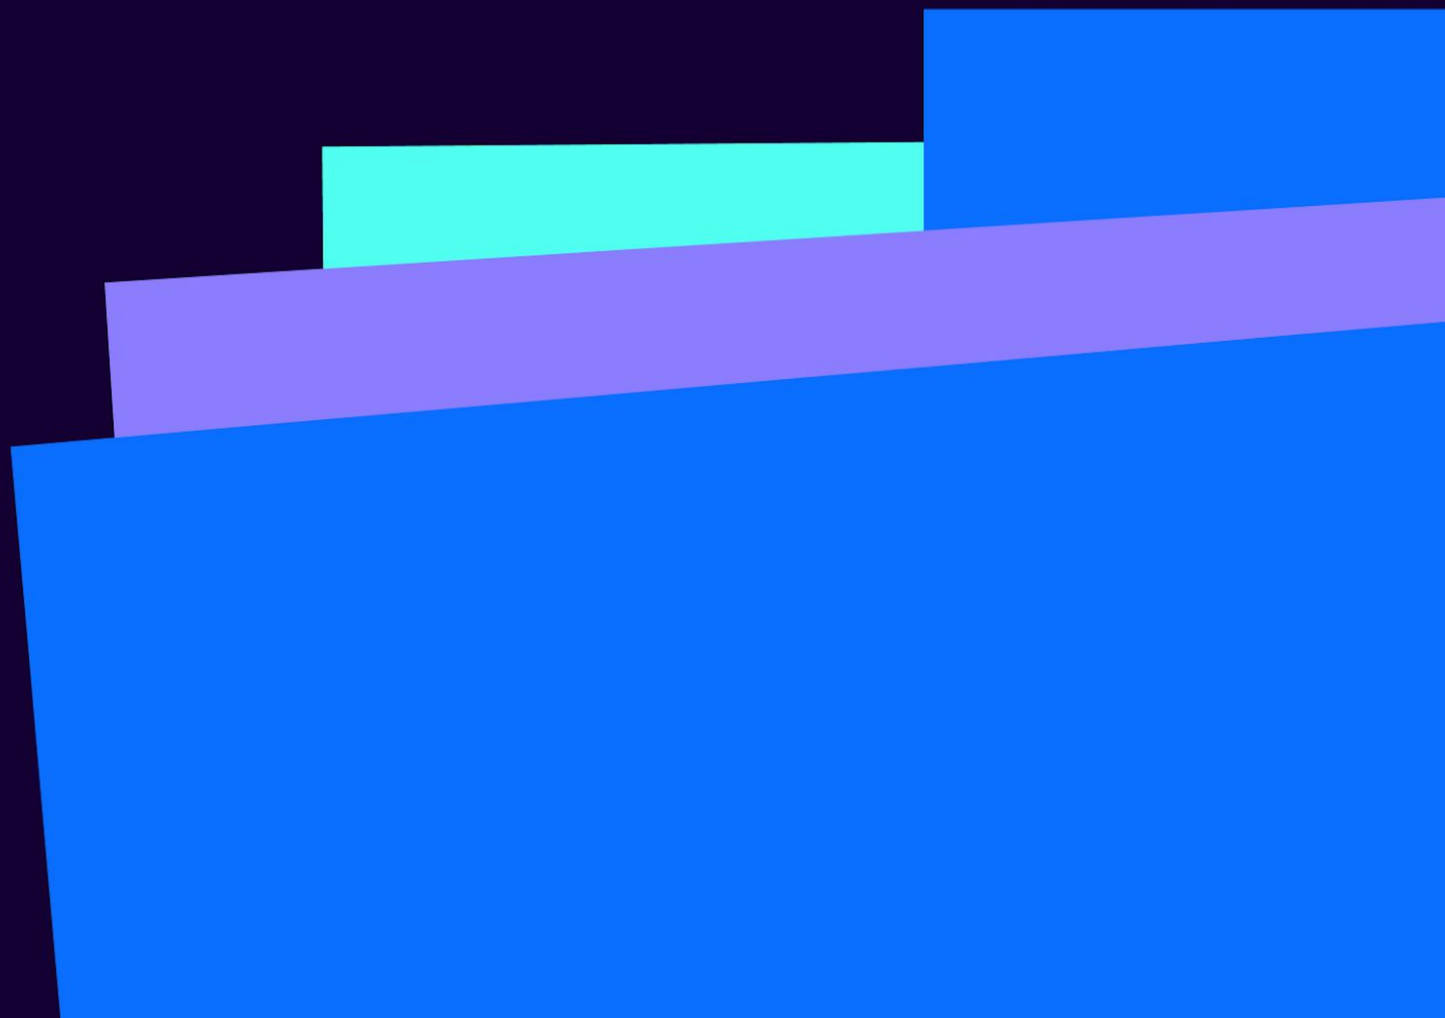

duc meetup/4

```
$ kubectl krew install oidc-login

# kube/config
users:
- name: admin
  user:
    exec:
      apiVersion: client.authentication.k8s.io/v1beta1
      command: kubectl
```

```
args:
- oidc-login
- get-token
- --oidc-issuer-url=https://dex.d8s.tjcollection.ru/
- --oidc-client-id=kubeconfig-generator
- --oidc-client-secret=VeryStrongPassword
- --oidc-extra-scope=email
- --oidc-extra-scope=profile
- --oidc-extra-scope=groups
- --oidc-extra-scope=offline_access
- --grant-type=device-code
- --skip-open-browser
```

```
$ kubectl get pods
Please visit the following URL in your browser:
https://dex.d8s.tjcollection.ru/device?user_code=DFRJ-FNZQ

NAME                                      READY   STATUS      RESTARTS   AGE
clamav-mirror-85f68f65f7-gbclk            1/1     Running     0          22h
clamav-mirror-cronjob-29519040-8r8dp      0/1     Completed   0          9h
clamav-mirror-cronjob-29519280-jnxr8      0/1     Completed   0          5h14m
clamav-mirror-cronjob-29519520-57xjj      0/1     Completed   0          74m
```

Мультитенантность

DUC meetup/4

```yaml
apiVersion: deckhouse.io/v1alpha2
kind: Project
metadata:
  name: clamav-mirror-stage
spec:
  description: Clamav Project
  projectTemplateName: default
  podSecurityProfile: Restricted
…
```

```yaml
…
 parameters:
    resourceQuota:
      requests:
        cpu: 0.5
      limits:
        cpu: 0.5
        memory: 256Mi
    networkPolicy: Isolated
    administrators:
    - subject: Group
      name: admins
```

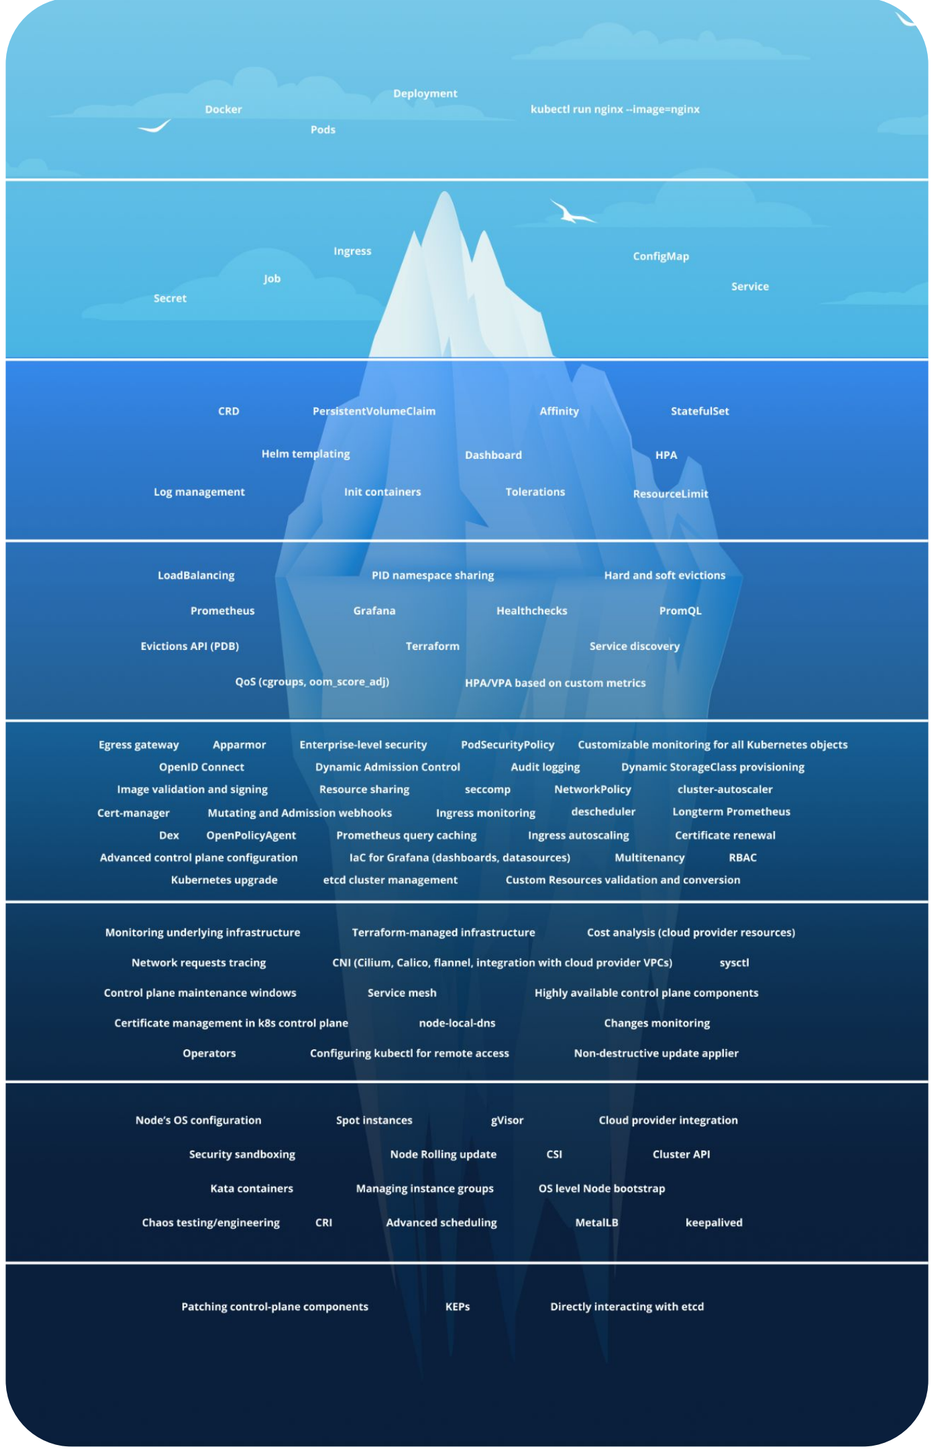
Deployment
Docker
kubectl run nginx --image=nginx
Pods
Ingress
ConfigMap
Job
Service
Secret
CRD
PersistentVolumeClaim
Affinity
StatefulSet
Helm templating
Dashboard
HPA
Log management
Init containers
Tolerations
ResourceLimit
LoadBalancing
PID namespace sharing
Hard and soft evictions
Prometheus
Grafana
Healthchecks
PromQL
Evictions API (PDB)
Terraform
Service discovery
QoS (cgroups, oom_score_adj)
HPA/VPA based on custom metrics
Egress gateway
Apparmor
Enterprise-level security
PodSecurityPolicy
Customizable monitoring for all Kubernetes objects
OpenID Connect
Dynamic Admission Control
Audit logging
Dynamic StorageClass provisioning
Image validation and signing
Resource sharing
seccomp
NetworkPolicy
cluster-autoscaler
Cert-manager
Mutating and Admission webhooks
Ingress monitoring
descheduler
Longterm Prometheus
Dex
OpenPolicyAgent
Prometheus query caching
Ingress autoscaling
Certificate renewal
Advanced control plane configuration
IaC for Grafana (dashboards, datasources)
Multitenancy
RBAC
Kubernetes upgrade
etcd cluster management
Custom Resources validation and conversion
Monitoring underlying infrastructure
Terraform-managed infrastructure
Cost analysis (cloud provider resources)
Network requests tracing
CNI (Cilium, Calico, flannel, integration with cloud provider VPCs)
sysctl
Control plane maintenance windows
Service mesh
Highly available control plane components
Certificate management in k8s control plane
node-local-dns
Changes monitoring
Operators
Configuring kubectl for remote access
Non-destructive update applier
Node's OS configuration
Spot instances
gVisor
Cloud provider integration
Security sandboxing
Node Rolling update
CSI
Cluster API
Kata containers
Managing instance groups
OS level Node bootstrap
Chaos testing/engineering
CRI
Advanced scheduling
MetalLB
keepalived
Patching control-plane components
KEPs
Directly interacting with etcd

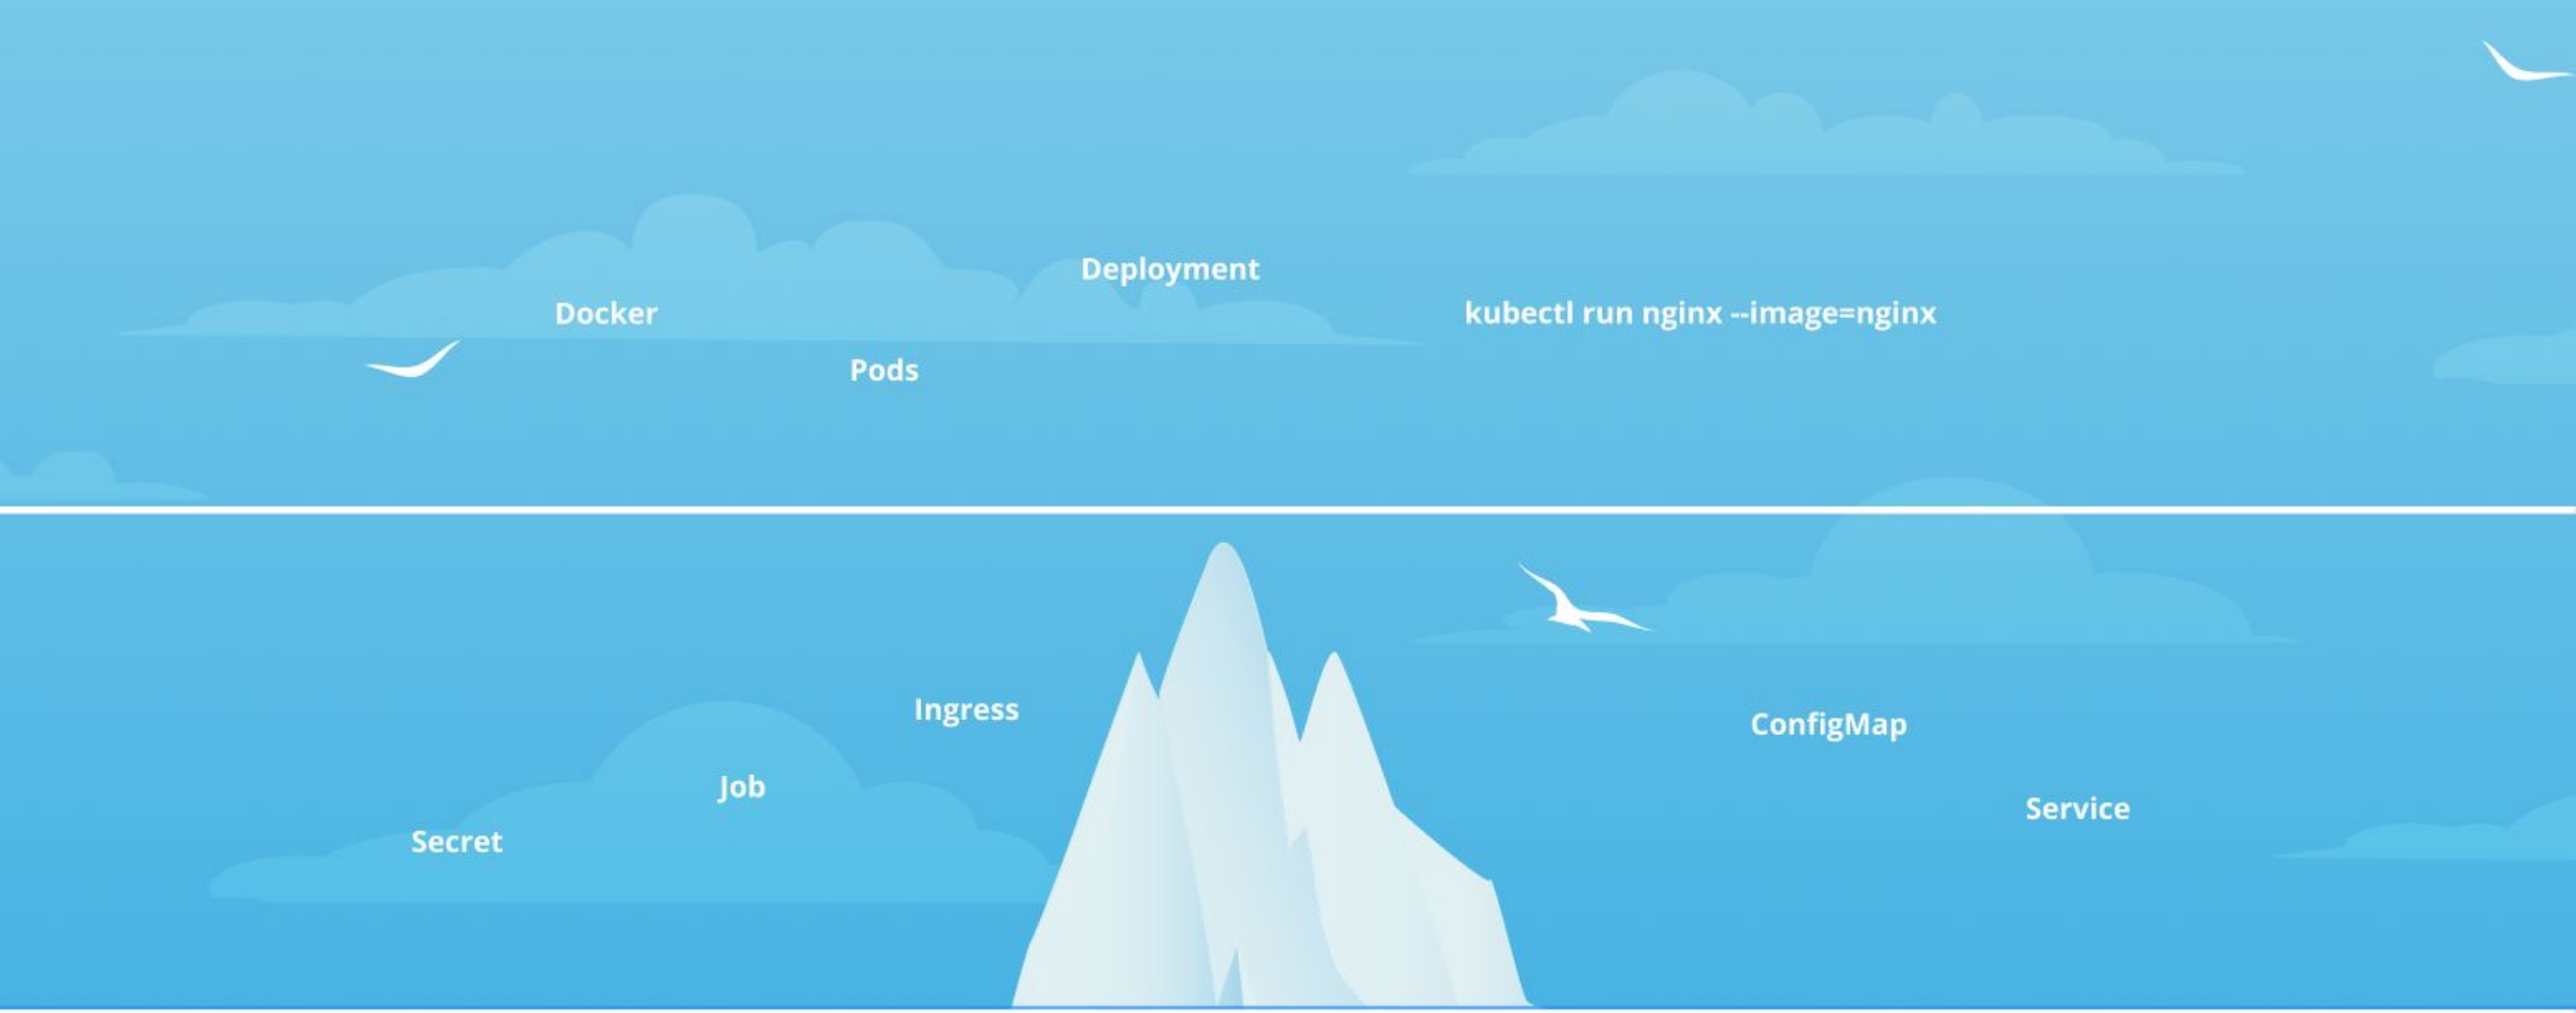
Deployment
Docker
kubectl run nginx --image=nginx
Pods
Ingress
ConfigMap
Job
Service
Secret

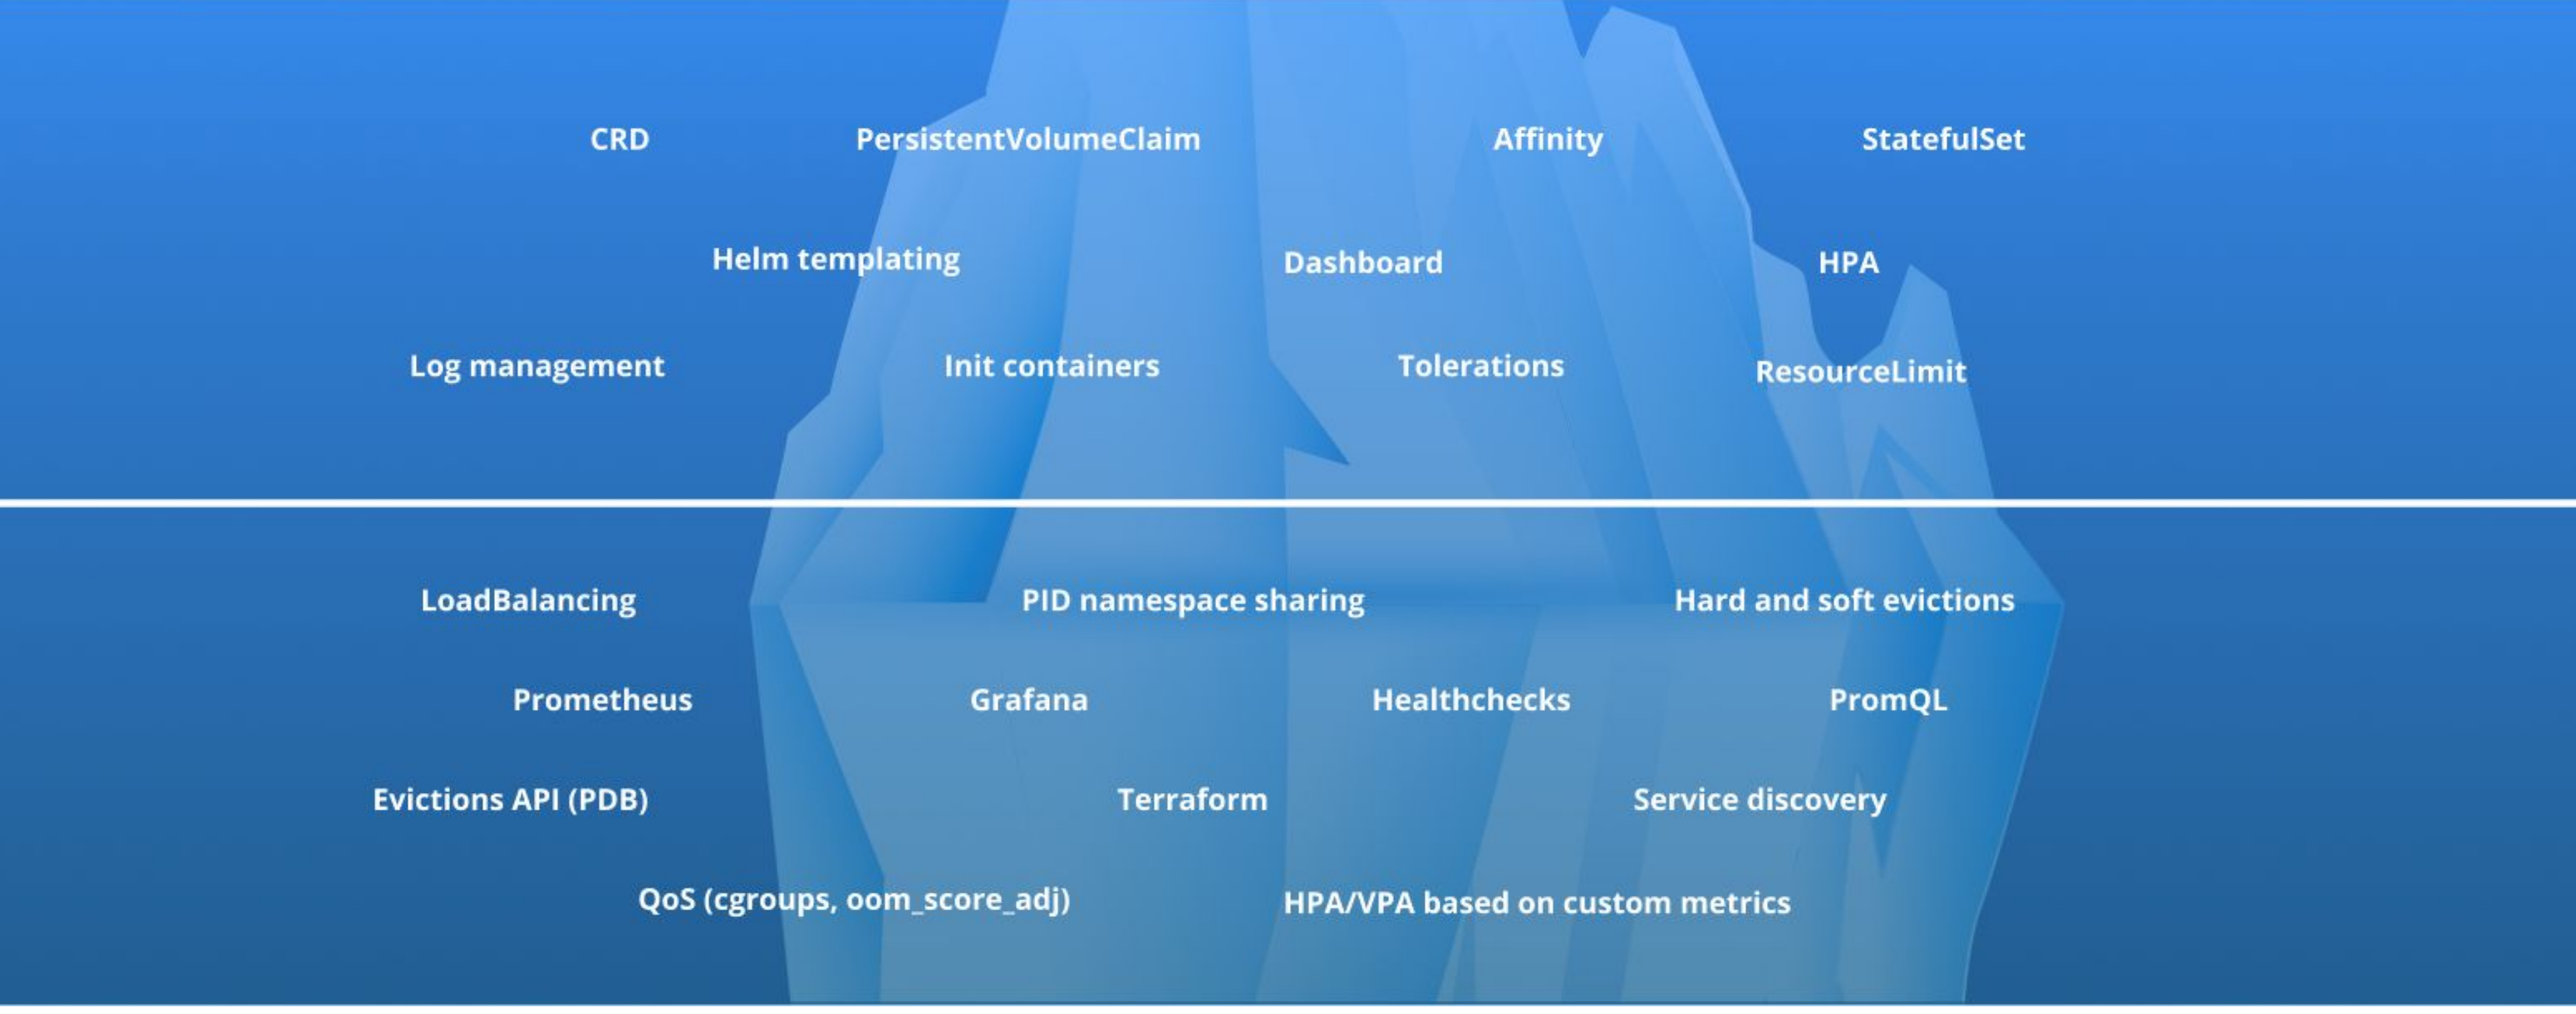
CRD
PersistentVolumeClaim
Affinity
StatefulSet
Helm templating
Dashboard
HPA
Log management
Init containers
Tolerations
ResourceLimit
LoadBalancing
PID namespace sharing
Hard and soft evictions
Prometheus
Grafana
Healthchecks
PromQL
Evictions API (PDB)
Terraform
Service discovery
QoS (cgroups, oom_score_adj)
HPA/VPA based on custom metrics

Egress gateway
Apparmor
Enterprise-level security
PodSecurityPolicy
Customizable monitoring for all Kubernetes objects
OpenID Connect
Dynamic Admission Control
Audit logging
Dynamic StorageClass provisioning
Image validation and signing
Resource sharing
seccomp
NetworkPolicy
cluster-autoscaler
Cert-manager
Mutating and Admission webhooks
Ingress monitoring
descheduler
Longterm Prometheus
Dex
OpenPolicyAgent
Prometheus query caching
Ingress autoscaling
Certificate renewal
Advanced control plane configuration
IaC for Grafana (dashboards, datasources)
Multitenancy
RBAC
Kubernetes upgrade
etcd cluster management
Custom Resources validation and conversion

Monitoring underlying infrastructure
Terraform-managed infrastructure
Cost analysis (cloud provider resources)
Network requests tracing
CNI (Cilium, Calico, flannel, integration with cloud provider VPCs)
sysctl
Control plane maintenance windows
Service mesh
Highly available control plane components
Certificate management in k8s control plane
node-local-dns
Changes monitoring
Operators
Configuring kubectl for remote access
Non-destructive update applier

Node's OS configuration

Spot instances

gVisor

Cloud provider integration

Security sandboxing

Node Rolling update

CSI

Cluster API

Kata containers

Managing instance groups

OS level Node bootstrap

Chaos testing/engineering

CRI

Advanced scheduling

MetalLB

keepalived

Patching control-plane components

KEPs

Directly interacting with etcd

Disclaimer по разработке

Активная разработка заняла 1,5 года. Команда перестроилась на вывод логов в STDOUT, env vars, хранение статики в S3, мигрировали с монорепо в мультирепо. подключили Prometheus Instrumentator к FastAPI

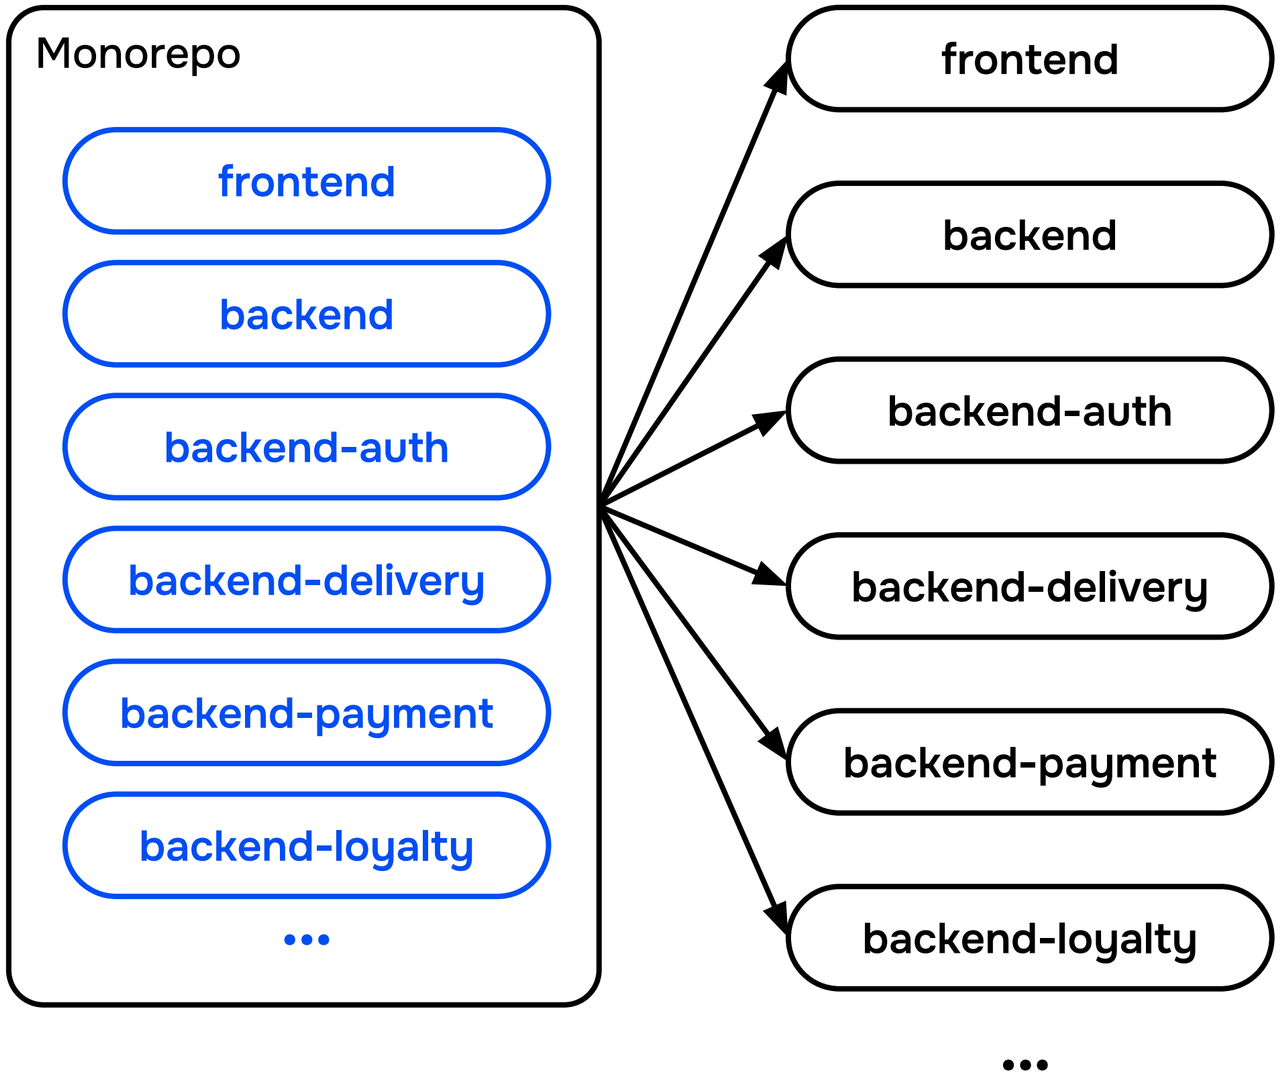
Monorepo
frontend
backend
backend-auth
backend-delivery
backend-payment
backend-loyalty
...
frontend
backend
backend-auth
backend-delivery
backend-payment
backend-loyalty
...

```python
from prometheus_fastapi_instrumentator import Instrumentator
# The Four Golden Signals: Latency, Traffic, Errors, and Saturation.
try:
    instrumentator = Instrumentator(
        excluded_handlers=[
            "/metrics",
            "/healthz/readiness",
            "/healthz/liveness",
        ]
    )
    instrumentator.instrument(app).expose(
        app, endpoint="/metrics", include_in_schema=False, should_gzip=True
    )
except Exception as e:
    logger.error(str(e))
```

Перешли на werf

Билдились через docker build и Kaniko, деплоились Helm’ом. Заменили всё на **werf**, количество CI/CD-кода сократилось, дебаг упростился

Чего не хватает?

Чего не хватает для полного счастья с DKP CE?

- Иногда ловим cannot resolve DNS name на сервисах, не хватает кеша
- Отставание от апстрима модулей, тот же Loki, Grafana
- SDS использовать с планом бэкапа, был опыт с Linstor
- Не хватает магазина приложений, было бы полезно для быстрого деплоя nexus, redis, postgres, S3 и т. д.

Выводы

Какие можно сделать выводы по прошествии года production-эксплуатации двух кластеров DKP?

- Docker compose – только local dev
- Kubesrpay – ванильная боль
- DKP CE – production ready

Можно ли в одного DevOps крутить кубы?

Определенно да, если это DKP CE. Было бы неплохо, если бы ванильный K8s ставился так же просто, как DKP CE. **Что больше всего понравилось:**

- Лёгкость поддержки кластера
- Богатый набор штатного тулинга
- Алерты буквально на всё
- Установка external-модулей
- IaC-подход

CPU

Usage by controller

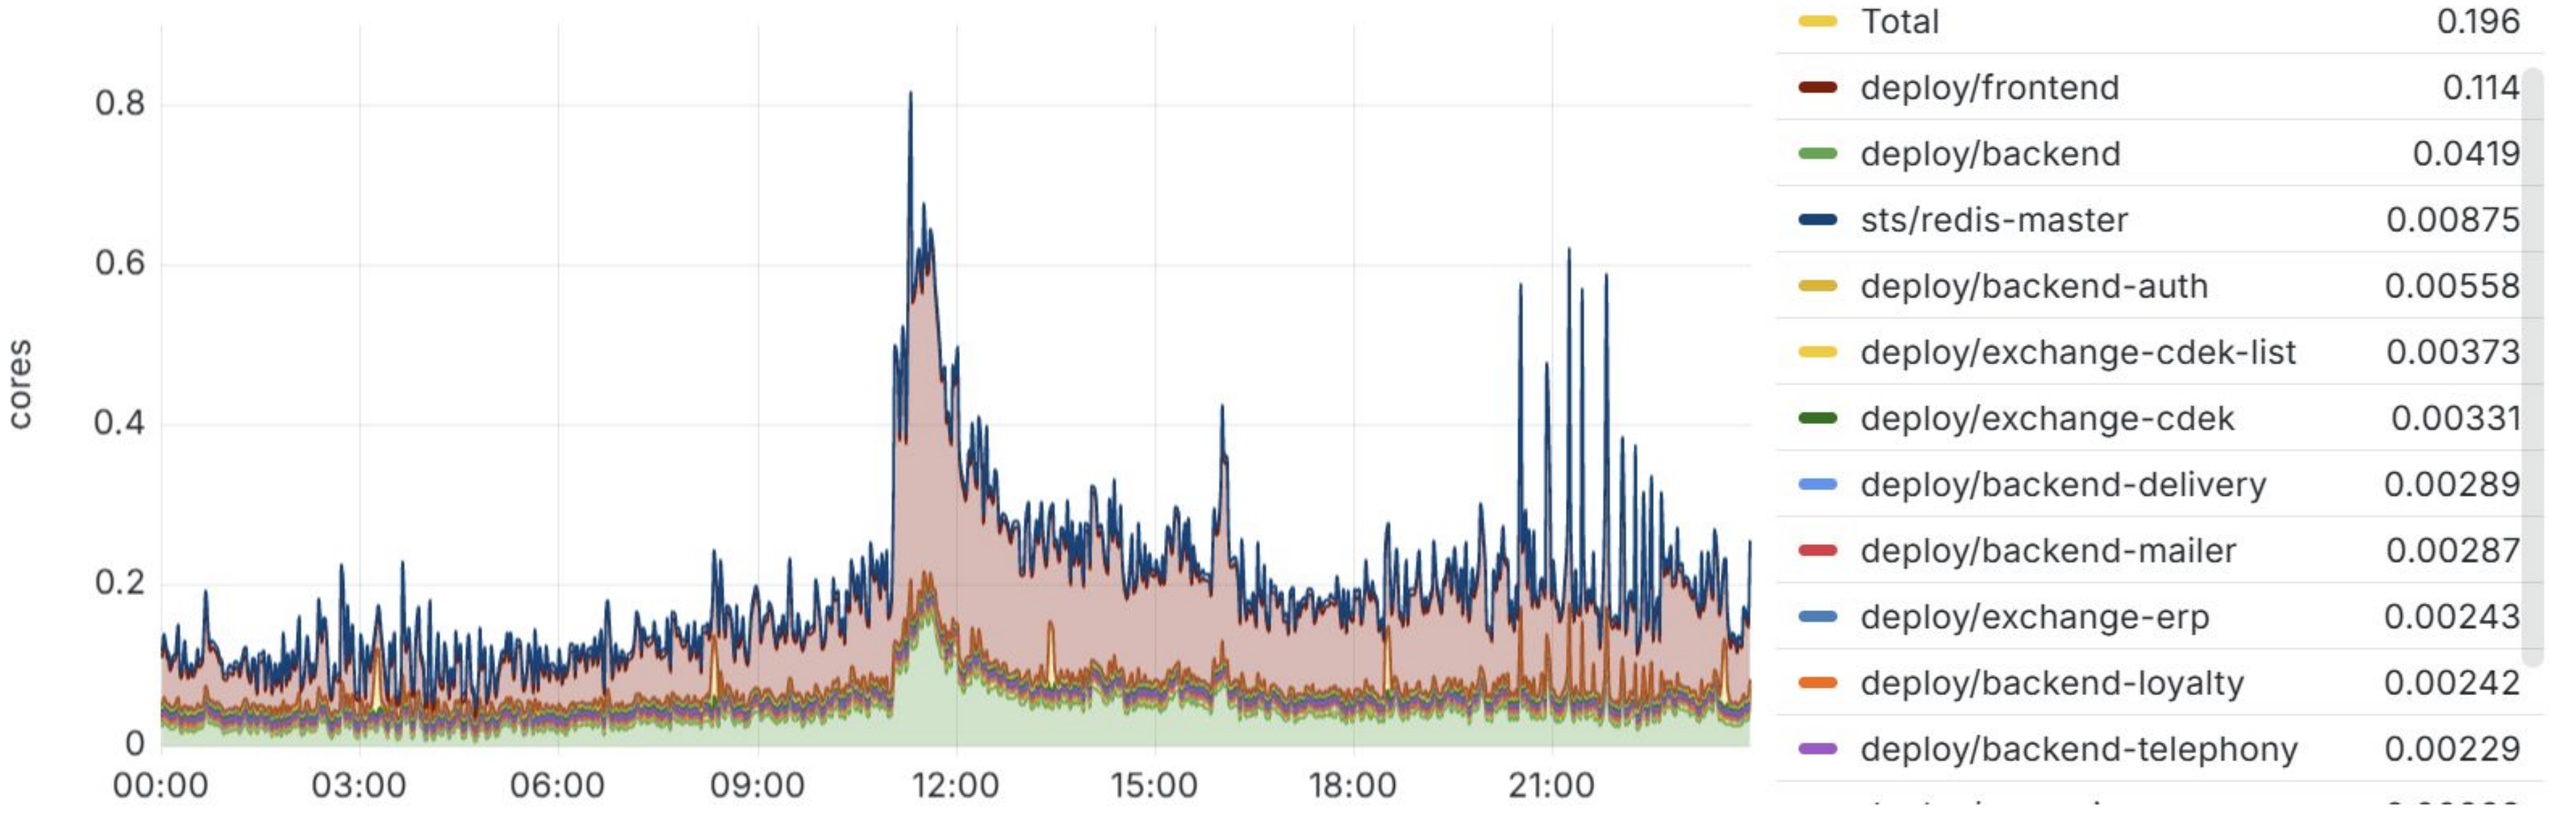

Спасибо за внимание!

DUC meetup/4

Оцените доклад

Вячеслав Дружинин
@dvg_lab, @tjcollection_bot
tjcollection.ru

/Следующий доклад

20:30